Università Politecnica delle Marche

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione



Cancer Risk Factors: Classification e Clustering

Google Stock Data: Forecasting

DATA SCIENCE

Diocis Daniel
Ricci Ettore
Salvatore Pietro
Sebastianelli Nicola

Anno accademico: 2025–2026

Indice

1 Introduzione **5**

2 Dataset Cancer Risk Factors **6**

3 Analisi Esplorativa dei Dati **8**

3.1 Sintesi Statistica e Qualità del Dataset 8

3.2 Analisi delle Caratteristiche Generali 8

3.3 Analisi dei Fattori Comportamentali e Ambientali 11

3.4 Analisi dei Fattori Clinici e del Rischio Complessivo 13

4 Cancer Risk Factors: Classification **16**

4.1 Inquadramento del problema 16

4.2 Analisi preliminare del dataset 16

4.3 Definizione degli scenari sperimentali 19

4.3.1 Scenario A – Scenario ottimistico 19

4.3.2 Scenario B – Scenario realistico 19

4.4 Preprocessing dei dati 20

4.5 Modelli di classificazione 21

4.5.1 Regressione Logistica Multiclasse 22

4.5.2 Random Forest 22

4.5.3 Gradient Boosting 22

4.6 Metriche di valutazione 23

4.7 Risultati sperimentali 24

4.7.1 Scenario A 24

4.7.2 Scenario B 28

4.8 Discussione e conclusioni 32

5 Cancer Risk Factors: Clustering **35**

5.1 Preprocessing del dataset 35

5.2 K-Means 38

5.3 DBSCAN 43

6 Introduzione e Descrizione del Dataset Google Stock Data **47**

6.1 Obiettivi del Progetto 47

6.2 Motivazioni della scelta del dataset 47

6.3 Descrizione delle Variabili 47

7 Google Stock Data: Forecasting **49**
7.1 Fase di ETL e Pre-processing 49
7.1.1 Caricamento e Pulizia dei Dati 49
7.2 Analisi Esplorativa dei Dati (EDA) 50
7.2.1 Analisi Preliminare delle Variabili di Prezzo 50
7.2.2 Analisi dell'Andamento Storico e dei Volumi 51
7.2.3 Distribuzione dei Rendimenti e Volatilità 52
7.2.4 Focus: L'impatto del COVID-19 53
7.2.5 Riepilogo Statistico delle Variabili 55
7.3 Forecasting sul prezzo di chiusura con modello il ARIMA 56
7.3.1 Introduzione e Selezione dei Dati 56
7.3.2 Decomposizione della Serie Temporale (STL) 56
7.3.3 Verifica della Stazionarietà (Test ADF) 58
7.3.4 Identificazione dei Parametri del Modello 59
7.3.5 Selezione del Modello Ottimale (Grid Search) 60
7.3.6 Analisi dei Risultati e Metriche di Performance 60
7.4 Forecasting del Volume con modello SARIMAX 63
7.4.1 Introduzione e Pre-processing dei Dati 63
7.4.2 Decomposizione della Serie Temporale (STL) 63
7.4.3 Analisi di Stazionarietà (Test ADF) 65
7.4.4 Identificazione e Selezione del Modello (Auto-ARIMA) 66
7.4.5 Valutazione dei Risultati e Metriche 67
7.5 Forecasting della Volatilità IntraDay con Prophet 70
7.5.1 Introduzione al Modello Prophet 70
7.5.2 Selezione dei Dati e Definizione del Target 70
7.5.3 Analisi Preliminare e Decomposizione (STL) 71
7.5.4 Configurazione del Modello e Componenti 73
7.5.5 Valutazione dei Risultati 74
7.5.6 Diagnostica e Metriche di Performance 75

Elenco delle figure

1 Copertina del dataset 6
2 Distribuzione delle tipologie di cancro nel dataset. 9
3 Distribuzione dei pazienti per genere. 9
4 Distribuzione dell'età dei pazienti. 10
5 Analisi del BMI con evidenza delle soglie cliniche di rischio. 10
6 Livello di esposizione al fumo di tabacco. 11
7 Frequenza di consumo di alcolici. 11
8 Livello di attività fisica praticata. 12
9 Frequenza del consumo di carne rossa. 12
10 Apporto quotidiano di frutta e verdura. 13
11 Livello di esposizione all'inquinamento atmosferico. 13
12 Prevalenza percentuale di fattori clinici e genetici 14
13 Distribuzione dell'Overall Risk Score per fasce d'età. 14
14 Matrice di correlazione 15
15 Distribuzione percentuale della variabile target nei set di training e test (split stratificato). 17
16 Distribuzione dell'età per classe di rischio oncologico. 18
17 Matrice di confusione – Scenario A (Regressione Logistica con pesi di classe personalizzati) 26
18 Matrice di confusione – Scenario A (Random Forest) 27
19 Matrice di confusione – Scenario A (Gradient Boosting) 28
20 Matrice di confusione – Scenario B (Regressione Logistica con pesi di classe personalizzati) 30
21 Matrice di confusione – Scenario B (Random Forest) 31
22 Matrice di confusione – Scenario B (Gradient Boosting) 32
23 Varianza cumulativa spiegata 37
24 Visualizzazione della struttura dei dati tramite t-SNE 38
25 Grafico dell'Elbow Method 39
26 Cluster ottenuti 39
27 Heatmap con i profili medi dei cluster 40
28 Boxplot dell'Overall_Risk_Score 41
29 Barplot dei livelli di rischio per ciascun cluster 42
30 Grafico della silhouette dei cluster 43
31 Heatmap del numero di cluster generata al variare di ϵ e min_samples . . . 44
32 Heatmap della percentuale di rumore generata al variare di ϵ e min_samples 44

33 Heatmap della silhouette generata al variare di ϵ e min_samples 45
34 Cluster individuati dal DBSCAN tramite t-SNE 45
35 Confronto andamento prezzi: Open, High, Low e Close. 50
36 Andamento storico del prezzo Adj Close (2004-2022). 51
37 Evoluzione del volume di scambi nel tempo. 52
38 Distribuzione di frequenza dei rendimenti giornalieri. 52
39 Andamento della volatilità nel tempo. 53
40 Dettaglio del crollo e della ripresa immediata (Marzo-Agosto 2020). 53
41 Panoramica del trend nel periodo pandemico 54
42 Decomposizione STL: Trend, Stagionalità e Residui. 57
43 Confronto: Serie Originale vs Serie Differenziata. 59
44 Funzioni di Autocorrelazione (ACF) e Autocorrelazione Parziale (PACF). . 59
45 Sommario statistico del modello ARIMA(3,2,1). 60
46 Confronto Valori Reali vs Forecast ARIMA(3,2,1) 61
47 Dettaglio Zoom: Confronto Valori Reali vs Forecast ARIMA. 61
48 Decomposizione STL del Volume: Trend, Stagionalità e Residui. 64
49 Autocorrelazione (ACF) e Autocorrelazione Parziale (PACF) del Volume. . 66
50 Sommario statistico del modello SARIMAX selezionato. 67
51 Confronto Volume Reale vs Forecast SARIMAX (Mensile). 67
52 Dettaglio Zoom: Confronto Volume Reale vs Forecast. 68
53 Decomposizione STL del Range: Volatilità osservata, Trend, Stagionalità e Residui. 71
54 Profilo di rischio mensile: Media e Deviazione Standard del Range. 72
55 Componenti del modello Prophet: Trend, Festività e Stagionalità. 73
56 Confronto Range Reale vs Previsione Prophet 74
57 Dettaglio Zoom: La previsione (linea rossa) vs Realtà (linea grigia). 74
58 Diagnostica dei Residui: Analisi temporale, distribuzione, Q-Q Plot e Autocorrelazione 75

1 Introduzione

La tesina di seguito esposta mira a mostrare le analisi effettuate sui dataset **Cancer Risk Factors** e **Google Stock Data**, e ad evidenziarne i risultati ottenuti.
Lo studio è stato realizzato attraverso l'applicazione di tecniche di machine learning per eseguire operazioni di classificazione e clustering per il primo dataset; e di forecasting per il secondo.

La presente tesina, dunque, si articola come segue:

- Il primo capitolo sarà dedicato alla presentazione del dataset *Cancer Risk Factors*, andando ad evidenziarne le caratteristiche che esso presenta;
- Il secondo capitolo mirerà a presentare lo studio effettuato durante l'analisi descrittiva e i relativi risultati ottenuti;
- Il terzo capitolo mostrerà le analisi effettuate attraverso le tecniche di clustering e i rispettivi risultati ottenuti;
- Il quarto capitolo presenterà la struttura del dataset *Google Stock Data*, andando ad evidenziarne le caratteristiche presenti;
- Il quinto capitolo sarà volto ad esporre le tecniche di analisi predittiva effettuate e i risultati ottenuti.

2 Dataset Cancer Risk Factors



Figura 1: Copertina del dataset

Il dataset *Cancer Risk Factors*, disponibile sulla piattaforma Kaggle, esamina come fattori di stile di vita condotto, ambientali e genetici possano influenzare il manifestarsi di alcune tra le tipologie più diffuse di cancro.

Sebbene i dati presenti siano simulati, e, quindi, non corrispondano a diagnosi effettuate su individui reali, il dataset si presenta fornito e, soprattutto, adatto a studi negli ambiti del machine learning, di ricerca e studi accademici.

Il dataset contiene 2000 record di pazienti, e, per ognuno di essi, le seguenti feature:

- **Informazioni sul paziente**:
  - **Patient_ID**: Identificativo univoco assegnato a ciascun paziente, ad esempio: LU0000;
- **Target**:
  - **Cancer_Type**: tipologia di cancro riscontrata (polmoni, seno, colon, prostata e pelle);
  - **Risk_Level**: livello di rischio (basso, medio o alto);
  - **Overall_Risk_Score**: valore numerico del rischio (basso se < 0.33, medio se $[0.35, 0.66]$, alto se > 0.66);
- **Demografica**:

  - **Age**: età del paziente;
  - **Gender**: genere del paziente (0 = donna, 1 = uomo);
  - **BMI**: indice di massa corporea del paziente;

- **Feature riguardanti lo stile di vita condotto e fattori ambientali**. Ognuna di esse è un indice compreso tra 0 e 10, e più alto è il valore, maggiore è l'intensità o l'esposizione del paziente:
  - **Smoking**;
  - **Alcohol_Use**;
  - **Obesity**;
  - **Diet_Red_Meat**;
  - **Diet_Salted_Processed**;
  - **Fruit_Veg_Intake**;
  - **Physical_Activity**;
  - **Physical_Activity_Level**;
  - **Air_Pollution**;
  - **Occupational_Hazards**;
  - **Calcium_Intake**

- **Feature genetiche o mediche**. Esse presentano valori booleani:
  - **Family_History**: se la famiglia del paziente ha avuto una diagnosi di cancro in passato;
  - **BRCA_Mutation**: mutazione dei geni BRCA1 e BRCA2, frequente nelle casistiche di tumori al seno e alla prostata;
  - **H_Pylori_Infection**: infezione che aumenta il rischio di tumori gastrici.

3 Analisi Esplorativa dei Dati

Questo capitolo è dedicato all'Analisi Esplorativa dei Dati (EDA), una fase fondamentale per comprendere la natura e la struttura del dataset in esame prima di procedere con la modellazione. L'obiettivo principale di questa esplorazione è estrarre informazioni preliminari sulle caratteristiche dei pazienti, analizzare le distribuzioni delle singole variabili e individuare le dinamiche che legano i diversi fattori predittivi al rischio oncologico.

3.1 Sintesi Statistica e Qualità del Dataset

Come fase preliminare, si è proceduto alla verifica della struttura e della qualità del dataset. Il campione risulta composto da 2000 osservazioni e 21 variabili. Non è stata riscontrata la presenza di valori mancanti (nulli) o di righe duplicate, garantendo l'integrità dei dati per le analisi successive. Nella Tabella 1 vengono riportate le principali statistiche descrittive calcolate sui parametri numerici del dataset.

Variabile	**Media**	**Dev. Std.**	**Min**	**Mediana**	**Max**
Age	63.25	10.46	25.00	64.00	90.00
BMI	26.18	3.95	15.00	26.20	41.40
Risk Score	0.45	0.12	0.03	0.46	0.85

Tabella 1: Statistiche descrittive del dataset

3.2 Analisi delle Caratteristiche Generali

Si è esaminata inizialmente la prevalenza delle diverse tipologie di cancro all'interno del dataset. Questo passaggio permette di inquadrare quali patologie siano più frequenti nella popolazione studiata, come illustrato nella Figura 2.

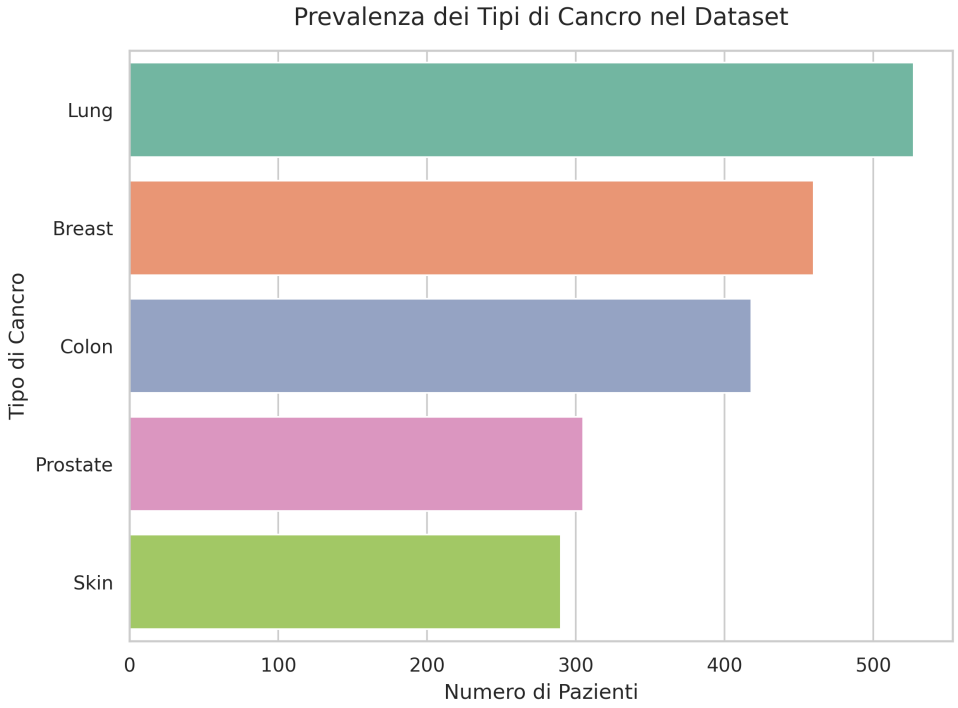


Figura 2: Distribuzione delle tipologie di cancro nel dataset.

Successivamente, si è analizzata la composizione del campione rispetto al genere dei pazienti. Come si può osservare nella Figura 3, il dataset presenta un ottimo equilibrio tra maschi e femmine, condizione ottimale per evitare distorsioni (bias) nelle fasi di modellazione.

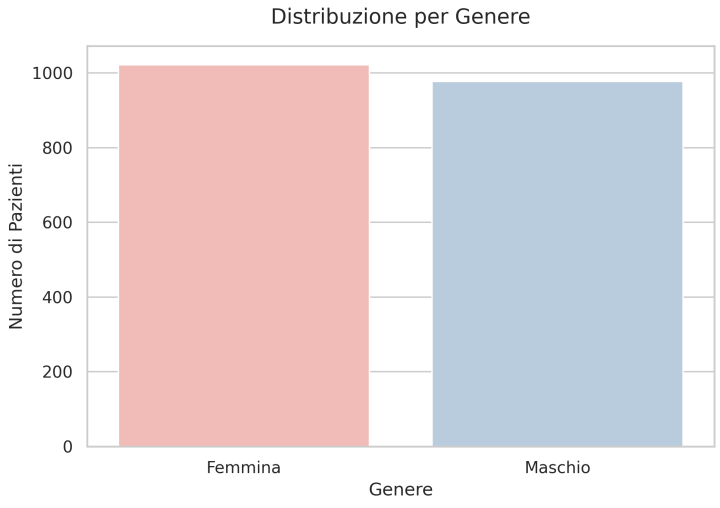


Figura 3: Distribuzione dei pazienti per genere.

Per quanto riguarda i parametri anagrafici, si è studiata la distribuzione dell'età. Nella Figura 4 si nota come il campione copra un ampio spettro anagrafico, con una

concentrazione maggiore nelle fasce d'età più avanzate, coerentemente con la natura della patologia.

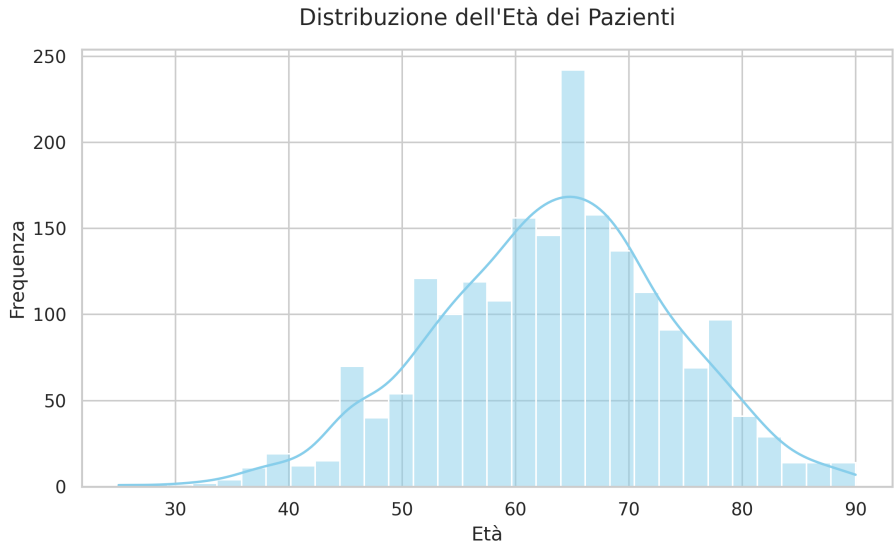


Figura 4: Distribuzione dell'età dei pazienti.

Parallelamente all'età, è stata analizzata la distribuzione del Body Mass Index (BMI). Nella Figura 5 sono state evidenziate le soglie cliniche di sovrappeso (25) e obesità (30), permettendo di quantificare immediatamente la frequenza dei soggetti che rientrano in queste categorie di rischio. Si nota come circa la metà dei pazienti presenti nel dataset siano almeno in sovrappeso e di questi una buona parte presentano obesità.

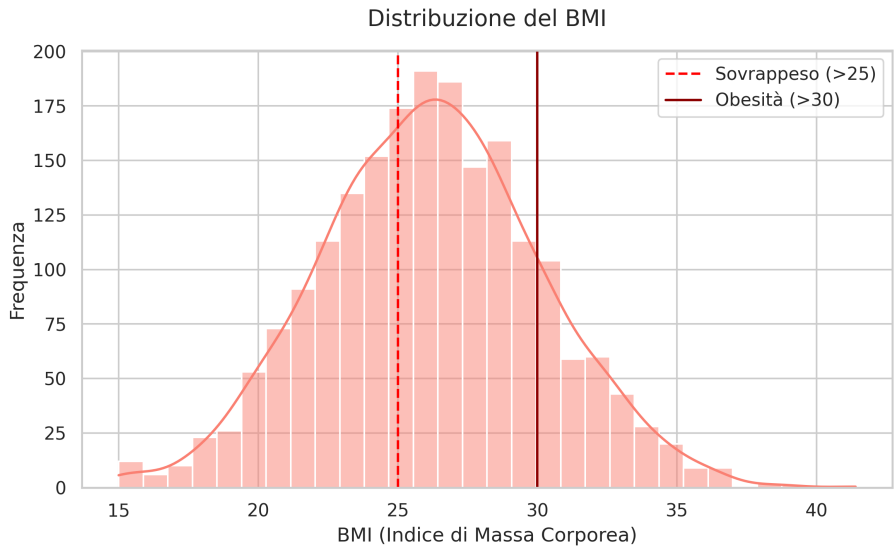


Figura 5: Analisi del BMI con evidenza delle soglie cliniche di rischio.

3.3 Analisi dei Fattori Comportamentali e Ambientali

Si è passati poi allo studio delle variabili legate allo stile di vita e all'ambiente, valutate su una scala da 0 a 10. La prima variabile analizzata è l'esposizione al fumo di tabacco, la cui distribuzione è visibile nella Figura 6.

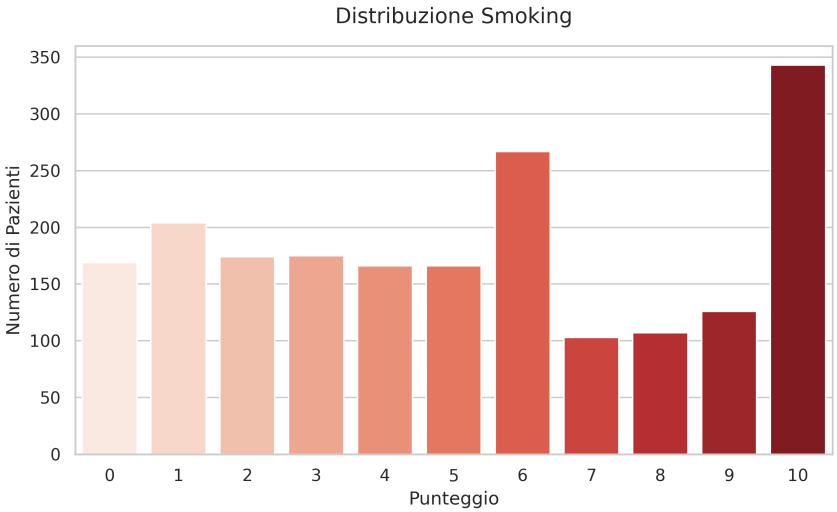


Figura 6: Livello di esposizione al fumo di tabacco.

Allo stesso modo, si è valutata la frequenza di consumo di alcolici tra i pazienti. I risultati riportati nella Figura 7 mostrano come la popolazione sia distribuita lungo i diversi livelli di consumo dichiarati.

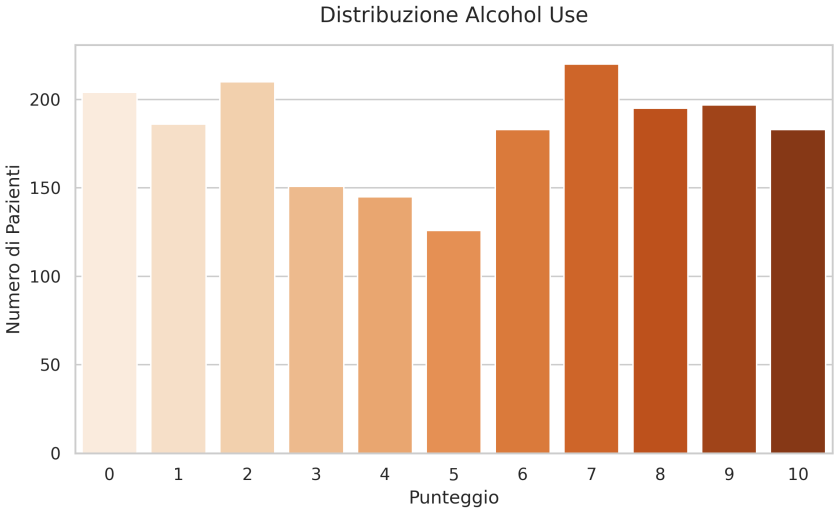


Figura 7: Frequenza di consumo di alcolici.

Per quanto riguarda l'attività fisica, è stata esaminata la frequenza con cui i pazienti praticano sport o movimento. La Figura 8 illustra la distribuzione di questo parametro fondamentale per il benessere e la prevenzione.

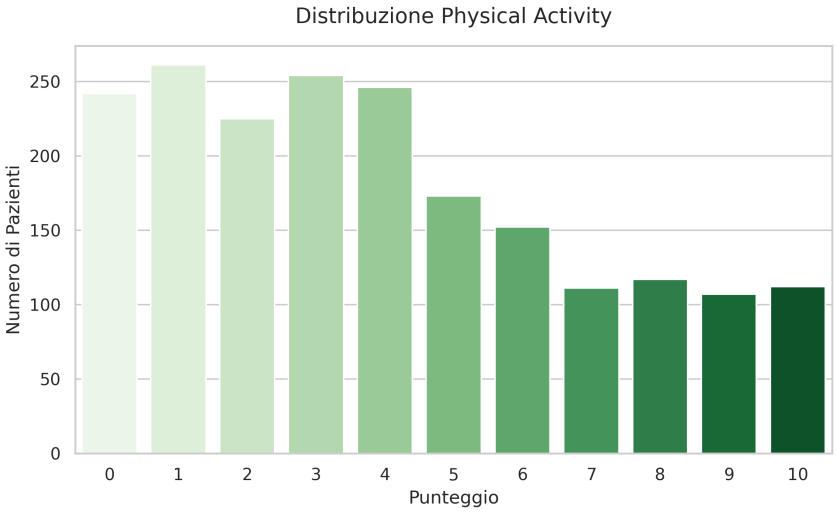


Figura 8: Livello di attività fisica praticata.

In ambito alimentare, si è analizzato il consumo dichiarato di carne rossa, spesso associato a determinati profili di rischio dietetico. La distribuzione è visibile nella Figura 9.

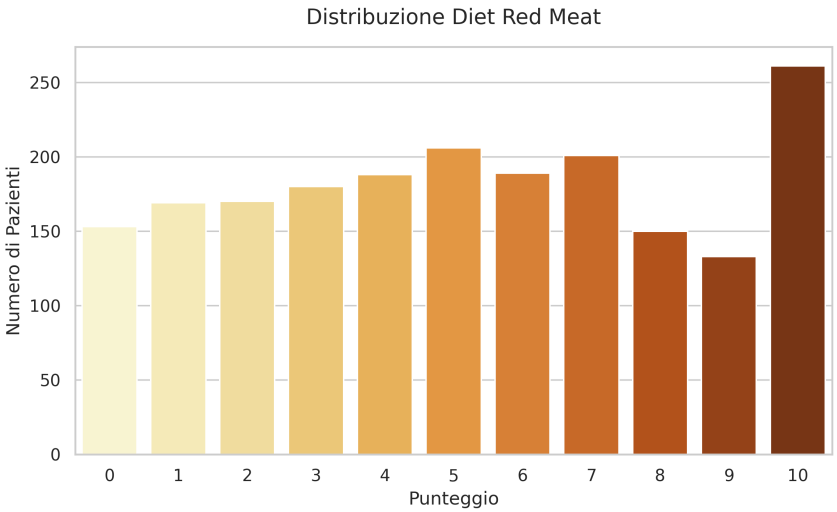


Figura 9: Frequenza del consumo di carne rossa.

Complementarmente, si è valutato l'apporto quotidiano di frutta e verdura. Come mostrato nella Figura 10, è possibile osservare la varietà delle abitudini alimentari salutari all'interno del campione studiato.

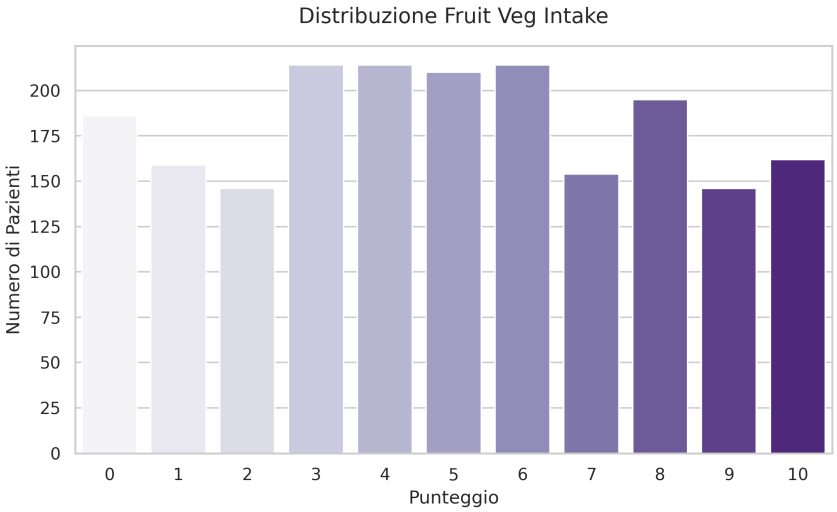


Figura 10: Apporto quotidiano di frutta e verdura.

Infine, si è considerata l'esposizione all'inquinamento atmosferico come fattore di rischio ambientale esterno. La Figura 11 mostra la ripartizione dei pazienti rispetto a questo parametro. Si nota un numero maggiore di pazienti nella fascia 10.

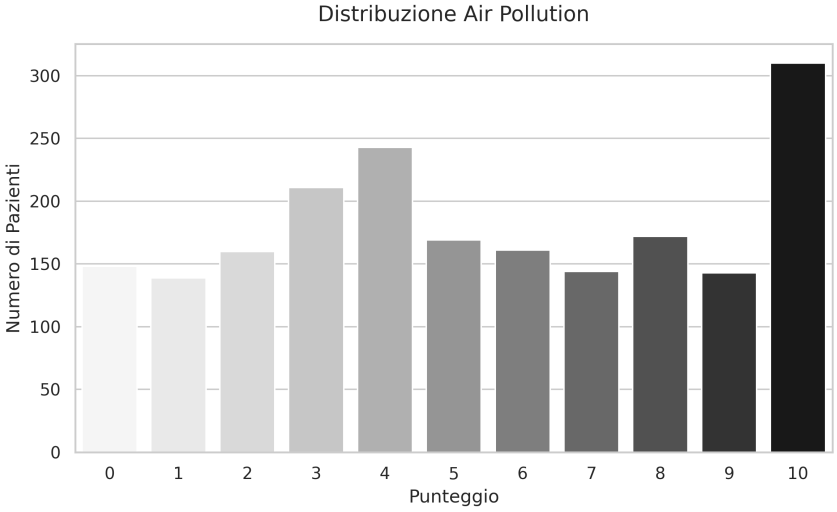


Figura 11: Livello di esposizione all'inquinamento atmosferico.

3.4 Analisi dei Fattori Clinici e del Rischio Complessivo

Per concludere la fase di analisi esplorativa è stata esaminata la prevalenza dei fattori clinici e genetici, come la familiarità o le mutazioni genetiche (Figura 12). Si osserva che tali condizioni interessano solo una parte sul totale dei pazienti; questo suggerisce che l'*Overall Risk Score* sia dovuto in buona parte dalla combinazione degli altri fattori ambientali e comportamentali analizzati e in una parte minore da fattori genetici.

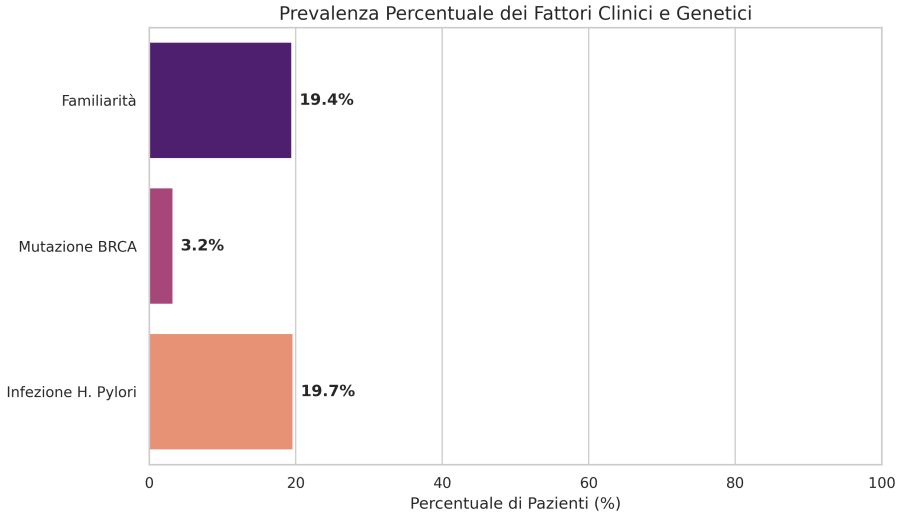


Figura 12: Prevalenza percentuale di fattori clinici e genetici

L'analisi del punteggio di rischio complessivo suddiviso per fasce d'età (Figura 13) evidenzia un trend incrementale molto chiaro. Si nota visivamente come la mediana del rischio aumenti progressivamente con l'avanzare dell'età, confermando l'invecchiamento come uno dei principali determinanti del punteggio di rischio. Si nota, però nella fascia 66-80 una leggera riduzione.

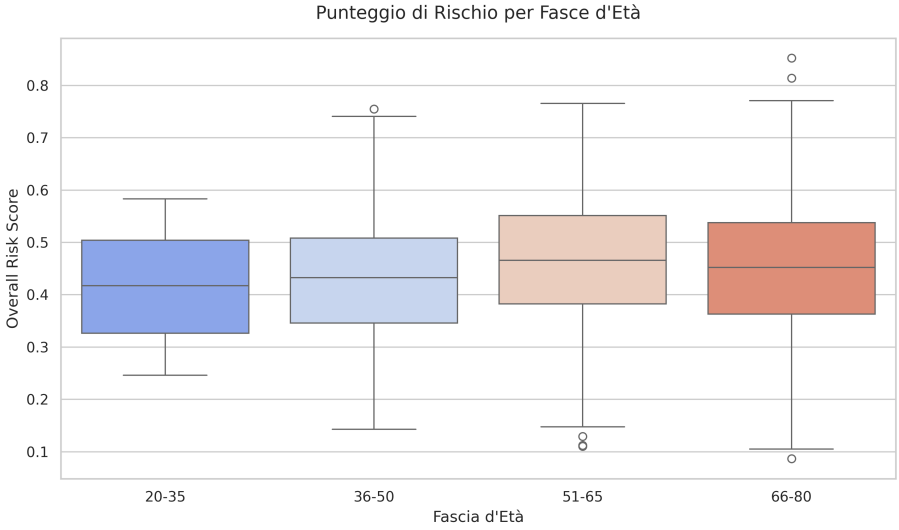


Figura 13: Distribuzione dell'Overall Risk Score per fasce d'età.

Infine, per concludere l'analisi esplorativa, è stata calcolata la matrice di correlazione lineare (Indice di Pearson) tra i principali parametri fisici, comportamentali e il punteggio di rischio complessivo (Figura 14).

Dall'analisi dettagliata dei coefficienti, emergono due ordini di considerazioni fondamentali per le successive fasi di progetto. In primo luogo, osservando la relazione tra

i predittori e la variabile target (*Overall Risk Score*), spicca la forte correlazione positiva del fattore fumo (**0.43**), che si conferma il principale indicatore di rischio lineare nel campione. Seguito, con un impatto moderato ma significativo, il consumo di alcolici (**0.39**).

In secondo luogo, focalizzando l'attenzione sulle interazioni reciproche tra le singole variabili predittive (come ad esempio Fumo-Alcol, o Età-BMI), si nota come tutti i coefficienti siano prossimi allo zero.

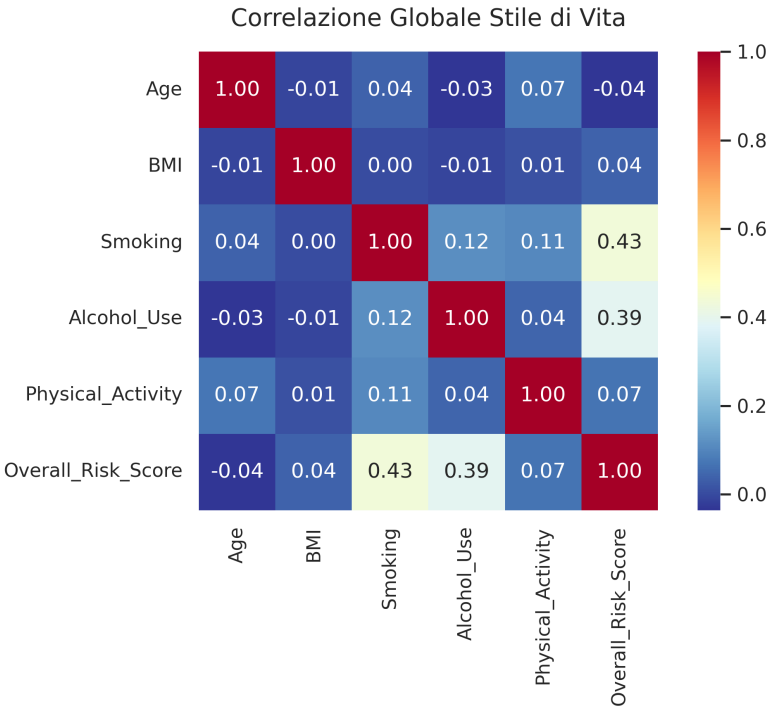


Figura 14: Matrice di correlazione

4 Cancer Risk Factors: Classification

4.1 Inquadramento del problema

Il presente capitolo affronta il problema della predizione del livello di rischio oncologico di un individuo sulla base di un insieme eterogeneo di fattori demografici, comportamentali e clinici. In particolare, l'obiettivo è stimare la probabilità che un soggetto rientri in una delle tre classi di rischio definite nel dataset, ovvero *Low*, *Medium* e *High*.

Dal punto di vista metodologico, il problema è stato modellato come un task di classificazione supervisionata multiclasse, in cui a ciascun campione è associata una classe target discreta. Questo tipo di formulazione è coerente con numerosi scenari applicativi in ambito sanitario, dove l'obiettivo non è fornire una stima puntuale del rischio, bensì supportare il processo decisionale attraverso una categorizzazione del livello di pericolosità.

Il dataset utilizzato, denominato *Cancer Risk Factors Dataset*, contiene informazioni relative allo stile di vita dei soggetti, alla loro storia clinica e ad alcune caratteristiche personali, includendo variabili sia numeriche sia categoriche. Tale eterogeneità rende il problema particolarmente interessante dal punto di vista della modellazione, richiedendo un'adeguata fase di preprocessing e una selezione attenta delle tecniche di classificazione.

Il dataset contiene complessivamente 2000 osservazioni ed è caratterizzato da una forte eterogeneità tra feature numeriche e categoriche, nonché da una marcata asimmetria nella distribuzione della variabile target.

Formalmente, il problema può essere descritto come una funzione di classificazione $f : \mathbb{R}^d \to \mathcal{Y}$, con $\mathcal{Y} = \{\text{Low}, \text{Medium}, \text{High}\}$, dove d rappresenta il numero di feature osservabili dopo il preprocessing. L'obiettivo è apprendere una funzione che massimizzi la capacità discriminativa tra le classi, con particolare attenzione alla corretta identificazione dei soggetti ad alto rischio.

4.2 Analisi preliminare del dataset

Un'analisi esplorativa iniziale del dataset è stata condotta al fine di comprenderne la struttura, la distribuzione delle variabili e le principali criticità in vista della fase di modellazione. In particolare, è stata analizzata la distribuzione della variabile target `Risk_Level`, che rappresenta il livello di rischio oncologico associato a ciascun individuo.

I risultati mostrano una distribuzione fortemente sbilanciata delle classi, con una netta prevalenza della classe *Medium*, che rappresenta circa il 79% dei campioni, seguita dalla classe *Low* (circa il 16%) e da una quota residua di soggetti appartenenti alla classe *High* (circa il 5%). Questo sbilanciamento riflette una situazione realistica, in cui i casi ad alto rischio risultano naturalmente meno frequenti rispetto a quelli a rischio moderato o basso.

Tabella 2: Distribuzione della variabile target nei set di training e test.

Split	**Low**	**Medium**	**High**
Train	0.162	0.787	0.051
Test	0.162	0.788	0.050

A supporto dell'analisi quantitativa riportata in Tabella 2, in Figura 15 è mostrata la distribuzione percentuale della variabile target nei set di training e test.

Il grafico evidenzia come la procedura di suddivisione del dataset sia stata condotta in modo stratificato, preservando la distribuzione originale delle classi nei due sottoinsiemi. In particolare, le percentuali associate alle classi *Low*, *Medium* e *High* risultano pressoché identiche tra training e test, a conferma dell'assenza di distorsioni introdotte dallo split.

Tale aspetto risulta cruciale nel contesto considerato, caratterizzato da un forte sbilanciamento della classe *High*, poiché garantisce che le prestazioni dei modelli siano valutate su un test set rappresentativo della distribuzione reale dei dati.

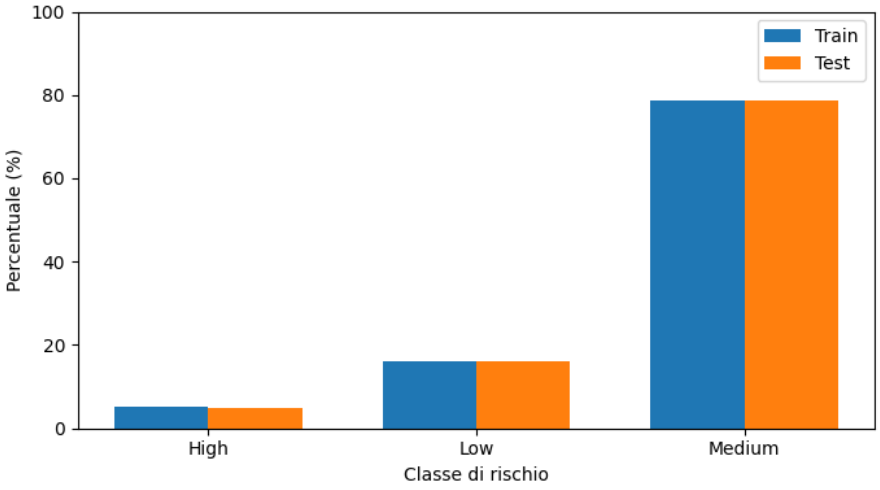


Figura 15: Distribuzione percentuale della variabile target nei set di training e test (split stratificato).

Al fine di analizzare il comportamento delle variabili numeriche rispetto al livello di rischio, è stata inoltre considerata la distribuzione dell'età nei diversi gruppi della variabile target.

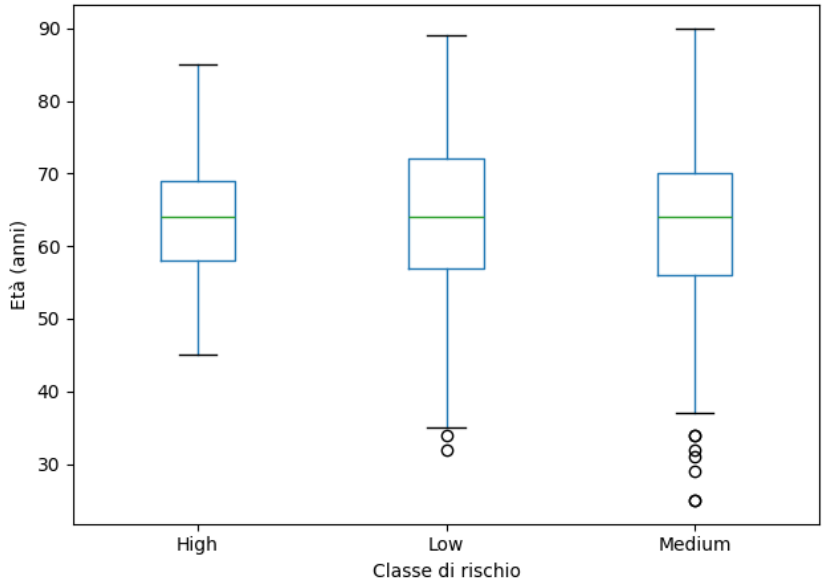


Figura 16: Distribuzione dell'età per classe di rischio oncologico.

Si osserva come l'età, pur rappresentando un fattore clinicamente rilevante, non appaia, se considerata singolarmente, sufficientemente discriminante per separare in modo netto le classi di rischio. Le distribuzioni associate alle classi *Low*, *Medium* e *High* mostrano infatti una marcata sovrapposizione, suggerendo che la stima del livello di rischio richieda la combinazione congiunta di più fattori osservabili piuttosto che l'analisi isolata di una singola variabile. Questo risultato evidenzia la necessità di ricorrere a modelli multivariati in grado di combinare più fattori di rischio per una stima efficace del livello oncologico.

Lo sbilanciamento osservato, e in particolare la minoritarietà della classe *High*, rende necessaria l'adozione di metriche di valutazione robuste rispetto alla distribuzione delle classi.

Dal punto di vista della modellazione, tale caratteristica introduce una criticità rilevante, poiché molti algoritmi di classificazione tendono a privilegiare la classe maggioritaria al fine di massimizzare l'accuratezza complessiva. In un contesto sanitario esplorativo, la mancata identificazione di un soggetto ad alto rischio risulta generalmente più critica della classificazione eccessivamente prudenziale di un soggetto appartenente a una classe meno severa.

Per questo motivo, l'accuratezza non è stata considerata una metrica sufficiente per la valutazione delle prestazioni dei modelli. L'analisi è stata invece orientata verso metriche robuste allo sbilanciamento delle classi, come la *Balanced Accuracy* e il *Macro F1-score*, nonché verso la valutazione della recall (sensibilità) per ciascuna classe, con particolare attenzione alla classe *High*.

Un'ulteriore osservazione riguarda la presenza nel dataset di variabili potenzialmente derivate o fortemente correlate con la variabile target, come il campo `Overall_Risk_Score`. Un'analoga attenzione è stata rivolta anche alla variabile `Cancer_Type`, la cui presenza può introdurre un'informazione clinica troppo vicina alla definizione del livello di rischio, alterando la valutazione della reale capacità predittiva dei fattori di rischio di base. La presenza di tali feature, se non adeguatamente gestita, può introdurre fenomeni di dipendenza informativa, portando a una sovrastima delle prestazioni dei modelli. Questa considerazione ha motivato la definizione di scenari sperimentali distinti, volti a confrontare un caso ottimistico con una valutazione più aderente a un contesto reale.

4.3 Definizione degli scenari sperimentali

Al fine di valutare l'impatto di alcune variabili potenzialmente ridondanti o derivate, sono stati definiti due scenari sperimentali distinti, coerentemente con l'impostazione adottata nel progetto di riferimento.

4.3.1 Scenario A – Scenario ottimistico

Nel primo scenario sono state incluse tutte le variabili disponibili, ad eccezione degli identificativi, compresa la variabile `Overall_Risk_Score`. Questo scenario rappresenta un caso ideale, in cui il modello dispone di una feature fortemente correlata con la variabile target, introducendo una semplificazione artificiale del problema di classificazione.

4.3.2 Scenario B – Scenario realistico

Nel secondo scenario, considerato quello di maggiore interesse applicativo, sono state escluse le variabili `Overall_Risk_Score` e `Cancer_Type`. La prima è stata rimossa in quanto rappresenta una sintesi del rischio complessivo fortemente correlata con la variabile target, mentre la seconda è stata esclusa poiché introduce un'informazione clinica troppo vicina alla definizione del livello di rischio. Lo Scenario B consente quindi di valutare la capacità predittiva dei modelli basandosi esclusivamente sui fattori di rischio osservabili, fornendo una stima più realistica delle prestazioni ottenibili in un contesto applicativo.

Tabella 3: Definizione degli scenari sperimentali.

Scenario	**Feature escluse**	**Finalità**
A	Identificativi	Valutare un caso ottimistico, includendo anche feature fortemente informative come `Overall_Risk_Score`.
B	Identificativi, `Overall_Risk_Score`, `Cancer_Type`	Valutare uno scenario più realistico, basato sui soli fattori di rischio osservabili.

4.4 Preprocessing dei dati

Prima della fase di addestramento dei modelli di classificazione, è stata condotta un'accurata fase di preprocessing dei dati, con l'obiettivo di rendere il dataset idoneo all'applicazione degli algoritmi selezionati e di prevenire potenziali distorsioni nei risultati sperimentali.

Il dataset presenta una struttura eterogenea, comprendendo sia variabili numeriche (ad esempio età, indicatori clinici e fattori quantitativi legati allo stile di vita) sia variabili categoriche (come abitudini, condizioni cliniche o altre caratteristiche qualitative). Per questo motivo, è stato adottato un approccio differenziato al preprocessing delle feature, in funzione della loro tipologia.

Le variabili categoriche sono state trasformate mediante la tecnica di *One-Hot Encoding*, che consente di rappresentare ciascuna categoria come una variabile binaria. Questa scelta permette di evitare l'introduzione di relazioni ordinali artificiali tra categorie e risulta particolarmente adatta all'utilizzo con modelli lineari e basati su alberi decisionali.

Le variabili numeriche sono state invece standardizzate tramite *StandardScaler*, che applica una trasformazione tale da ottenere distribuzioni con media nulla e varianza unitaria. Sebbene tale operazione non sia strettamente necessaria per modelli ensemble come Random Forest e Gradient Boosting, essa risulta fondamentale per modelli lineari come la regressione logistica, i quali sono sensibili alla scala delle feature. L'applicazione uniforme della standardizzazione consente inoltre di mantenere un flusso di preprocessing coerente tra i diversi modelli.

Per garantire una corretta separazione tra fase di addestramento e fase di valutazione, l'intero processo di preprocessing è stato integrato all'interno di una pipeline di apprendimento. In questo modo, le trasformazioni sono state apprese esclusivamente sul

training set e successivamente applicate al test set, evitando fenomeni di *data leakage* che avrebbero potuto compromettere la validità dei risultati sperimentali.

Dal punto di vista implementativo, il preprocessing è stato realizzato mediante un `ColumnTransformer`, applicando *StandardScaler* alle feature numeriche e *One-Hot Encoding* alle feature categoriche, con successiva integrazione dell'intero flusso all'interno di una *Pipeline* di apprendimento.

La suddivisione del dataset è stata effettuata tramite una procedura di *train-test split* stratificata, preservando la distribuzione originale della variabile target nelle due partizioni. In particolare, il dataset è stato suddiviso in training set e test set secondo una proporzione 80/20, utilizzando `random_state=42` e `stratify=y`, così da garantire riproducibilità sperimentale e preservare la distribuzione originaria delle classi. Questa scelta è risultata particolarmente importante in considerazione del forte sbilanciamento delle classi, garantendo una rappresentazione adeguata della classe *High* sia nel training set sia nel test set.

In presenza di una classe minoritaria, la dimensione del test set è stata verificata in modo da mantenere un numero sufficiente di campioni *High* per una valutazione significativa delle metriche per classe.

Infine, per affrontare lo sbilanciamento delle classi in fase di addestramento, sono state adottate strategie di pesatura differenziata. Nel caso della regressione logistica, sono stati assegnati pesi personalizzati pari a 1.0 per le classi *Low* e *Medium* e pari a 2.0 per la classe *High*, così da penalizzare maggiormente gli errori sui soggetti ad alto rischio. Per la Random Forest è stata invece utilizzata l'opzione `balanced_subsample`, che ricalibra automaticamente i pesi in base alla distribuzione delle classi nei campioni utilizzati per l'addestramento dei singoli alberi.

4.5 Modelli di classificazione

In accordo con l'impostazione metodologica adottata negli esempi di riferimento, sono stati selezionati un numero limitato di modelli di classificazione, privilegiando algoritmi consolidati e ampiamente utilizzati in letteratura, piuttosto che un confronto estensivo tra molte tecniche differenti. Questa scelta consente di concentrare l'analisi sull'interpretazione dei risultati e sul comportamento dei modelli in presenza di dati sbilanciati.

In questa fase si è scelto di confrontare modelli consolidati con configurazioni standard o moderatamente adattate, privilegiando la leggibilità del confronto e l'interpretazione dei risultati rispetto a una fase estesa di ottimizzazione degli iperparametri.

I modelli considerati differiscono per complessità, capacità di modellare relazioni non lineari e grado di interpretabilità, permettendo un confronto significativo in relazione al problema considerato.

4.5.1 Regressione Logistica Multiclasse

La regressione logistica multiclasse è stata adottata come modello di riferimento (*baseline*) per il problema di classificazione del rischio oncologico. Il modello stima una distribuzione di probabilità sulle classi; inoltre, ai fini della valutazione, è stata calcolata anche la $ROC–AUC$ in configurazione one-vs-rest.

Uno dei principali vantaggi della regressione logistica risiede nella sua semplicità e interpretabilità, caratteristiche particolarmente rilevanti nel contesto sanitario, dove la trasparenza del processo decisionale rappresenta un requisito fondamentale. Inoltre, il modello presenta una buona stabilità anche in presenza di un numero elevato di feature, soprattutto se opportunamente preprocessate.

Per mitigare l'effetto dello sbilanciamento delle classi, sono stati introdotti pesi di classe personalizzati, assegnando un peso maggiore alla classe *High*. Tale scelta consente di penalizzare maggiormente gli errori di classificazione relativi ai soggetti ad alto rischio, aumentando la sensibilità del modello verso la classe di maggiore interesse applicativo.

4.5.2 Random Forest

Il modello Random Forest è stato selezionato per la sua capacità di modellare relazioni non lineari e di catturare interazioni complesse tra le variabili. La Random Forest è un algoritmo ensemble basato su un insieme di alberi decisionali addestrati su sottoinsiemi casuali dei dati e delle feature, il cui output finale è ottenuto tramite un meccanismo di voto.

Questo approccio consente generalmente di ridurre il rischio di overfitting rispetto a un singolo albero decisionale e di ottenere buone prestazioni su dataset eterogenei. Nel contesto del problema considerato, la Random Forest è stata utilizzata anche per valutare la capacità dei modelli ensemble di gestire lo sbilanciamento delle classi.

Anche in questo caso è stata adottata una strategia di pesatura delle classi, attraverso l'opzione `balanced_subsample`, che ricalibra i pesi in base alla distribuzione delle classi nei campioni utilizzati per l'addestramento dei singoli alberi.

4.5.3 Gradient Boosting

Il modello Gradient Boosting rappresenta un ulteriore approccio ensemble, caratterizzato da una strategia di apprendimento sequenziale. A differenza della Random Forest, in cui gli alberi vengono addestrati in modo indipendente, il Gradient Boosting costruisce ciascun nuovo modello cercando di correggere gli errori commessi dai modelli precedenti.

Questa caratteristica consente al Gradient Boosting di raggiungere elevate prestazioni in molti contesti applicativi, specialmente in presenza di relazioni non lineari complesse.

Tuttavia, il modello risulta generalmente più sensibile allo sbilanciamento delle classi e alla scelta degli iperparametri, rendendo necessaria una valutazione attenta delle sue prestazioni nel contesto considerato.

Nel presente lavoro, il Gradient Boosting è stato incluso al fine di confrontare il comportamento di due diverse strategie ensemble e di analizzare la loro capacità di individuare correttamente i soggetti appartenenti alla classe *High*.

Tabella 4: Configurazione dei modelli utilizzati negli esperimenti.

Modello	**Configurazione principale**
Regressione Logistica	`solver=lbfgs`, `max_iter=2000`, pesi di classe personalizzati (*High*=2.0).
Random Forest	`n_estimators=300`, `random_state=42`, `class_weight=balanced_subsample`.
Gradient Boosting	`random_state=42`, configurazione standard del classificatore.

4.6 Metriche di valutazione

La valutazione delle prestazioni dei modelli di classificazione è stata condotta utilizzando un insieme di metriche selezionate in modo coerente con la natura del problema e con il contesto applicativo sanitario. In presenza di una distribuzione fortemente sbilanciata delle classi, infatti, l'utilizzo di una singola metrica aggregata risulta insufficiente a descrivere in modo accurato il comportamento dei modelli.

In particolare, l'accuratezza complessiva non è stata considerata una misura affidabile, in quanto tende a essere dominata dalla classe maggioritaria (*Medium*), fornendo una rappresentazione distorta delle prestazioni effettive sui casi di maggiore interesse. Un modello potrebbe infatti ottenere un'elevata accuratezza classificando correttamente la maggior parte dei campioni della classe dominante, pur fallendo sistematicamente l'identificazione dei soggetti ad alto rischio.

Per questo motivo, la metrica principale utilizzata è stata la *Balanced Accuracy*, definita come la media delle recall calcolate separatamente per ciascuna classe. Questa metrica consente di valutare in modo più equo le prestazioni dei modelli in presenza di classi sbilanciate, assegnando la stessa importanza a ciascun livello di rischio.

Accanto alla *Balanced Accuracy*, è stato utilizzato il *Macro F1-score*, che rappresenta la media aritmetica degli F1-score calcolati per ogni classe. Questa metrica risulta particolarmente utile per sintetizzare il compromesso tra precision e recall in un singolo valore, penalizzando i modelli che mostrano prestazioni fortemente disomogenee tra le classi.

Un'attenzione specifica è stata inoltre riservata alla *recall per classe*, con particolare riferimento alla classe *High*. In ambito sanitario, la recall della classe ad alto rischio assume un ruolo centrale, poiché una bassa sensibilità su questa classe implica la mancata identificazione di soggetti potenzialmente critici, con conseguenze rilevanti dal punto di vista applicativo. Di conseguenza, i modelli sono stati valutati privilegiando la riduzione dei falsi negativi sulla classe *High*, anche a costo di un lieve aumento degli errori sulle classi meno critiche.

A supporto dell'analisi quantitativa, sono state utilizzate le matrici di confusione, che forniscono una rappresentazione dettagliata delle predizioni corrette e degli errori commessi da ciascun modello. L'analisi visiva delle matrici di confusione consente di individuare rapidamente eventuali pattern di misclassificazione, come la tendenza a confondere classi adiacenti o a privilegiare la classe maggioritaria.

Si osserva inoltre che, per modelli probabilistici come la regressione logistica, la soglia decisionale può influire sul compromesso tra precision e recall, in particolare per la classe *High*.

Infine, ove possibile, è stata calcolata la metrica *ROC–AUC* in modalità *one-vs-rest*, al fine di valutare la capacità discriminativa complessiva dei modelli rispetto a ciascuna classe. Sebbene la *ROC–AUC* fornisca un'indicazione utile sulla separabilità delle classi, essa è stata interpretata con cautela, in quanto può risultare ottimistica in presenza di classi fortemente sbilanciate; in tali casi, metriche basate su curve Precision–Recall possono risultare più informative. Per questo motivo, tale metrica è stata considerata complementare alle precedenti e non utilizzata come criterio principale di selezione del modello finale.

Questo aspetto risulta particolarmente evidente nello Scenario B, in cui alcuni modelli mostrano valori elevati di *ROC–AUC* pur mantenendo una sensibilità limitata sulla classe *High*.

Sulla base delle scelte metodologiche descritte, è stata condotta una serie di esperimenti volti a confrontare le prestazioni dei modelli nei due scenari definiti.

4.7 Risultati sperimentali

4.7.1 Scenario A

Nello Scenario A, tutti i modelli hanno ottenuto prestazioni estremamente elevate, con valori di *Balanced Accuracy*, *Macro F1-score* e *ROC–AUC* prossimi a 1.

Tabella 5: Confronto delle prestazioni dei modelli nello Scenario A (include `Overall_Risk_Score`).

Modello	**Balanced Acc.**	**Macro F1**	**ROC–AUC (OvR)**
LogReg (weighted High)	0.967	0.973	1.000
Random Forest	1.000	1.000	1.000
Gradient Boosting	0.999	0.997	0.999

Tali risultati sono attribuibili alla presenza della variabile `Overall_Risk_Score`, che introduce una forte correlazione con la variabile target. Questo scenario è stato quindi interpretato come un limite superiore teorico delle prestazioni ottenibili, utile a fini comparativi ma non rappresentativo di una valutazione realistica del problema.

Di conseguenza, i risultati dello Scenario A non sono stati utilizzati per la selezione del modello finale, ma esclusivamente come termine di confronto.

Regressione Logistica Multiclasse Nello Scenario A, la regressione logistica multiclasse con pesi di classe personalizzati raggiunge prestazioni prossime al limite teorico, come evidenziato dai valori elevati di *Balanced Accuracy* e *Macro F1-score* riportati in Tabella 5. Il modello risulta in grado di separare in modo quasi perfetto le tre classi di rischio, mostrando un comportamento estremamente stabile sul test set.

Tali prestazioni sono principalmente attribuibili alla presenza della variabile `Overall_Risk_Score`, fortemente correlata con la variabile target, che introduce una semplificazione sostanziale del problema di classificazione. In questo contesto, il modello non è chiamato a inferire il livello di rischio esclusivamente a partire dai fattori osservabili, ma beneficia di una feature che incorpora già una sintesi del rischio complessivo.

La matrice di confusione in Figura 17 conferma la quasi totale assenza di errori di classificazione, con un numero trascurabile di campioni assegnati a una classe errata.

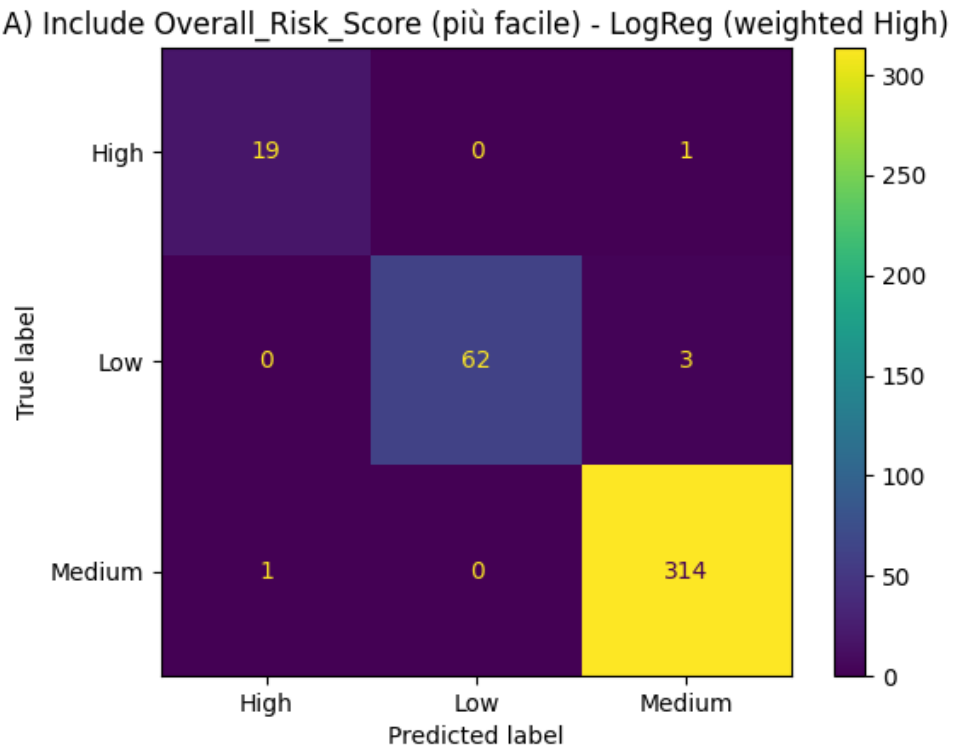


Figura 17: Matrice di confusione – Scenario A (Regressione Logistica con pesi di classe personalizzati)

Per completezza, si riportano le matrici di confusione anche per i modelli ensemble, al fine di evidenziare come l'elevata performance sia comune a tutti gli approcci quando è presente una feature altamente correlata con il target.

Random Forest Coerentemente con quanto osservato nello Scenario A, anche la Random Forest raggiunge prestazioni prossime al limite teorico, confermando che la presenza di `Overall_Risk_Score` rende la separazione tra le classi estremamente agevole per il modello.

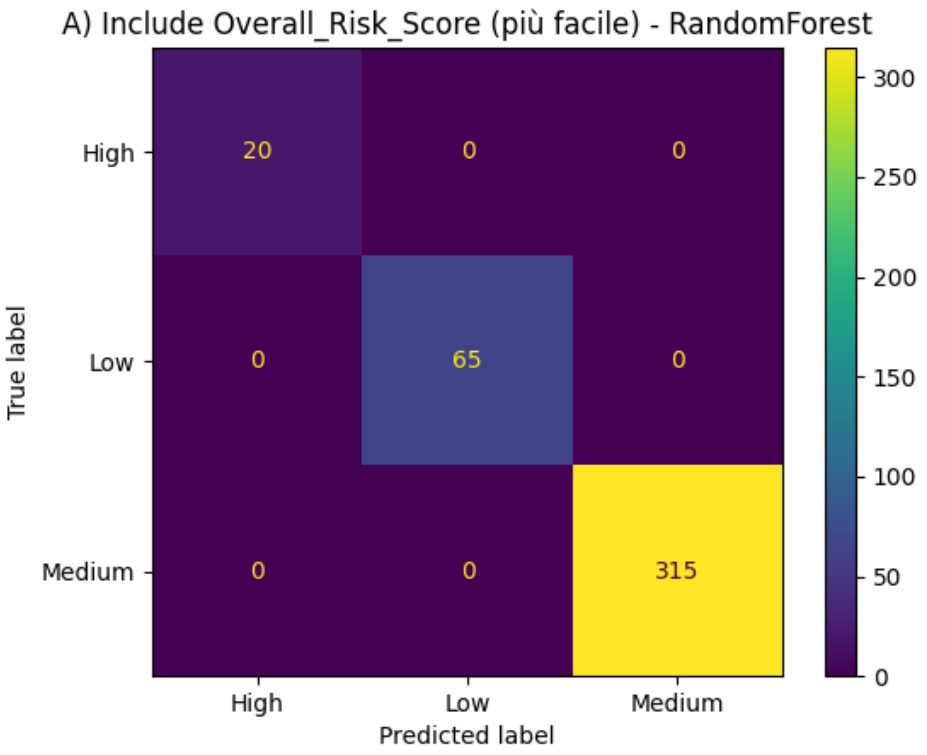


Figura 18: Matrice di confusione – Scenario A (Random Forest)

Gradient Boosting Il Gradient Boosting evidenzia un comportamento analogo, con un numero di errori residui trascurabile. Anche in questo caso, la qualità delle predizioni è principalmente attribuibile alla forte informatività di `Overall_Risk_Score`, che semplifica il task di classificazione.

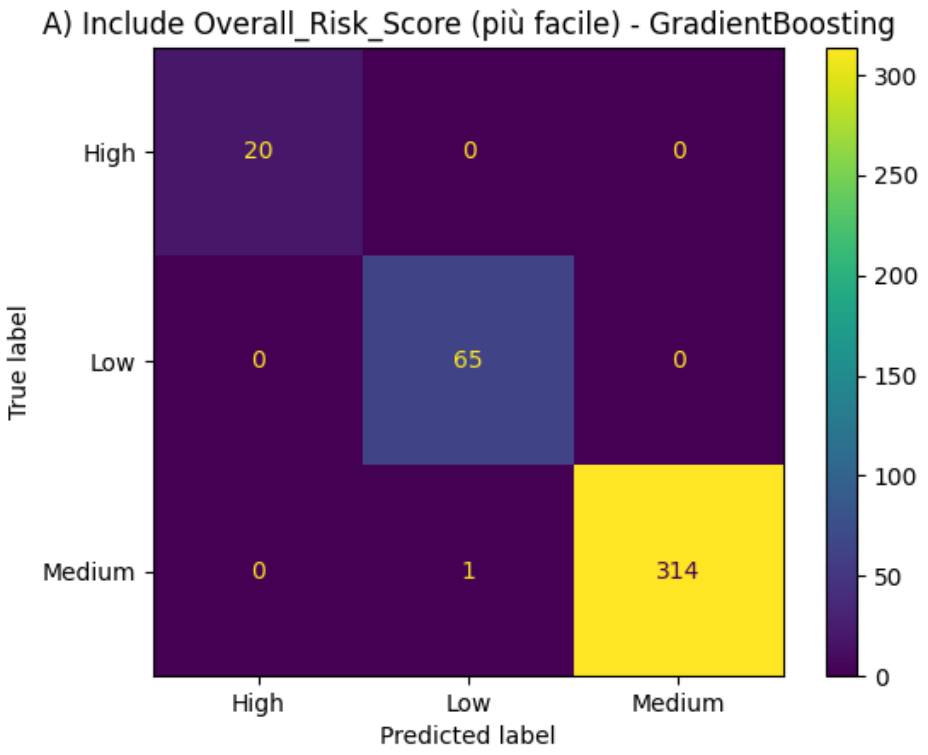


Figura 19: Matrice di confusione – Scenario A (Gradient Boosting)

4.7.2 Scenario B

Lo Scenario B rappresenta il caso di maggiore interesse applicativo, in quanto esclude variabili potenzialmente derivate o fortemente informative come `Overall_Risk_Score` e `Cancer_Type`, obbligando i modelli a basare la predizione esclusivamente sui fattori di rischio osservabili.

In questo contesto, il problema di classificazione risulta sensibilmente più complesso rispetto allo Scenario A, come evidenziato dal generale calo delle prestazioni registrato da tutti i modelli analizzati.

Tabella 6: Confronto delle prestazioni dei modelli nello Scenario B (esclude `Overall_Risk_Score` e `Cancer_Type`).

Modello	**Balanced Acc.**	**Macro F1**	**ROC–AUC (OvR)**
LogReg (weighted High)	0.692	0.711	0.953
Random Forest	0.435	0.457	0.917
Gradient Boosting	0.537	0.576	0.912

I risultati in Tabella 6 evidenziano un calo significativo delle prestazioni rispetto allo Scenario A e differenze marcate tra i modelli.

Regressione Logistica Multiclasse La regressione logistica multiclasse con pesi di classe personalizzati ha ottenuto le migliori prestazioni complessive nello Scenario B, mostrando un buon compromesso tra accuratezza globale e capacità di riconoscimento delle classi minoritarie.

In particolare, il modello ha raggiunto una *Balanced Accuracy* pari a 0.692 e un *Macro F1-score* di 0.711, valori significativamente inferiori rispetto allo Scenario A, ma coerenti con la maggiore difficoltà del problema. La classe *Medium* risulta essere quella meglio predetta, mentre le prestazioni sulla classe *High* rimangono più contenute, con una recall pari a 0.350.

È inoltre interessante osservare come il modello presenti una $ROC\text{–}AUC$ pari a 0.953, valore che indica una buona capacità discriminativa complessiva, ma che non si traduce automaticamente in un'elevata sensibilità operativa sulla classe *High* alla soglia decisionale adottata. Questo conferma la necessità di interpretare con cautela le metriche aggregate in presenza di classi fortemente sbilanciate.

Nonostante ciò, la regressione logistica risulta l'unico modello in grado di mantenere una sensibilità non trascurabile verso i soggetti ad alto rischio, riducendo il numero di falsi negativi rispetto ai modelli ensemble.

Di conseguenza, la scelta privilegia la capacità di individuare almeno una parte dei casi *High* rispetto a modelli che, pur con buone prestazioni globali, presentano recall nulla sulla classe critica.

Tabella 7: Prestazioni sulla classe *High* nello Scenario B sul test set (focus sulla sensibilità verso la classe minoritaria).

Modello	**Precision (High)**	**Recall (High)**	**F1 (High)**
LogReg (weighted High)	0.438	0.350	0.389
Random Forest	0.000	0.000	0.000
Gradient Boosting	0.375	0.150	0.214

Tabella 8: Prestazioni della regressione logistica nello Scenario B per ciascuna classe.

Classe	**Precision**	**Recall**	**F1-score**
High	0.438	0.350	0.389
Low	0.850	0.785	0.816
Medium	0.917	0.943	0.930

In particolare, Tabella 7 mostra che la regressione logistica mantiene una recall non nulla sulla classe *High*, a differenza dei modelli ensemble.

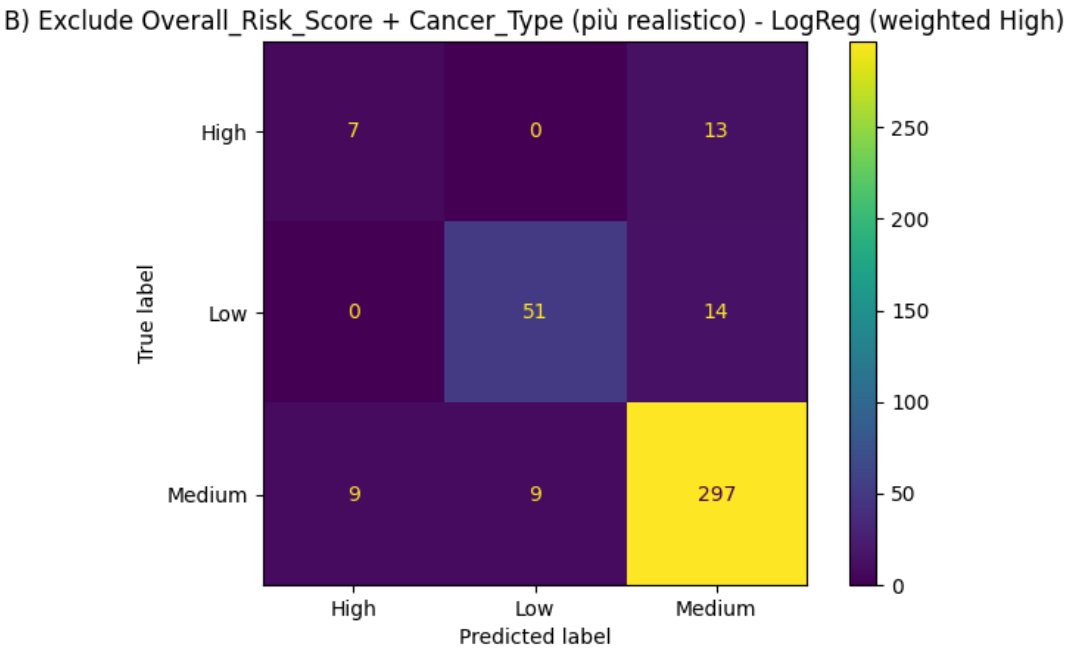


Figura 20: Matrice di confusione – Scenario B (Regressione Logistica con pesi di classe personalizzati)

La matrice di confusione in Figura 20 evidenzia come, pur in presenza di alcune confusioni tra le classi *Low* e *Medium*, il modello riesca comunque a individuare una parte dei soggetti ad alto rischio, aspetto cruciale nel contesto sanitario considerato.

Random Forest Il modello Random Forest mostra prestazioni significativamente inferiori nello Scenario B. Le metriche aggregate, se considerate isolatamente, possono risultare fuorvianti in presenza di sbilanciamento delle classi. La *Balanced Accuracy* si attesta infatti a 0.435, mentre il *Macro F1-score* scende a 0.457, evidenziando un forte squilibrio nelle prestazioni tra le classi.

L'analisi dettagliata del report di classificazione (precision, recall e F1-score per classe) rivela come il modello tenda a classificare la quasi totalità dei campioni nella classe *Medium*, ottenendo una recall nulla sulla classe *High*.

Nel presente esperimento, il modello mostra una marcata tendenza a privilegiare la classe maggioritaria, minimizzando l'errore globale a scapito della capacità di riconoscimento della classe minoritaria.

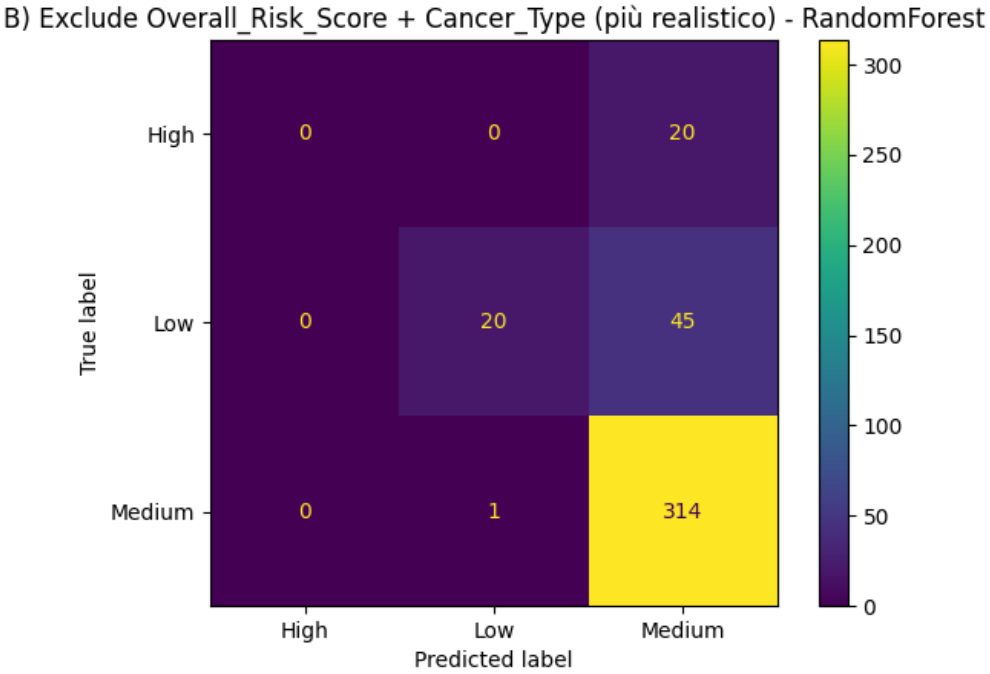


Figura 21: Matrice di confusione – Scenario B (Random Forest)

Come mostrato in Figura 21, il modello Random Forest fallisce completamente l'identificazione dei soggetti ad alto rischio, rendendo le sue predizioni poco affidabili in un contesto applicativo reale.

Gradient Boosting Il modello Gradient Boosting presenta prestazioni intermedie tra la regressione logistica e la Random Forest, con una *Balanced Accuracy* pari a 0.537 e un *Macro F1-score* di 0.576. Anche in questo caso, la classe *Medium* risulta essere quella meglio predetta, mentre la capacità di riconoscimento della classe *High* rimane limitata, con una recall pari a 0.150.

Nonostante un leggero miglioramento rispetto alla Random Forest, il modello non raggiunge livelli di sensibilità sufficienti sulla classe di maggiore interesse, confermando, nel presente contesto sperimentale, la difficoltà di questo approccio nel gestire efficacemente una classe fortemente minoritaria senza meccanismi di compensazione più incisivi.

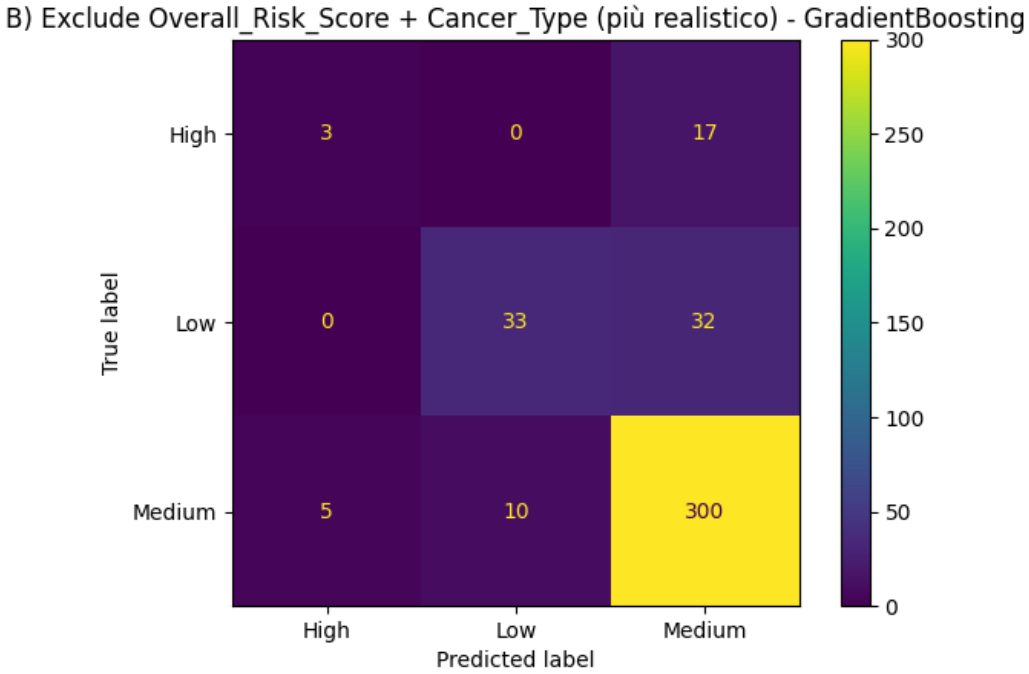


Figura 22: Matrice di confusione – Scenario B (Gradient Boosting)

Confronto complessivo Il confronto tra i modelli nello Scenario B evidenzia come la regressione logistica multiclasse con pesi di classe personalizzati rappresenti la soluzione più equilibrata per il problema considerato. Sebbene altri indicatori aggregati, come l'accuratezza complessiva, risultino ancora relativamente elevati anche per modelli meno efficaci sulla classe *High*, il criterio di selezione è stato guidato dalla capacità del modello di mantenere una sensibilità non nulla verso i soggetti a maggiore rischio. Pur non raggiungendo le prestazioni ideali osservate nello Scenario A, tale modello garantisce una migliore capacità di identificazione dei soggetti ad alto rischio, mantenendo al contempo un buon livello di interpretabilità.

Alla luce di questi risultati, la regressione logistica è stata selezionata come modello finale per lo Scenario B, in quanto maggiormente aderente alle esigenze di un contesto sanitario reale, dove la priorità è l'identificazione tempestiva dei soggetti appartenenti alla classe *High*.

4.8 Discussione e conclusioni

Il lavoro svolto in questo capitolo ha affrontato il problema della classificazione del livello di rischio oncologico attraverso un approccio di apprendimento supervisionato multiclasse, basato su fattori di rischio demografici, comportamentali e clinici. L'analisi è stata

strutturata in modo da valutare non solo le prestazioni predittive dei modelli, ma anche la loro affidabilità e adeguatezza in un contesto applicativo reale.

Il confronto tra i due scenari sperimentali ha evidenziato in maniera chiara l'impatto della selezione delle feature sulle prestazioni dei modelli. Nello Scenario A, caratterizzato dalla presenza di variabili fortemente informative come `Overall_Risk_Score`, tutti i modelli hanno ottenuto risultati estremamente elevati. Tali prestazioni, pur indicative della capacità dei modelli di apprendere relazioni presenti nei dati, non risultano rappresentative di un contesto realistico, in quanto influenzate da una forte dipendenza informativa tra alcune feature e la variabile target.

Lo Scenario B ha invece fornito una valutazione più aderente a una situazione reale, in cui il livello di rischio oncologico deve essere stimato a partire da fattori di rischio osservabili. In questo scenario, il problema di classificazione si è rivelato sensibilmente più complesso, come dimostrato dal calo generalizzato delle metriche di prestazione e dalla difficoltà dei modelli nel riconoscere correttamente la classe *High*, fortemente minoritaria.

L'analisi comparativa dei modelli ha mostrato come approcci ensemble quali Random Forest e Gradient Boosting tendano a privilegiare la classe maggioritaria, ottenendo buone prestazioni globali ma fallendo nell'identificazione dei soggetti ad alto rischio. Questo comportamento, osservato nel presente contesto sperimentale, risulta poco compatibile con un contesto sanitario, in cui la riduzione dei falsi negativi sulla classe critica rappresenta una priorità.

Al contrario, la regressione logistica multiclasse con pesi di classe personalizzati si è dimostrata il modello più equilibrato nello Scenario B. Pur non raggiungendo le prestazioni ideali osservate nello Scenario A, tale approccio è riuscito a mantenere una sensibilità non trascurabile verso la classe *High*, garantendo al contempo una buona stabilità complessiva e un elevato livello di interpretabilità. Quest'ultimo aspetto rappresenta un elemento di particolare rilevanza in ambito sanitario, dove la comprensione delle decisioni del modello è spesso un requisito fondamentale.

Nel complesso, i risultati ottenuti confermano l'importanza di una valutazione attenta delle metriche di prestazione e della distribuzione delle classi, nonché la necessità di privilegiare modelli che offrano un compromesso adeguato tra accuratezza, sensibilità e trasparenza. In questo contesto, la regressione logistica è stata selezionata come modello finale per il problema di classificazione del rischio oncologico.

Infine, è opportuno sottolineare alcuni limiti del lavoro svolto. Il dataset utilizzato presenta una forte asimmetria nella distribuzione delle classi e non include informazioni temporali o longitudinali, che potrebbero fornire un contributo significativo alla stima del rischio. Inoltre, il confronto tra i modelli è stato condotto adottando configurazioni standard o moderatamente adattate, senza una fase estesa di ottimizzazione degli iper-

parametri; di conseguenza, i risultati ottenuti devono essere letti come una valutazione metodologicamente controllata ma non necessariamente come la massima performance raggiungibile dai modelli considerati. Sviluppi futuri potrebbero includere l'applicazione di tecniche di *resampling* sul training set, l'ottimizzazione sistematica degli iperparametri, lo studio di soglie decisionali alternative per aumentare la sensibilità verso la classe *High*, nonché l'introduzione di nuove feature derivate o di tecniche di interpretabilità più avanzate.

Nel complesso, il capitolo mostra come l'adozione di un approccio metodologicamente rigoroso sia fondamentale per l'applicazione di tecniche di machine learning in ambito sanitario.

5 Cancer Risk Factors: Clustering

In questo capitolo si mostrano le analisi effettuate sul dataset attraverso le tecniche di clustering, al fine di partizionare i dati in diversi gruppi, appunto cluster, con caratteristiche simili.

Tale capitolo inizialmente presenterà le operazioni eseguite sul dataset, mirate a prepararlo all'analisi; successivamente saranno mostrati i risultati ottenuti a seguito dell'applicazione degli algoritmi K-Means, DBSCAN e HDBSCAN.

5.1 Preprocessing del dataset

Prima di applicare gli algoritmi di clustering, è stata eseguita un'operazione di preparazione dei dati.
Inizialmente sono state escluse le seguenti colonne: *Patient_ID*, *Cancer_Type* e *Risk_Level*, poiché non utili durante la fase di clustering. Dunque, le feature presenti nel dataset si riducono a 18:

1. Age;
2. Gender;
3. Smoking;
4. Alcohol_Use;
5. Obesity;
6. Family_History;
7. Diet_Red_Meat;
8. Diet_Salted_Processed;
9. Fruit_Veg_Intake;
10. Physical_Activity;
11. Air_Pollution;
12. Occupational_Hazards;
13. BRCA_Mutation;
14. H_Pylori_Infection;

15. Calcium_Intake;
16. Overall_Risk_Score;
17. BMI;
18. Physical_Activity_Level.

Poiché presentano scale di misura diverse, ogni feature è stata normalizzata attraverso lo **StandardScaler**. Con questa trasformazione, ogni variabile presenta una media μ pari a 0 e una varianza σ^2 pari a 1 attraverso la seguente formula:

$$Z = \frac{x - \mu}{\sigma}$$

Sebbene le operazioni precedentemente eseguite abbiano ridotto la dimensionalità del dataset, esse non risultano sufficienti, poiché non permettono una visualizzazione chiara dei risultati, e contribuiscono al fenomeno di *Curse of dimensionality*, per cui l'efficienza e l'efficacia degli algoritmi si deteriora esponenzialmente al crescere della dimensionalità. Per ovviare a tale problema, si ricorre a delle tecniche di riduzione: la *Principal Component Analysis* (PCA) e *t-Distributed Stochastic Neighbor Embedding* (t-SNE).
Il primo tentativo è stato effettuato attraverso la PCA, che selezionara esclusivamente le variabili o componenti più rilevanti, rendendo la visualizzazione dei dati più semplice ed intuitiva.
Durante questa fase, è stata analizzata la varianza cumulativa spiegata dalle componenti principali, ovvero la quantità di varianza spiegata dalle prime K componenti principali selezionate.

Come si può notare dal seguente grafico, per raccogliere il 70% di varianza cumulativa occorrono 10 componenti; mentre per raggiungere il 90% della varianza ne occorrono 14. Si evince, dunque, che l'informazione presente nel dataset è distribuita su un numero elevato di dimensioni, e che una riduzione bidimensionale comporterebbe una perdita significativa di informazione (la varianza cumulativa spiegata sarebbe a circa il 20%). Ne consegue che l'utilizzo della PCA non risulterebbe una scelta adeguata per una corretta interpretazione dei cluster.

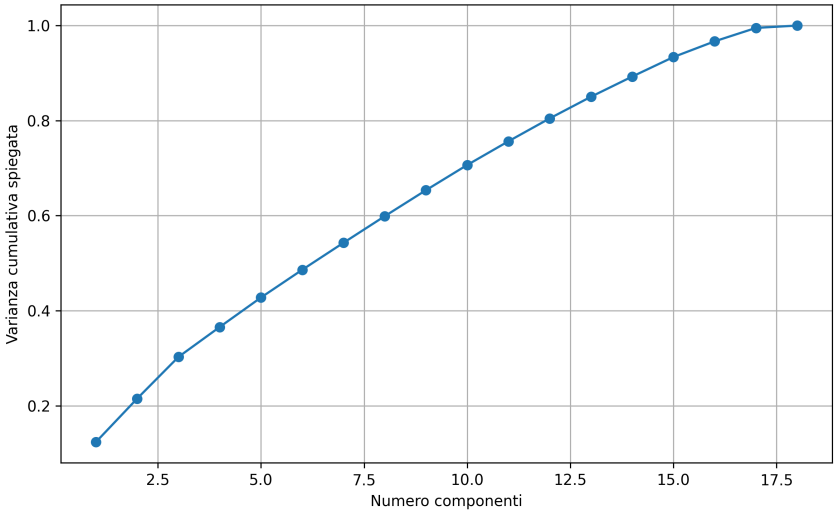


Figura 23: Varianza cumulativa spiegata

Poiché oltre alla riduzione della dimensionalità, risulta fondamentale anche la visualizzazione dei risultati, si è optato per l'utilizzo della tecnica t-SNE.
Tale algoritmo permette una riduzione della dimensionalità, per visualizzare i dati in due o tre dimensioni. Una sua peculiarità è quella di preservare la struttura locale, affinché gli oggetti che erano vicini nello spazio originale lo siano anche in quello ridotto, e oggetti lontani risultino lontani.
Nel progetto la t-SNE è stata applicata allo spazio delle feature standardizzate con i seguenti parametri:

- **n_components** = 2, per consentire una visualizzazione bidimensionale;
- **random_state** = 42, per rendere i risultati riproducibili. Questo parametro controlla il generatore di numeri casuali usato per l'inizializzazione;
- **perplexity** = 30, per bilanciare l'attenzione ai vicini locali e globali.

La figura successiva mostra la visualizzazione ottenuta dopo l'applicazione dell'algoritmo t-SNE sul dataset. Si noti come le dimensioni siano state ridotte da 18 a 2. È possibile osservare una distribuzione dei punti che evidenzia la presenza di regioni dense e strutture locali ben definite, suggerendo l'esistenza di gruppi potenzialmente distinti.

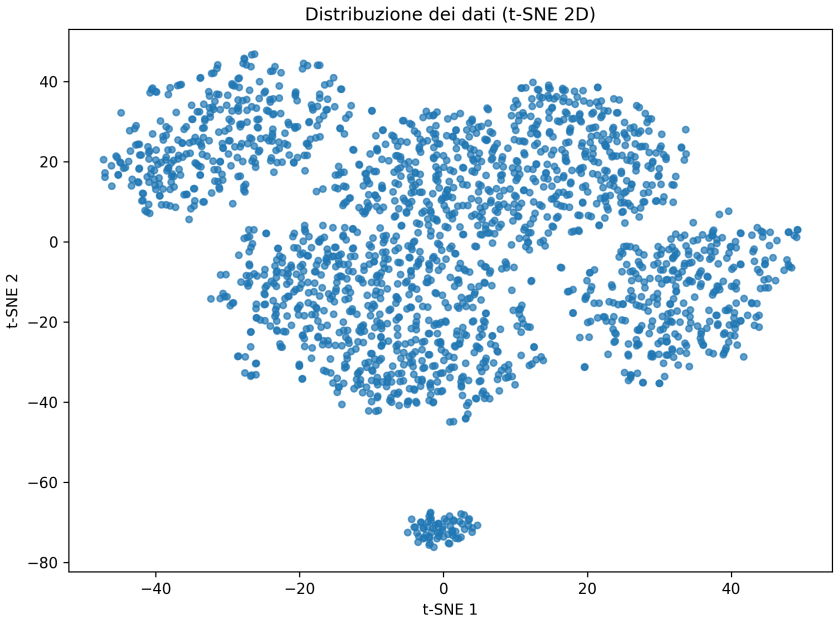


Figura 24: Visualizzazione della struttura dei dati tramite t-SNE

5.2 K-Means

Il primo algoritmo di clustering applicato al dataset è il *K-Means*. Si tratta di una tecnica di apprendimento non supervisionato e di clustering partizionale, poiché, ad ogni passo, lavora su una porzione di dati diversa. La peculiarità di questo algoritmo è la necessità di esplicitare il numero di cluster da creare. L'obiettivo della tecnica è quella di minimizzare la distanza intra-cluster, ovvero la distanza tra un punto e il centroide del cluster a cui appartiene, e massimazzare quella inter-cluster, ovvero tra i centroidi dei diversi cluster.

La prima operazione eseguita è stata la scelta del parametro K, per indicare il numero di cluster su cui lavorare. Tale fase risulta cruciale, poiché la scelta di un valore troppo basso o alto può portare a underfitting o overfitting.
Il metodo più utilizzato per la selezione del parametro K è l'**Elbow method**. Esso si basa sulla metrica inertia che misura quanto i punti sono vicini al centroide del proprio cluster; più tale valore è basso e meglio è. Tuttavia, il valore della metrica tende a diminuire all'aumentare del numero di cluster considerati, ragion per cui la scelta ricade nel valore di K tale per cui i miglioramenti diventano meno netti.
Il grafico è mostrato nella seguente figura.

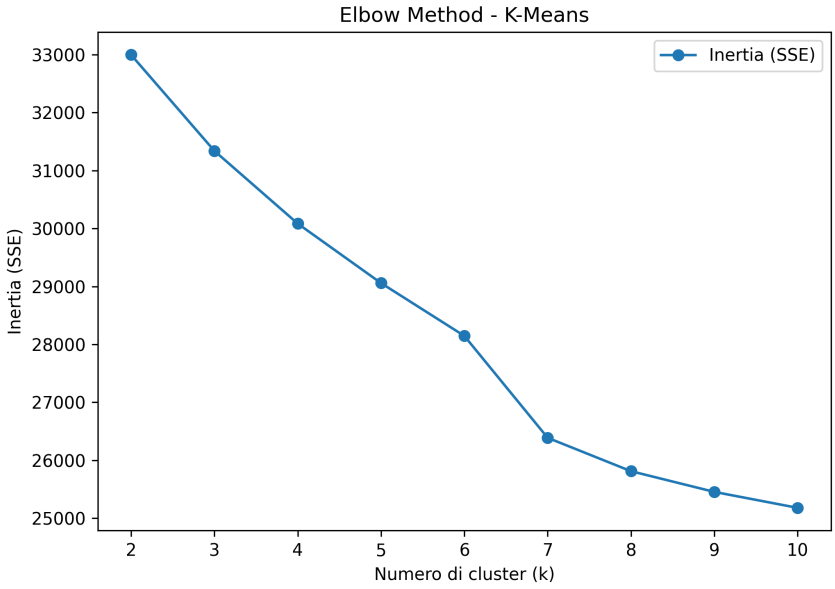


Figura 25: Grafico dell'Elbow Method

Dal grafico risulta evidente la scelta del parametro K pari a 7, poiché è il punto dopo il quale il valore dell'inertia migliora meno drasticamente.

Esaminiamo, adesso, i cluster ottenuti:

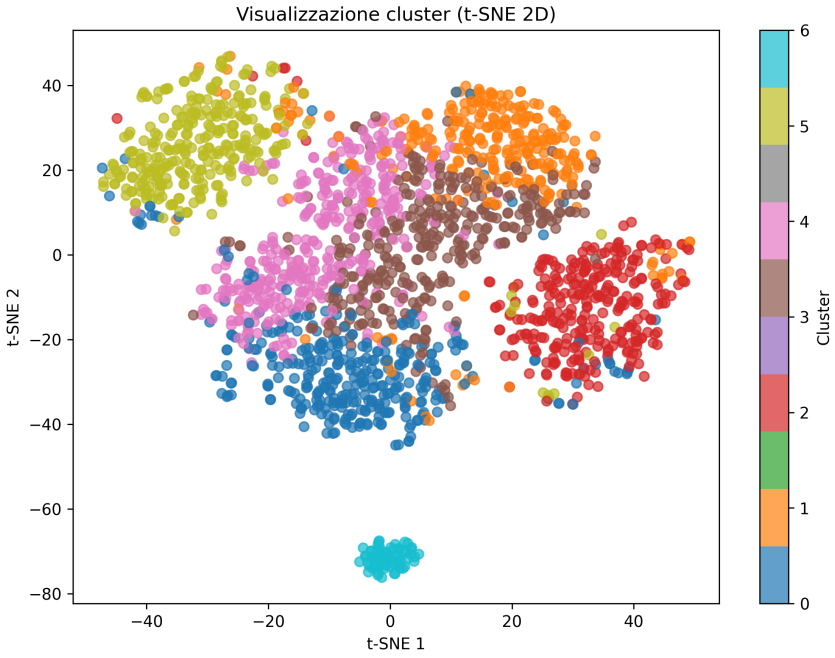


Figura 26: Cluster ottenuti

Come possiamo notare, la rappresentazione bidimensionale ottenuta tramite t-SNE mostra i dati suddivisi in 7 cluster:

- **0**, contenente 348 pazienti;

- **1**, contenente 293 pazienti;
- **2**, contenente 290 pazienti;
- **3**, contenente 341 pazienti;
- **4**, contenente 370 pazienti;
- **5**, contenente 293 pazienti;
- **6**, contenente 65 pazienti.

Poniamo, ora, l'attenzione sulla distribuzione dei cluster. Essi tendono a concentrarsi in regioni locali relativamente compatte, mentre altri gruppi, come il 6, risultano più isolati. La sovrapposizione dei cluster non sorprende, data la natura medica del dataset. Di fatti, ogni feature rappresenta fattori di rischio, fisici o genetici, che possono essere condivisi dallo stesso paziente.

Proseguiamo, osservando in che modo sono distribuite le feature tra i vari cluster:

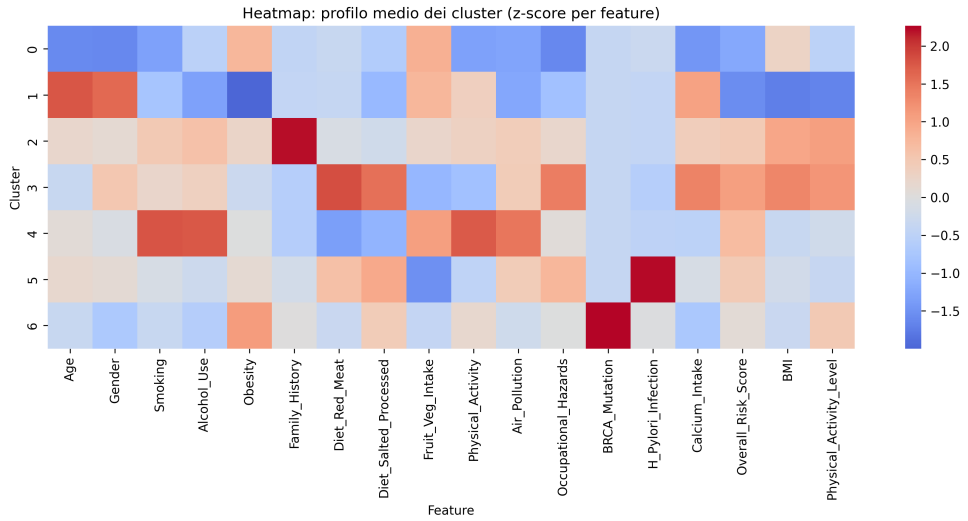


Figura 27: Heatmap con i profili medi dei cluster

Come possiamo notare dalla heatmap, i cluster individuati non sono caratterizzati da una singola variabile dominante, ma da combinazioni specifiche di fattori di rischio. Alcuni presentano dei valori sopra la media per feature come Smoking e Alcohol_Use; e altri valori più elevati per Physical_Activity e Fruit_Veg_Intake. Concentriamoci su alcuni di essi: il cluster 0 mostra un profilo di basso rischio, dovuto a un'età più bassa e feature "Smoking" bassa; il cluster 4 presenta rischio elevato, causato da grande quantità di fumatori e consumatori di bevande alcoliche; il cluster 6, infine, rappresenta un piccolo sottogruppo specifico con valori alti di obesità, livello di attività fisica e mutazione del

gene BRCA.
L'assenza di contrasti netti tra i profili, inoltre, conferma la natura multifattoriale del dataset e dimostra coerenza con la parziale sovrapposizione osservata nelle precedenti visualizzazioni.

Nei succesivi grafici, invece, poniamo la nostra attenzione sui livelli di rischio individuati per ogni cluster.
Il primo di essi è il boxplot dell'Overall_Risk_Score.

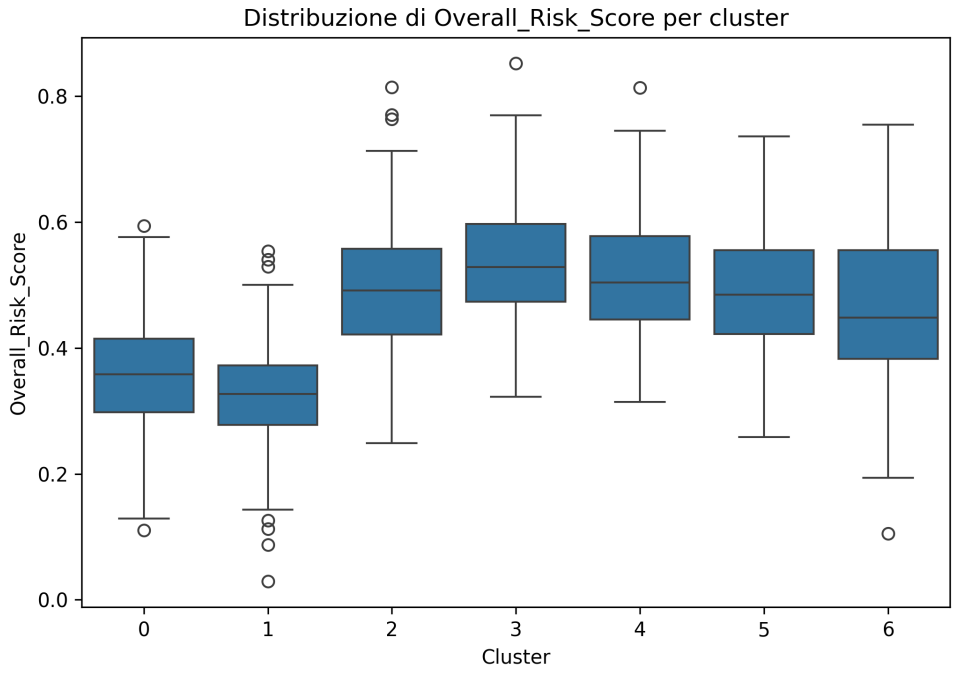


Figura 28: Boxplot dell'Overall_Risk_Score

Come possiamo osservare dalla figura appena presentata, emerge una chiara stratificazione dei cluster in termini di livello di rischio. Confrontando i risultati ottenuti con quelli presenti nella heatmap, non sorprende trovare i cluster 0 e 1 tra quelli con il rischio più basso; mentre cluster come il 3 e il 4 presentino livelli di rischio più alto. Infine, poniamo l'attenzione sul cluster 6, poiché si tratta di quello più eterogeneo. Quest'ultimo, infatti, presenta un range più ampio, includendo soggetti a basso ed alto rischio.

Mostriamo, infine, il livello di rischio per cluster. Come detto precedentemente, i livelli si dividono in tre categorie: Low, Medium e High. È bene precisare, però, che l'analisi è puramente interpretativa, poiché la feature *Risk_Level* non è stata utilizzata in fase di clustering.

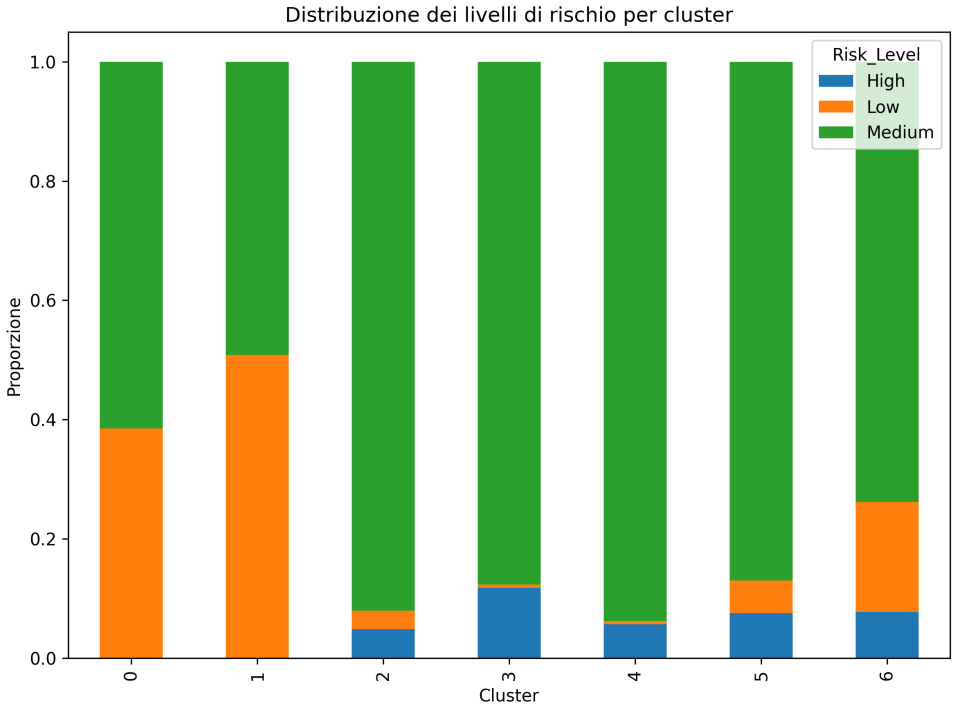


Figura 29: Barplot dei livelli di rischio per ciascun cluster

Possiamo immediatamente notare come tutti i cluster siano dominati dalla categoria Medium, con variazioni nella presenza relativa dei livelli Low e High. In particolare:

Cluster	High	Medium	Low
0	0	214	134
1	0	144	149
2	14	267	9
3	40	299	2
4	21	347	2
5	22	255	16
6	5	48	12

Osserviamo, dunque, che i risultati ottenuti in precedenza sono confermati, dimostrando come i primi due cluster siano quelli con un livello di rischio inferiore, il cluster 3 sia quello con il rischio più elevato e il cluster 6 quello più eterogeneo.

Mostriamo, infine, il grafico della Silhouette. Esso misura, per ogni osservazione, il grado di similarità con i punti appartenenti al proprio cluster rispetto a quelli appartenenti agli altri cluster. Tale valore oscilla tra -1 e 1. Valori positivi indicano una corretta assgnazione al cluster; valori prossimi allo zero indicano che il punto è sul bordo tra più cluster.

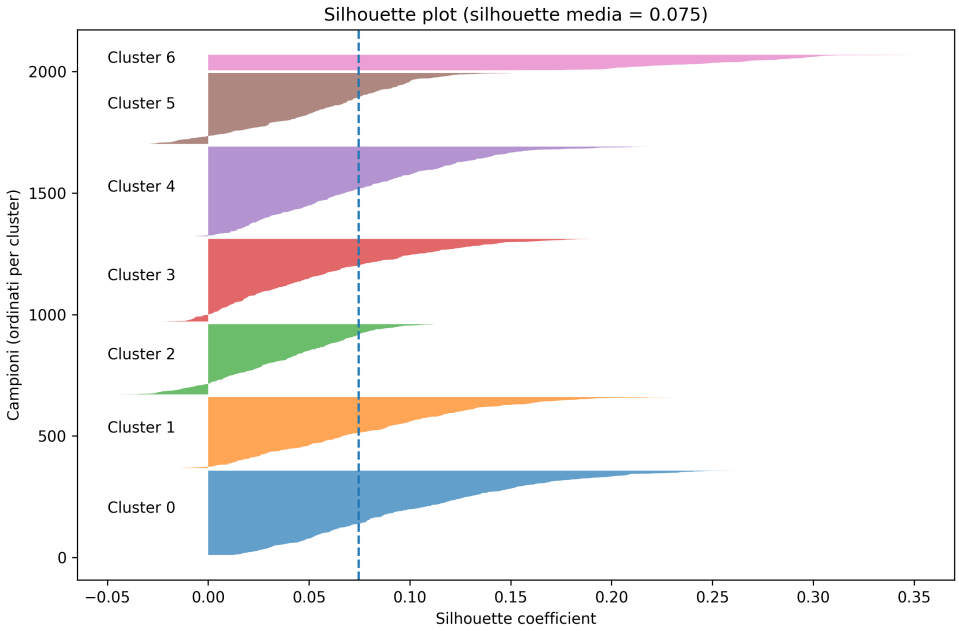


Figura 30: Grafico della silhouette dei cluster

La figura appena presentata mostra il grafico della silhouette relativo al clustering tramite l'algoritmo K-Means. Notiamo come la maggior parte delle osservazioni presenti valori positivi della silhouette, e che la concentrazione intorno allo zero sia notevole. Evidenziamo, infine, il valore della silhouette media pari a 0.075, che risulta particolarmente basso. Tali risultati non sorprendono, ma avvalorano le tesi esposte precedentemente riguardo alla natura multifattoriale del dataset e la mancanza di confini rigidi tra i profili di rischio. Ciò risulta conforme con l'ambito medico del dataset analizzato, dove è naturale che i dati si organizzino lungo gradienti piuttosto che in classi nettamente separate.

5.3 DBSCAN

Il secondo algoritmo di clustering applicato al dataset è il DBSCAN. Esso si basa sulla densità dei dati, e li categorizza in tre tipologie: core point, border point e rumore. Esso identifica i cluster come regioni dense, che possono assumere forma arbitraria.

L'algoritmo si basa sulla scelta di due parametri fondamentali: ϵ, che definisce il raggio entro il quale due punti sono considerati vicini; e *min_samples*, che indica il numero minimo di punti richiesti all'interno del raggio ϵ, per formare una regione densa.

Per determinare i valori di ϵ e *min_samples*, è stata condotta una ricerca a griglia, che ha esplorato un insieme discreto di combinazioni plausibili. La seguente tabella mostra un esempio dei risultati ottenuti:

eps	min_samples	Numero cluster	Percentuale di rumore	Silhouette score
3.0	3	13	23.550	-0.100
3.2	3	8	13.200	-0.050
3.4	3	6	6.4	-0.022
⋮	⋮	⋮	⋮	⋮

Lo spazio di ricerca esplorato per i parametri è: per ϵ da 3.0 a 5.0 con intervalli di 0.2 e per *min_samples* da 3 a 15. Da questa ricerca sono state generate tre heatmap, indicanti: il numero di cluster, la percentuale di rumore e il valore della silhouette.

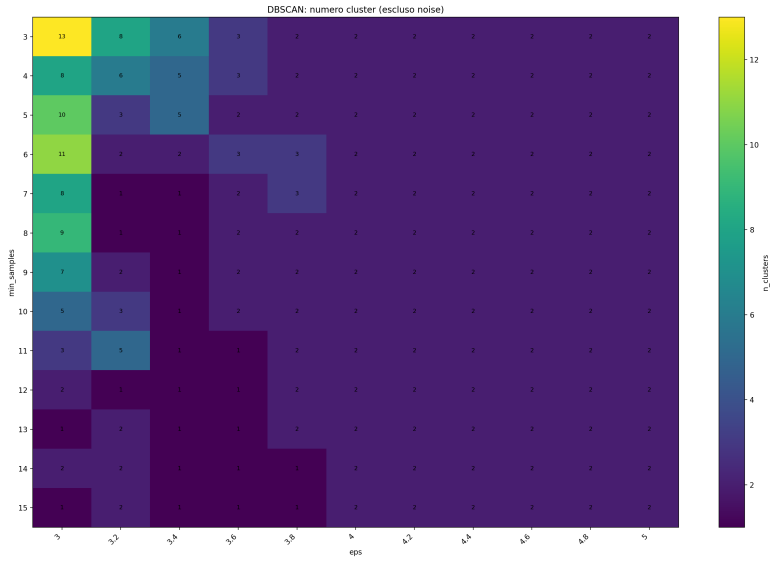


Figura 31: Heatmap del numero di cluster generata al variare di ϵ e min_samples

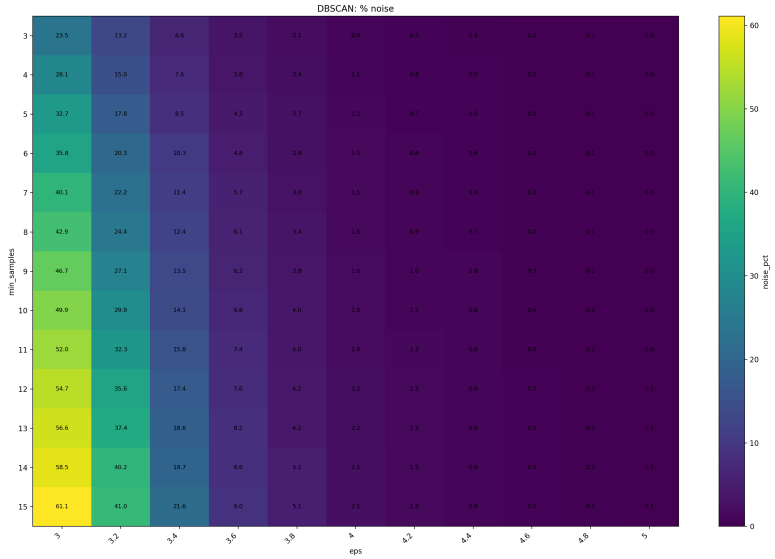


Figura 32: Heatmap della percentuale di rumore generata al variare di ϵ e min_samples

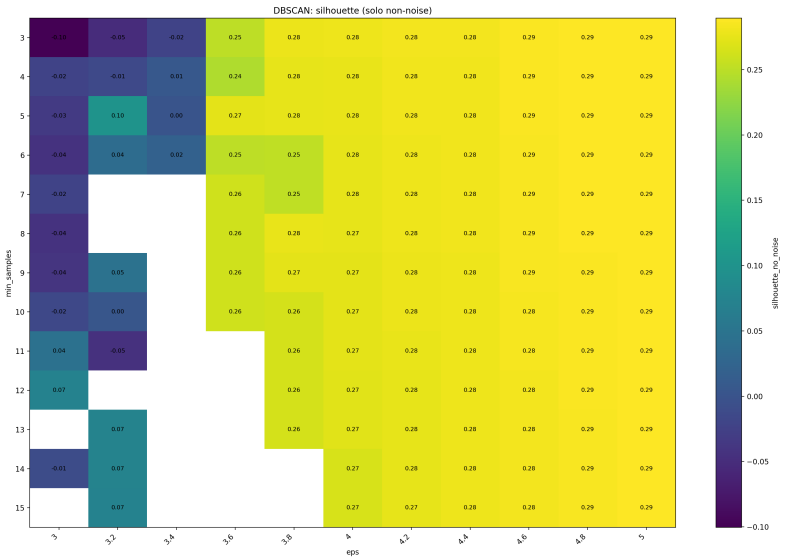


Figura 33: Heatmap della silhouette generata al variare di ϵ e min_samples

Come si può evincere dai grafici appena mostrati, per valori bassi dei parametri il numero dei cluster aumenta, e con esso anche la percentuale di rumore; mentre il valore del silhouette score cala drasticamente. Da qui, si ricava che la scelta di ϵ e min_samples deve essere un compromesso, e i parametri ottimali risultano: $\epsilon = 5.0$ e min_samples $= 3$, con cui si ottiene una silhouette score pari a 0.289 e un numero di cluster pari a 2.

Mostriamo, infine, la visualizzazione dei cluster tramite t-SNE:

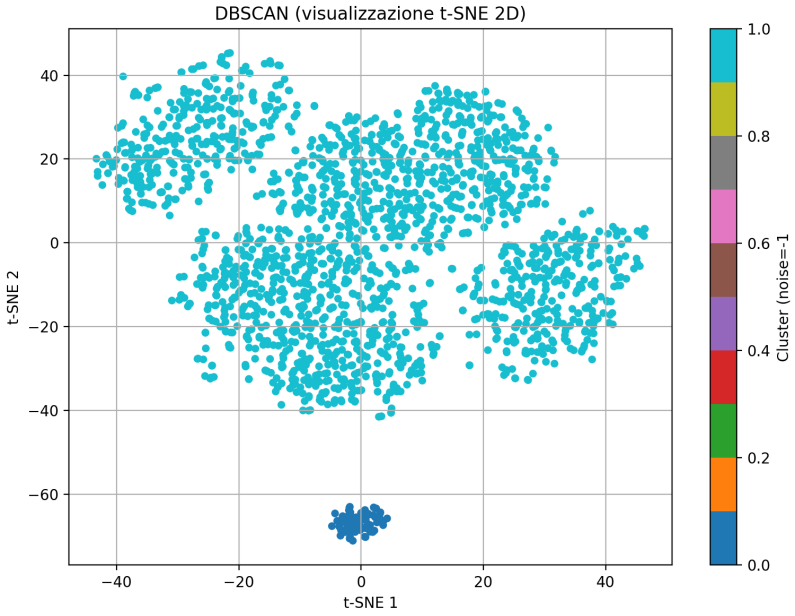


Figura 34: Cluster individuati dal DBSCAN tramite t-SNE

Come possiamo notare, l'algoritmo DBSCAN individua una grande regione continua di punti, corrispondente al cluster principale, e un secondo cluster separato e di dimen-

sioni ridotte.
Il risultato ottenuto indica, dunque, che il dataset non presenta delle regioni di densità chiaramente separate, ma una distribuzione continua delle osservazioni, mostrando come attraverso il DBSCAN la segmentazione risulti molto più semplice e non adatta a descrivere la struttura globale del dataset.

6 Introduzione e Descrizione del Dataset Google Stock Data

6.1 Obiettivi del Progetto

Il presente progetto si colloca nell'ambito dell'analisi delle serie storiche (*Time Series Analysis*), una disciplina fondamentale della Data Science che mira a modellare l'evoluzione di fenomeni dinamici nel tempo. Nello specifico, l'obiettivo principale del lavoro è analizzare il comportamento storico del titolo azionario di Google per sviluppare modelli di forecasting in grado di predirne l'andamento futuro.

Per condurre questa analisi, è stato selezionato il dataset `GOOGL.csv`, che copre un arco temporale estremamente significativo: dal 19 agosto 2004 (data della quotazione in borsa) fino al marzo 2022. La scelta di questo orizzonte temporale, pari a quasi 18 anni, ci permette di disporre di una base dati robusta per l'addestramento dei modelli predittivi.

6.2 Motivazioni della scelta del dataset

L'utilizzo del dataset relativo alle azioni Google per il forecasting è scelto per diversi motivi:

- **Continuità temporale:** I dati azionari sono registrati con una regolarità scandita dai giorni di borsa aperta (*trading days*). Questa continuità è preferibile rispetto a dataset con registrazioni sporadiche, poiché facilita le operazioni di *lagging* e il calcolo di metriche mobili.
- **Volume sufficiente di dati:** Con oltre 4000 osservazioni, il dataset offre una profondità storica tale da includere diversi cicli economici: la fase di espansione pre-2008, la grande crisi finanziaria, il lungo mercato rialzista del decennio 2010-2019 e lo shock della pandemia.
- **Variabili significative:** Il dataset contiene variabili numeriche quantitative essenziali per l'analisi tecnica e il forecasting, come i prezzi di apertura/chiusura e i volumi, che permettono di valutare non solo il valore ma anche la forza del trend.

6.3 Descrizione delle Variabili

Il dataset si presenta in formato tabellare e contiene 7 variabili per ogni osservazione giornaliera. Di seguito viene riportata la descrizione dettagliata:

- **Date:** La data di riferimento della rilevazione, fondamentale per l'indicizzazione temporale.
- **Open:** Il prezzo del titolo all'apertura della seduta di borsa.
- **High:** Il prezzo massimo raggiunto dal titolo durante la giornata.
- **Low:** Il prezzo minimo toccato dal titolo durante la giornata.
- **Close:** Il prezzo di chiusura alla fine della seduta.
- **Adj Close (Adjusted Close):** Il prezzo di chiusura "aggiustato". Questa variabile è cruciale per l'analisi finanziaria poiché tiene conto di eventi societari come dividendi, stock split (frazionamenti azionari) e nuove emissioni.
- **Volume:** Il numero totale di azioni scambiate durante la giornata, indicatore della liquidità del titolo.

7 Google Stock Data: Forecasting

7.1 Fase di ETL e Pre-processing

Prima di procedere con l'analisi esplorativa e la modellazione, i dati grezzi sono stati sottoposti a un processo di ETL (*Extract, Transform, Load*) per garantirne la qualità e l'usabilità. L'implementazione è stata effettuata utilizzando il linguaggio Python e la libreria `pandas`.

7.1.1 Caricamento e Pulizia dei Dati

In prima istanza, il file è stato importato e la colonna `Date` è stata convertita nel formato `datetime`. Successivamente, tale colonna è stata impostata come indice del DataFrame. Questo passaggio è stato necessario per abilitare le funzionalità di serie storica, come il ricampionamento (*resampling*) e la corretta gestione dell'asse temporale nei grafici.

È stata eseguita una verifica sulla presenza di valori mancanti (*missing values*) tramite il comando `isnull().sum()`. L'analisi non ha rilevato valori nulli (NaN) all'interno delle serie storiche dei prezzi, confermando la buona qualità del dataset di origine. Non sono state pertanto necessarie tecniche di imputazione dei dati.

Per fornire un riscontro immediato sulla struttura finale del dataset dopo le fasi di estrazione e pulizia, nella Tabella 9 viene riportato un estratto relativo agli ultimi 10 giorni di contrattazione disponibili nel periodo in esame. Questa visualizzazione permette di apprezzare l'organizzazione cronologica della serie storica e la granularità giornaliera delle variabili di prezzo (Open, High, Low, Close e Adjusted Close).

Date	**Open**	**High**	**Low**	**Close**	**Adj Close**
2022-03-11	2669.77	2675.91	2592.63	2597.41	2597.41
2022-03-14	2605.00	2608.18	2505.50	2519.02	2519.02
2022-03-15	2539.52	2597.09	2514.41	2583.96	2583.96
2022-03-16	2614.66	2666.66	2574.69	2665.61	2665.61
2022-03-17	2662.98	2681.61	2643.70	2676.78	2676.78
2022-03-18	2668.49	2724.88	2645.17	2722.51	2722.51
2022-03-21	2723.27	2741.00	2681.85	2722.03	2722.03
2022-03-22	2722.03	2821.00	2722.03	2797.36	2797.36
2022-03-23	2774.05	2791.77	2756.70	2765.51	2765.51
2022-03-24	2784.00	2832.38	2755.01	2831.44	2831.44

Tabella 9: Ultimi 10 giorni di dati del dataset

7.2 Analisi Esplorativa dei Dati (EDA)

L'Analisi Esplorativa dei Dati (EDA) costituisce una fase fondamentale del progetto, necessaria per comprendere a fondo le caratteristiche del dataset prima di procedere con la modellazione. In questo capitolo, attraverso l'ausilio di visualizzazioni grafiche e test statistici, vengono indagate le proprietà della serie storica delle azioni Google, evidenziando trend, stagionalità e anomalie strutturali.

7.2.1 Analisi Preliminare delle Variabili di Prezzo

In questa prima fase viene esaminato il comportamento generale delle variabili a disposizione. Il grafico in Figura 35 mostra l'andamento delle principali metriche di prezzo: chiusura, apertura, massimo giornaliero e minimo giornaliero, nel periodo che va dal 2004 al 2022. Questi grafici forniscono una visione completa delle dinamiche del mercato, consentendo di identificare trend, stagionalità e anomalie.

Come è evidente, i grafici sono pressoché identici e sovrapponibili. Essi evidenziano una crescita significativa a lungo termine, con accelerazioni notevoli in corrispondenza di eventi di mercato chiave. Le differenze puntuali tra il prezzo massimo e minimo di giornata, pur presenti, risultano trascurabili se osservate su un orizzonte temporale così ampio. Alla luce di questa forte correlazione, per alcune delle successive analisi di previsione si farà riferimento al prezzo di chiusura rettificato (*Adj Close*), in quanto rappresenta la misura più sintetica e completa del valore del titolo a fine giornata.

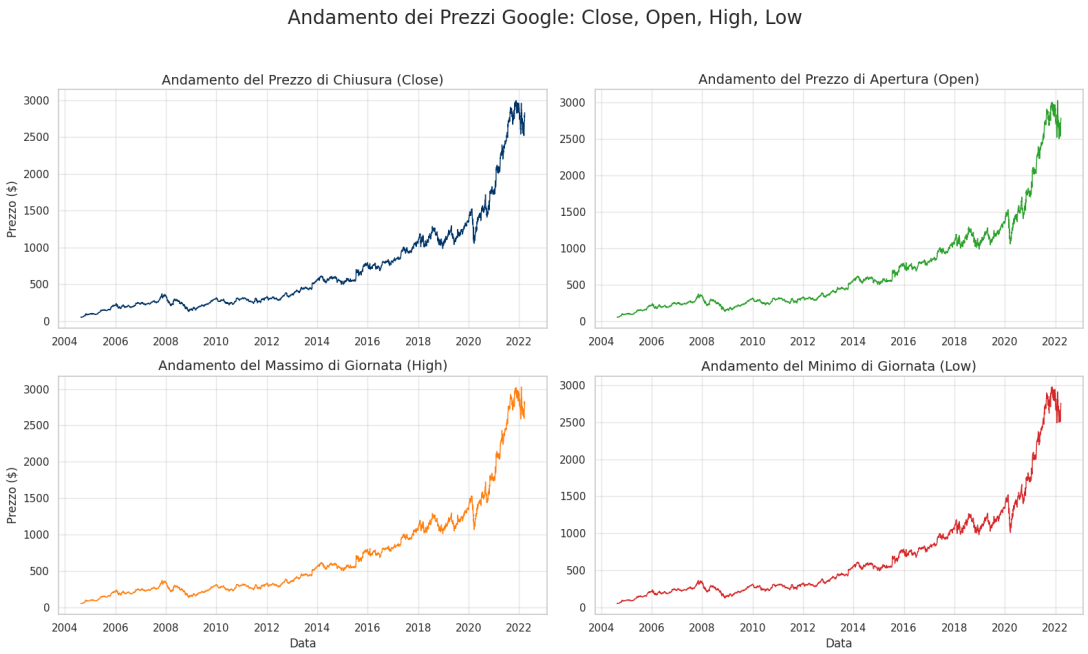


Figura 35: Confronto andamento prezzi: Open, High, Low e Close.

7.2.2 Analisi dell'Andamento Storico e dei Volumi

Focalizzando l'attenzione sulla variabile Adj Close, la Figura 36 mostra l'evoluzione storica del prezzo di chiusura rettificato.



Figura 36: Andamento storico del prezzo Adj Close (2004-2022).

Dal grafico emerge un chiaro trend crescente di lungo periodo. Il prezzo è passato da valori inferiori ai 100 dollari nei primi anni successivi alla quotazione fino a superare i 2500 dollari nel 2021. Tale crescita non appare lineare ma esponenziale, specialmente nell'ultimo decennio. Si possono tuttavia notare fasi di correzione, ovvero periodi in cui il prezzo scende temporaneamente, che corrispondono alle principali crisi economiche globali.

Parallelamente, sono stati analizzati i volumi di scambio, riportati in Figura 37.

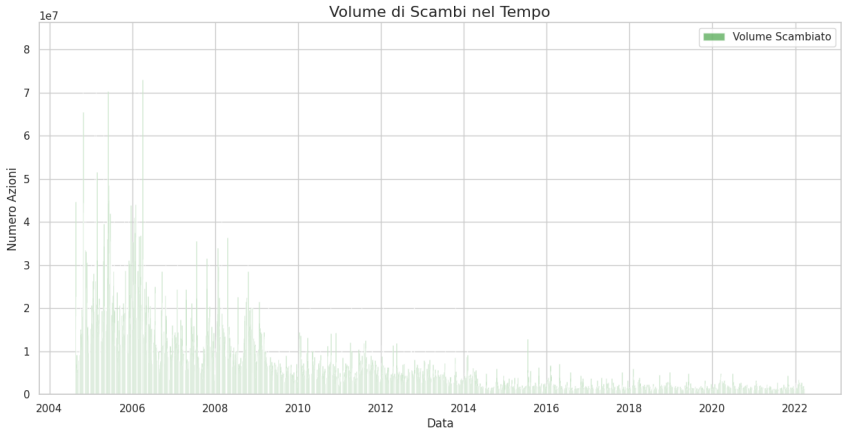


Figura 37: Evoluzione del volume di scambi nel tempo.

Si nota come l'attività di scambio sia stata molto più intensa e variabile nei primi anni (2004-2008), una fase iniziale di assestamento del titolo sul mercato. Successivamente, i volumi medi si sono stabilizzati su livelli più bassi, pur mantenendo dei picchi improvvisi in corrispondenza di notizie rilevanti o shock esterni.

7.2.3 Distribuzione dei Rendimenti e Volatilità

Per comprendere meglio le variazioni giornaliere, sono stati analizzati i rendimenti (la variazione percentuale del prezzo da un giorno all'altro). La Figura 38 mostra come si distribuiscono queste variazioni.

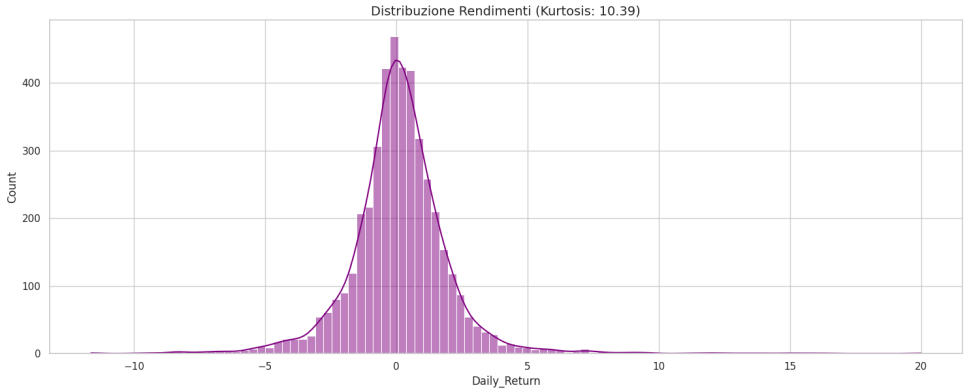


Figura 38: Distribuzione di frequenza dei rendimenti giornalieri.

La forma del grafico (istogramma) ricorda una campana, centrata sullo zero: ciò significa che la maggior parte delle volte le variazioni di prezzo sono contenute. Tuttavia, si nota che le code del grafico sono un po' più alte del normale: questo indica che eventi estremi (grandi rialzi o grandi crolli) accadono più spesso di quanto si possa pensare.

La Figura 39 illustra invece la volatilità, ovvero quanto il prezzo oscilla nel tempo.

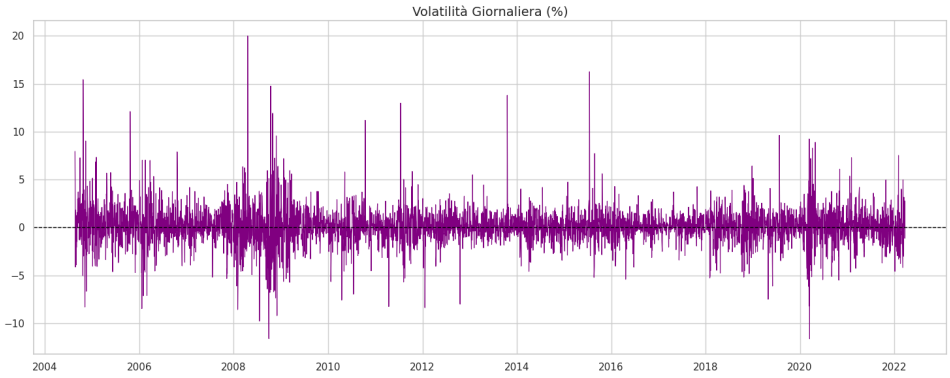


Figura 39: Andamento della volatilità nel tempo.

È evidente che i periodi di alta instabilità tendono a raggrupparsi. Si osservano picchi di volatilità durante la crisi del 2008 e la pandemia del 2020, mentre in altri periodi il mercato appare molto più calmo. Questo fenomeno è noto come "raggruppamento della volatilità" (*volatility clustering*).

7.2.4 Focus: L'impatto del COVID-19

Un'attenzione particolare è stata dedicata al periodo della pandemia, un evento storico che ha rappresentato un vero e proprio "stress test" per l'economia globale e per i mercati finanziari. Analizzare questo intervallo temporale è fondamentale per capire come il titolo reagisce di fronte a shock esterni imprevisti.

La Figura 40 mostra il dettaglio del crollo avvenuto a marzo 2020.



Figura 40: Dettaglio del crollo e della ripresa immediata (Marzo-Agosto 2020).

Il grafico evidenzia una caduta verticale dei prezzi: in pochissime settimane il valore delle azioni ha subito una drastica riduzione. Questo crollo non è stato causato da problemi specifici dell'azienda Google, ma dalla paura generalizzata e dall'incertezza che hanno colpito tutti i mercati mondiali all'inizio dell'emergenza sanitaria. Gli investitori, non sapendo cosa sarebbe accaduto, hanno venduto massicciamente le proprie posizioni.

Tuttavia, l'aspetto più interessante che emerge dal grafico è la rapidità e la forma della risalita. La ripresa è stata immediata, disegnando quella che in gergo tecnico viene definita una curva a "V": dopo aver toccato il minimo, il prezzo è rimbalzato velocemente e in pochi mesi (già ad agosto 2020) il titolo aveva recuperato tutto il valore perso, tornando ai livelli pre-crisi. Questo comportamento dimostra una straordinaria resilienza: mentre altri settori faticavano a ripartire, il settore tecnologico ha dimostrato di essere solido.

Espandendo l'analisi al 2020 (Figura 41), si può apprezzare il contesto generale e le conseguenze a lungo termine.

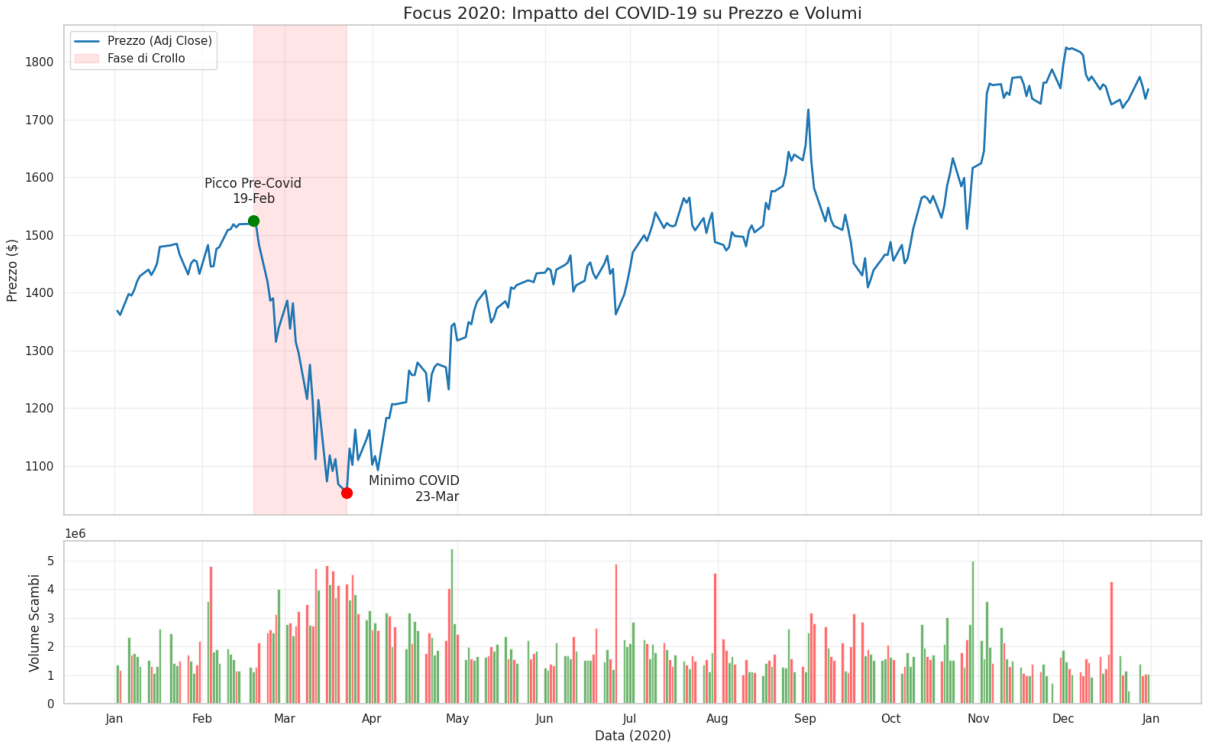


Figura 41: Panoramica del trend nel periodo pandemico

Si nota chiaramente come, dopo lo shock iniziale, il trend di crescita non solo sia ripreso, ma abbia subito un'accelerazione rispetto agli anni precedenti. La pandemia ha infatti agito da catalizzatore per la digitalizzazione: costrette a casa del lockdown, le persone e le aziende hanno aumentato l'uso di servizi digitali, rendendo Google ancora più centrale nell'economia globale.

Parallelamente all'andamento dei prezzi, è rilevante osservare anche la dinamica dei volumi di scambio. Durante le fasi più acute del 2020, si è registrato un incremento dell'attività di scambio rispetto al periodo precedente. Nello specifico, in concomitanza con la brusca discesa dei prezzi di febbraio-marzo, si evidenzia un netto picco dei volumi. Tale fenomeno riflette l'incremento alle vendite da parte degli investitori che, di fronte all'improvvisa incertezza dell'emergenza sanitaria, hanno liquidato le proprie posizioni.

7.2.5 Riepilogo Statistico delle Variabili

A completamento dell'analisi preliminare, si riportano nella Tabella 10 le statistiche descrittive puntuali per tutte le variabili di prezzo (Open, High, Low, Close e Adj Close). Questo riepilogo permette di quantificare la dispersione e il range di variazione dei dati storici.

Variabile	**Count**	**Mean**	**Std**	**Min**	**25%**	**50%**	**75%**	**Max**
Open	4431.0	693.09	645.12	49.64	248.56	434.92	1007.36	3025.00
High	4431.0	699.74	651.33	50.92	250.85	437.89	1020.65	3030.93
Low	4431.0	686.08	638.58	48.03	245.81	432.69	997.27	2977.98
Close	4431.0	693.10	645.19	50.06	248.42	435.33	1007.79	2996.77
Adj Close	4431.0	693.10	645.19	50.06	248.42	435.33	1007.79	2996.77

Tabella 10: Statistiche descrittive dei prezzi (1984-2024).

Dall'analisi della tabella emerge con chiarezza l'ampiezza dell'escursione storica del titolo: la distanza tra i valori minimi (intorno ai 50$) e i massimi (oltre i 3000$) conferma il forte trend di crescita di lungo periodo. Inoltre, l'elevata deviazione standard (superiore a 600$) testimonia l'alta variabilità e la dispersione dei prezzi rispetto al valore medio nel corso dei decenni analizzati.

7.3 Forecasting sul prezzo di chiusura con modello il ARIMA

7.3.1 Introduzione e Selezione dei Dati

Nel presente capitolo viene illustrata l'applicazione di tecniche di analisi delle serie storiche per la previsione del prezzo delle azioni Google. Nello specifico, l'analisi è stata condotta impiegando la libreria `statsmodels` in ambiente Python, focalizzandosi sulla variabile *Adj Close* (prezzo di chiusura rettificato) e utilizzando il modello ARIMA.

Il dataset originario copre un periodo estremamente esteso, dal 2004 al 2022. Sebbene questa granularità offra una visione storica completa, l'utilizzo di una serie temporale così profonda può presentare delle criticità in fase di modellazione predittiva. Le dinamiche di mercato del 2004, infatti, rispondevano a logiche economiche e strutturali molto diverse da quelle attuali; includere dati così remoti rischierebbe di introdurre "rumore" o bias nel modello, riducendone la capacità di adattarsi ai trend più recenti.
Per ovviare a tale problema e garantire che il modello apprenda dalle dinamiche più pertinenti, si è deciso di restringere l'analisi agli **ultimi 10 anni**. Il periodo in esame va dunque dal **26 marzo 2012** al **24 marzo 2022**.

Questa selezione rappresenta un compromesso ottimale tra la necessità di avere un volume di dati sufficiente per l'addestramento (oltre 2000 osservazioni) e l'esigenza di focalizzarsi sul comportamento "moderno" del titolo. Il dataset così ridotto è stato ripartito in due sottoinsiemi per la fase di validazione:

- **Training Set:** Comprende i primi 2231 giorni, utilizzati per stimare i parametri del modello.
- **Test Set:** Comprende gli ultimi 286 giorni, utilizzati per valutare la capacità predittiva su dati non visti.

7.3.2 Decomposizione della Serie Temporale (STL)

Prima di procedere con la modellazione parametrica, è stata eseguita una decomposizione della serie temporale mirata a isolare le componenti fondamentali del segnale. Utilizzando la tecnica STL (*Seasonal-Trend decomposition using LOESS*), il prezzo è stato scomposto in tre elementi additivi, come illustrato in Figura 42.

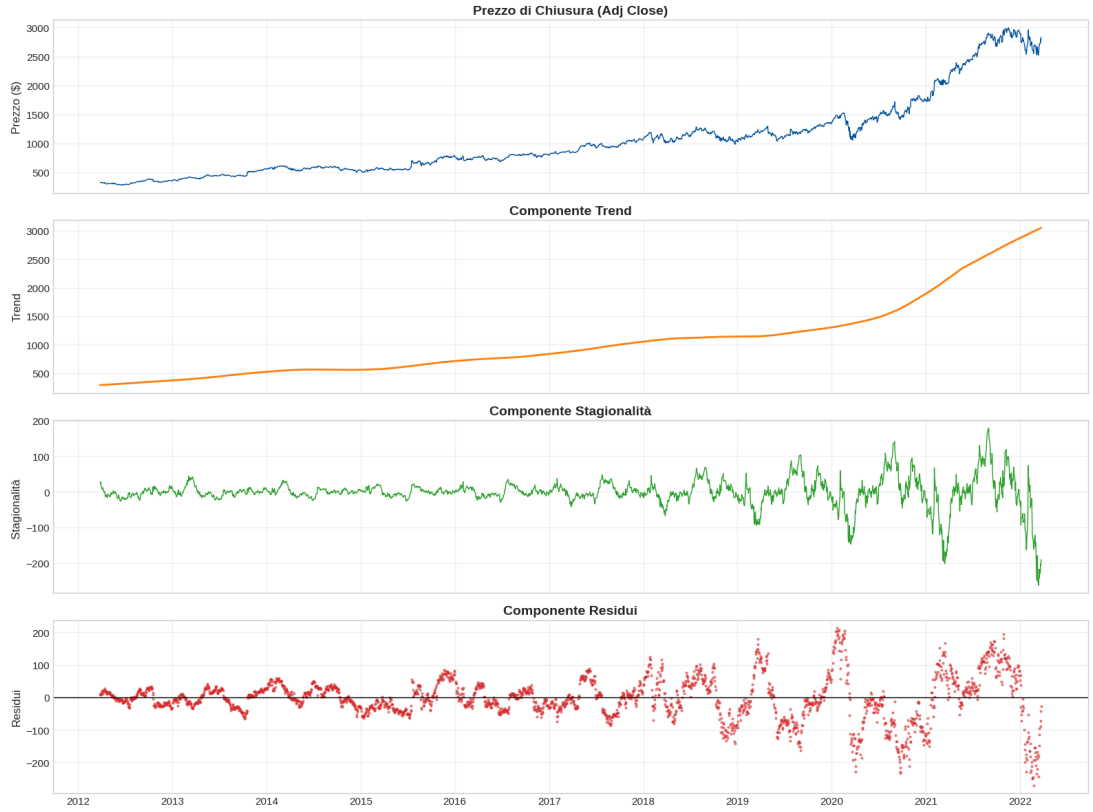


Figura 42: Decomposizione STL: Trend, Stagionalità e Residui.

L'analisi visiva delle componenti evidenzia:

- **Prezzo di chiusura (Adj Close):** Il grafico mostra l'andamento storico del prezzo di chiusura delle azioni Apple dal 2004 al 2022 (già ampiamente descritto nelle sezioni precedenti).

- **Componente di Trend:** Mostra la direzione di fondo del mercato. Si osserva una crescita robusta e continua, che conferma la tendenza rialzista strutturale del titolo nel decennio considerato.

- **Componente Stagionale:** Isola le oscillazioni periodiche che si ripetono a intervalli regolari. La presenza di una stagionalità definita suggerisce l'esistenza di pattern ricorrenti (probabilmente legati a cicli annuali o trimestrali) che si sovrappongono al trend principale.

- **Componente Residuale:** Rappresenta la parte residuale della serie, ovvero ciò che non è spiegato dal trend o dalla stagionalità. È importante notare come la varianza dei residui non sia costante nel tempo , ma aumenti significativamente in corrispondenza di shock di mercato, segnalando periodi di maggiore incertezza.

7.3.3 Verifica della Stazionarietà (Test ADF)

Un prerequisito teorico fondamentale per l'applicazione dei modelli della famiglia ARIMA è la stazionarietà della serie storica. Una serie si definisce stazionaria se le sue proprietà statistiche (media, varianza, autocovarianza) sono costanti nel tempo. L'osservazione del grafico del trend suggerisce chiaramente che la serie originale non soddisfa questa condizione, in quanto la media varia nel tempo seguendo la crescita del prezzo.

Per ottenere una conferma statistica rigorosa, è stato applicato il test **Augmented Dickey-Fuller (ADF)**. Tale test pone come ipotesi nulla (H_0) che la serie sia non stazionaria. I risultati del test sulla serie originale sono riportati nella Tabella 11.

Metrica	**Valore (Pre-Diff)**
Test Statistic	1.726417
p-value	0.998191
Critical Value (1%)	-3.432975
Critical Value (5%)	-2.862700
Critical Value (10%)	-2.567387

Tabella 11: Risultati Test ADF sulla serie originale.

Il *p-value* ottenuto è pari a **0.998**. Essendo tale valore ampiamente superiore alla soglia critica di confidenza (0.05), non è possibile rifiutare l'ipotesi nulla. Si conclude pertanto che la serie originale **non è stazionaria**.

Per rendere la serie stazionaria, si è reso necessario applicare un'operazione di differenziazione. Dopo alcune iterazioni, si è determinato che una differenziazione di ordine secondo ($d = 2$) fosse necessaria per rimuovere completamente le componenti di trend e stabilizzare la media. I risultati del test ripetuto sulla serie trasformata sono visibili in Tabella 12.

Metrica	**Valore (Post-Diff, $d = 2$)**
Test Statistic	-15.75465
p-value	1.21×10^{-28}
Critical Value (1%)	-3.432982
Critical Value (5%)	-2.862703
Critical Value (10%)	-2.567389

Tabella 12: Risultati Test ADF sulla serie differenziata.

In questo caso, il *p-value* risulta essere un valore infinitesimale (1.21×10^{-28}), ben al di sotto della soglia di significatività. Possiamo quindi affermare con certezza che la serie differenziata è **stazionaria**. La Figura 43 mostra il confronto grafico: la serie originale

(a sinistra) evolve nel tempo, mentra la serie differenziata (a destra) oscilla attorno allo zero.

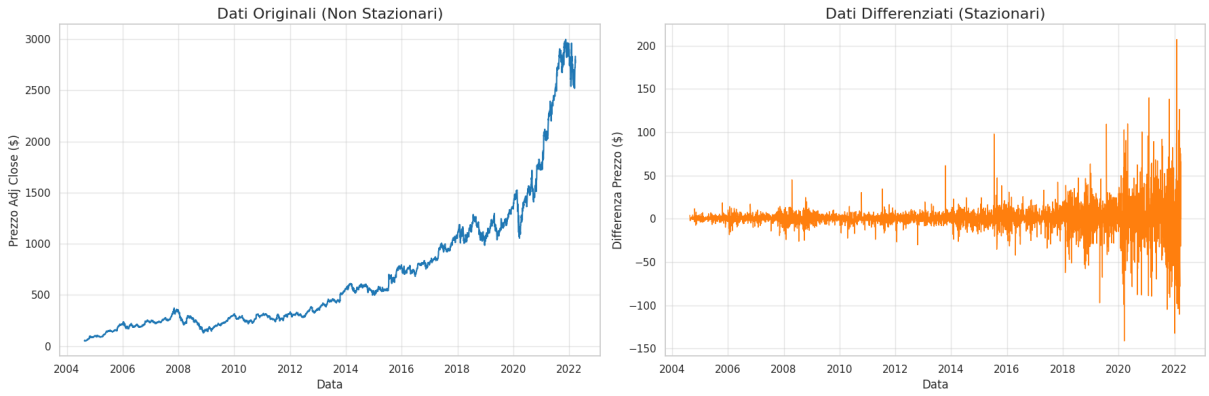


Figura 43: Confronto: Serie Originale vs Serie Differenziata.

7.3.4 Identificazione dei Parametri del Modello

Una volta ottenuta la stazionarietà, il passo successivo è stato quello di identificare i valori dei parametri p (parte autoregressiva) e q (media mobile). A tale scopo, sono stati analizzano i correlogrammi delle funzioni di Autocorrelazione (ACF) e Autocorrelazione Parziale (PACF), riportati in Figura 44.

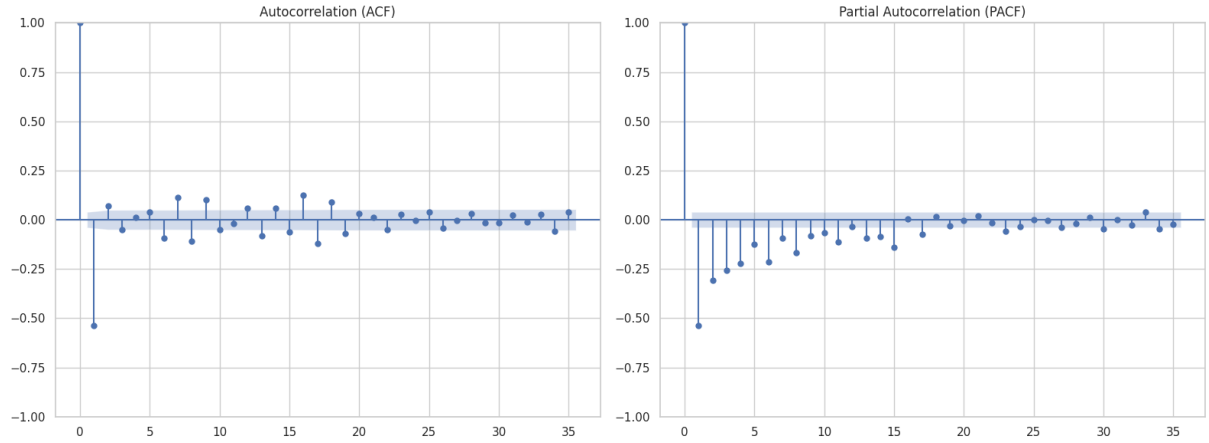


Figura 44: Funzioni di Autocorrelazione (ACF) e Autocorrelazione Parziale (PACF).

L'ACF mostra la correlazione tra la serie e le sue versioni ritardate (lags), aiutando a stimare la componente a media mobile (MA). Il PACF isola la correlazione diretta, depurata dagli effetti intermedi, risultando utile per la componente autoregressiva (AR). L'osservazione dei grafici evidenzia picchi significativi nei primi lag, suggerendo che il processo generatore dei dati dipenda dai valori immediatamente precedenti.

7.3.5 Selezione del Modello Ottimale (Grid Search)

Non limitandosi alla sola ispezione visiva, per determinare la combinazione ottimale dei parametri (p, d, q) si è adottato un approccio computazionale di **Grid Search**. L'algoritmo ha testato diverse configurazioni in modo iterativo, valutando la bontà di ciascun modello tramite l'**AIC (Akaike Information Criterion)**. L'AIC stima la qualità relativa di un modello statistico penalizzandone la complessità (numero di parametri) per evitare l'overfitting: minore è il valore dell'AIC, migliore è il trade-off tra aderenza ai dati e semplicità.

Al termine della procedura, la configurazione che ha minimizzato l'AIC è risultata essere:

ARIMA(3, 2, 1)

Di seguito, in Figura 45, viene riportato il sommario statistico del modello addestrato, che mostra i coefficienti stimati per i termini autoregressivi e di media mobile.

```
==============================================================================
Dep. Variable:              Adj Close   No. Observations:                 2231
Model:                 ARIMA(3, 2, 1)   Log Likelihood               -9384.821
Date:                Wed, 07 Jan 2026   AIC                          18779.642
Time:                        17:07:20   BIC                          18808.188
Sample:                             0   HQIC                         18790.066
                                 - 2231
Covariance Type:                  opg
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
ar.L1         -0.0950      0.011     -8.713      0.000      -0.116      -0.074
ar.L2          0.0320      0.011      2.849      0.004       0.010       0.054
ar.L3         -0.0022      0.012     -0.190      0.849      -0.025       0.021
ma.L1         -0.9987      0.002   -454.719      0.000      -1.003      -0.994
sigma2       265.0891      3.061     86.614      0.000     259.091     271.088
===================================================================================
Ljung-Box (L1) (Q):                   0.00   Jarque-Bera (JB):             15492.30
Prob(Q):                              0.96   Prob(JB):                         0.00
Heteroskedasticity (H):              15.25   Skew:                             0.06
Prob(H) (two-sided):                  0.00   Kurtosis:                        15.91
===================================================================================
```

Figura 45: Sommario statistico del modello ARIMA(3,2,1).

7.3.6 Analisi dei Risultati e Metriche di Performance

Il modello ARIMA(3,2,1) è stato infine utilizzato per generare le previsioni sul Test Set. La Figura 46 offre una panoramica completa, confrontando la serie storica reale (in verde) con la traiettoria prevista dal modello (in rosso).



Figura 46: Confronto Valori Reali vs Forecast ARIMA(3,2,1)

Per apprezzare meglio la qualità della previsione nel breve termine, la Figura 47 propone un ingrandimento focalizzato sulla transizione tra dati di training e dati di test.

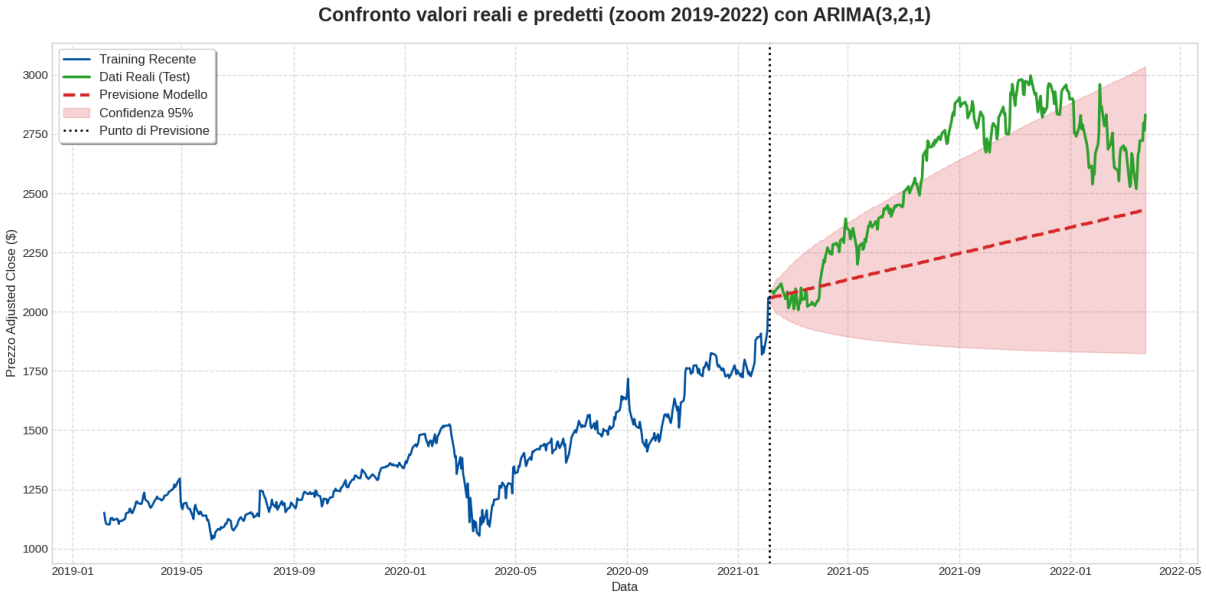


Figura 47: Dettaglio Zoom: Confronto Valori Reali vs Forecast ARIMA.

Dal grafico si evince come il modello riesce a catturare la tendenza generale, ma mostri dei limiti nel replicare le fluttuazioni, generando una linea retta. Per quantificare oggettivamente l'errore di previsione, sono state calcolate le seguenti metriche, riassunte in Tabella 13:

Metrica	**Valore**
MAE (Errore Medio Assoluto)	344.99
MSE (Errore Quadratico Medio)	159449.61
RMSE (Radice Err. Quadr. Medio)	399.31
MAPE (Err. Percentuale Medio)	12.66%
R^2 (Coefficiente di Determinazione)	-0.8670

Tabella 13: Metriche di performance ARIMA (3,2,1)

Il **MAPE** del 12.66% indica che, mediamente, la previsione si discosta dal valore reale di circa il 12%, un risultato accettabile data l'elevata volatilità del titolo. Tuttavia, il valore negativo dell'R^2 (-0.8670) suggerisce cautela: i modelli univariati lineari come l'ARIMA, pur essendo potenti strumenti statistici, faticano a prevedere cambiamenti strutturali improvvisi o trend non lineari complessi tipici dei mercati finanziari moderni, dove variabili esogene non considerate giocano un ruolo determinante.

7.4 Forecasting del Volume con modello SARIMAX

7.4.1 Introduzione e Pre-processing dei Dati

In questo capitolo l'analisi si sposta dalla previsione del prezzo a quella del **Volume** di scambio delle azioni Google. Il volume rappresenta una grandezza fondamentale in ambito finanziario, in quanto indicatore della liquidità e dell'intensità dell'interesse degli investitori verso il titolo.

A differenza del prezzo, che è una variabile di stato continua, il volume è una grandezza di flusso caratterizzata da una natura molto più irregolare. Spesso si osservano picchi improvvisi (*spikes*) legati a notizie esterne (come i risultati trimestrali o annunci di prodotto), seguiti da periodi di relativa quiete.
Per gestire questa complessità e catturare le ciclicità temporali, si è scelto di utilizzare il modello **SARIMAX** (Seasonal AutoRegressive Integrated Moving Average with eXogenous factors). Questo modello estende le capacità dell'ARIMA integrando esplicitamente la componente stagionale, fondamentale per analizzare serie con periodicità ricorrenti.

Il periodo osservato per questa analisi copre l'intero storico disponibile, dal **31 agosto 2004** al **31 marzo 2022**. Tuttavia, data l'elevata frequenza e il rumore dei dati giornalieri, si è reso necessario un pre-processing: è stato effettuato un **campionamento mensile**, aggregando i dati tramite il calcolo della media mensile dei volumi. Questa operazione permette di smussare le irregolarità di breve periodo ed evidenziare i trend macroscopici.
Il dataset risultante è stato suddiviso in:

- **Training Set:** 169 mesi (utilizzati per l'addestramento).
- **Test Set:** 43 mesi (utilizzati per la validazione).

7.4.2 Decomposizione della Serie Temporale (STL)

Prima di procedere con la verifica della stazionarietà, è fondamentale comprendere la struttura interna della serie dei volumi. A tal fine, è stata applicata la decomposizione STL, visualizzata in Figura 48.

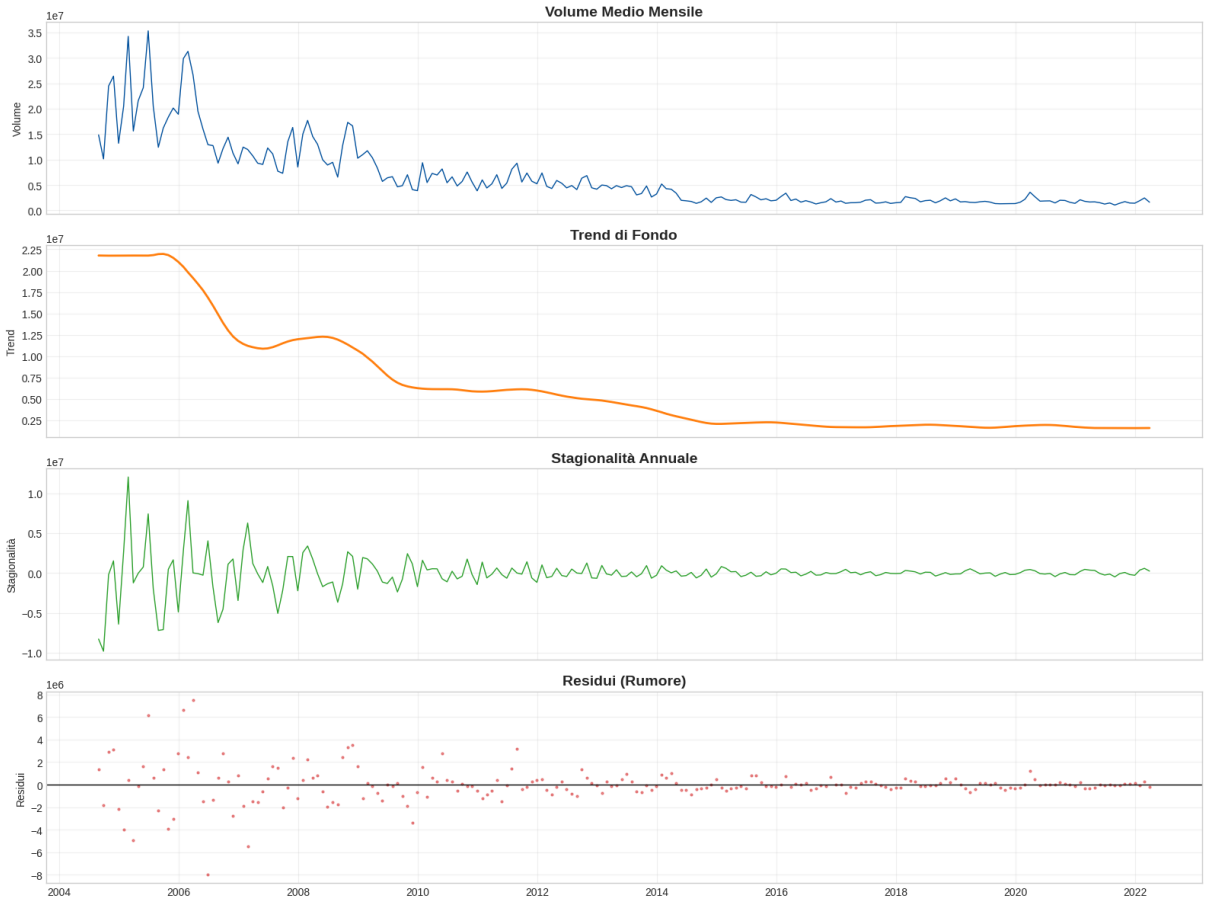


Figura 48: Decomposizione STL del Volume: Trend, Stagionalità e Residui.

L'analisi delle componenti evidenzia aspetti cruciali:

- **Trend:** A differenza del prezzo (che mostrava una crescita costante), il trend del volume è stato discendente o stazionario per lunghi periodi, stabilizzandosi negli ultimi anni. Questo è coerente con la maturazione del titolo: la fase speculativa iniziale lascia spazio a scambi meno frenetici.

- **Stagionalità:** Emerge una chiara componente ciclica che si ripete annualmente. Questo giustifica l'utilizzo di un modello SARIMAX ($m = 12$) rispetto a un semplice ARIMA, poiché esiste una periodicità sistematica nell'attività di scambio.

- **Residui:** La componente residuale rimane significativa e presenta un'elevata varianza. Ciò conferma che, nonostante la rimozione di trend e stagionalità, una parte rilevante delle fluttuazioni del volume è guidata da fattori casuali o esogeni.

7.4.3 Analisi di Stazionarietà (Test ADF)

COme fatto anche per ARIMA è stata svolta la verifica della stazionarietà, verificando che le proprietà statistiche fondamentali della serie, come la media e la variabilità, non cambiano nel tempo.

Per accertare tale proprietà, è stato utilizzato, anche qui, il test di **ADF**. Il test funziona verificando un'ipotesi di partenza (ipotesi nulla) secondo cui la serie non è stazionaria. Se il valore risultante dal test, chiamato *p-value*, è molto basso (inferiore convenzionalmente a 0.05), si può scartare l'ipotesi di partenza e considerare la serie stazionaria. I risultati sulla serie originale sono riportati nella Tabella 14.

Metrica	**Valore (Serie Originale)**
Test Statistic	-3.123156
p-value	0.024886
Critical Value (1%)	-3.464161
Critical Value (5%)	-2.876402
Critical Value (10%)	-2.574692

Tabella 14: Risultati Test ADF sulla serie originale del Volume Mensile.

Il test ha restituito un *p-value* pari a **0.0249**. Essendo questo valore inferiore alla soglia critica del 5% (0.05), si potrebbe tecnicamente considerare la serie già stazionaria. Tuttavia, un'analisi più approfondita dei grafici ha mostrato che persistevano ancora tracce di stagionalità e un leggero trend residuo che avrebbero potuto condizionare le previsioni. Per garantire la massima robustezza del modello, si è deciso di procedere comunque a una differenziazione della serie.

Ripetendo il test sulla serie trasformata (Tabella 15), si ottiene un risultato molto più netto.

Metrica	**Valore (Serie Differenziata Finale)**
Test Statistic	-3.503321
p-value	0.007902
Critical Value (1%)	-3.464161
Critical Value (5%)	-2.876402
Critical Value (10%)	-2.574692

Tabella 15: Risultati Test ADF sulla serie differenziata.

Il nuovo *p-value* scende a **0.0079**, confermando in modo inequivocabile che la serie differenziata è stazionaria e idonea per la modellazione.

7.4.4 Identificazione e Selezione del Modello (Auto-ARIMA)

La fase successiva riguarda la scelta dei parametri che definiscono la struttura del modello. Per orientarsi in questa scelta, sono stati inizialmente analizzati i grafici di Autocorrelazione (ACF) e Autocorrelazione Parziale (PACF), visibili in Figura 49. Questi grafici mostrano quanto il volume di un mese è influenzato dai volumi dei mesi precedenti.

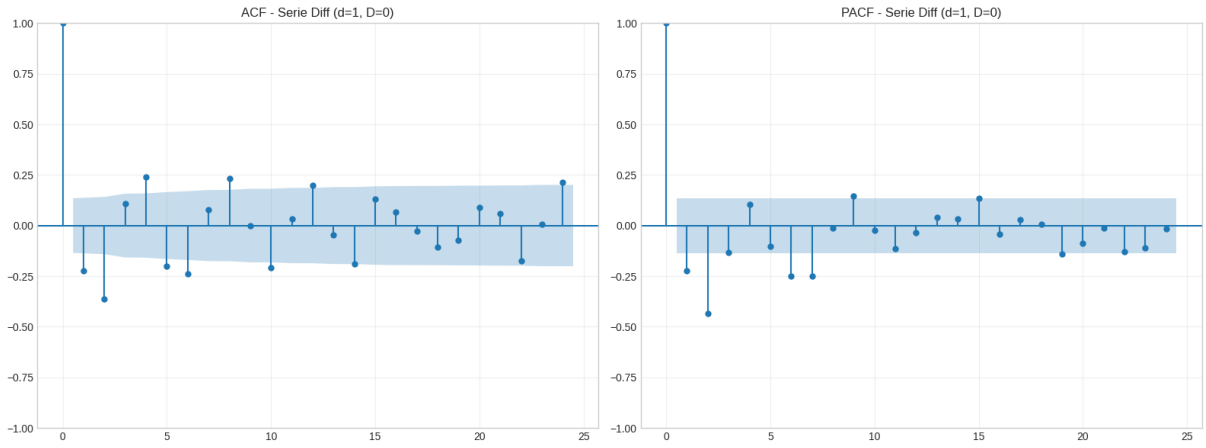


Figura 49: Autocorrelazione (ACF) e Autocorrelazione Parziale (PACF) del Volume.

Per individuare la configurazione matematicamente ottimale, è stato utilizzato l'algoritmo **Auto-ARIMA**, che testa diverse combinazioni di parametri minimizzando l'**AIC (Akaike Information Criterion)**. Al termine della procedura di ottimizzazione, il modello selezionato è risultato essere il:

SARIMAX(1, 1, 1) x (1, 0, 2, 12)

I parametri sono così ripartiti:

- **Componente Non Stagionale (1, 1, 1):** Si utilizza una differenziazione ($d = 1$) per rimuovere il trend residuo. I termini $p = 1$ e $q = 1$ indicano che il volume corrente dipende sia dal valore del mese precedente (AR) sia dall'errore di previsione recente (MA).
- **Componente Stagionale (1, 0, 2, 12):** La periodicità $s = 12$ riflette il ciclo annuale dei dati mensili. Il modello impiega un termine autoregressivo stagionale ($P = 1$) e due termini di media mobile stagionale ($Q = 2$) per catturare le ricorrenze annuali, senza necessitare di ulteriore differenziazione ($D = 0$).

Il sommario statistico completo è riportato in Figura 50.

```
==========================================================================================
Dep. Variable:                                    y   No. Observations:                169
Model:            SARIMAX(1, 1, 1)x(1, 0, [1, 2], 12)   Log Likelihood           -2752.590
Date:                                Wed, 07 Jan 2026   AIC                        5517.179
Time:                                        23:15:53   BIC                        5535.923
Sample:                                  08-31-2004   HQIC                       5524.786
                                       - 08-31-2018
Covariance Type:                               opg
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
ar.L1          0.5236      0.073      7.189      0.000       0.381       0.666
ma.L1         -0.9002      0.042    -21.324      0.000      -0.983      -0.817
ar.S.L12       0.6707      0.107      6.262      0.000       0.461       0.881
ma.S.L12      -0.7504      0.132     -5.688      0.000      -1.009      -0.492
ma.S.L24       0.5052      0.078      6.455      0.000       0.352       0.659
sigma2      1.008e+13   1.08e-14   9.29e+26      0.000    1.01e+13    1.01e+13
==========================================================================================
Ljung-Box (L1) (Q):                   0.00   Jarque-Bera (JB):               252.22
Prob(Q):                              0.95   Prob(JB):                         0.00
Heteroskedasticity (H):               0.02   Skew:                             0.89
Prob(H) (two-sided):                  0.00   Kurtosis:                         8.73
==========================================================================================
```

Figura 50: Sommario statistico del modello SARIMAX selezionato.

7.4.5 Valutazione dei Risultati e Metriche

Dopo aver addestrato il modello sui dati passati, è stato testato per prevedere i volumi degli ultimi 43 mesi (Test Set). La Figura 51 mostra il confronto tra ciò che è realmente accaduto (linea verde) e la previsione del modello (linea rossa).

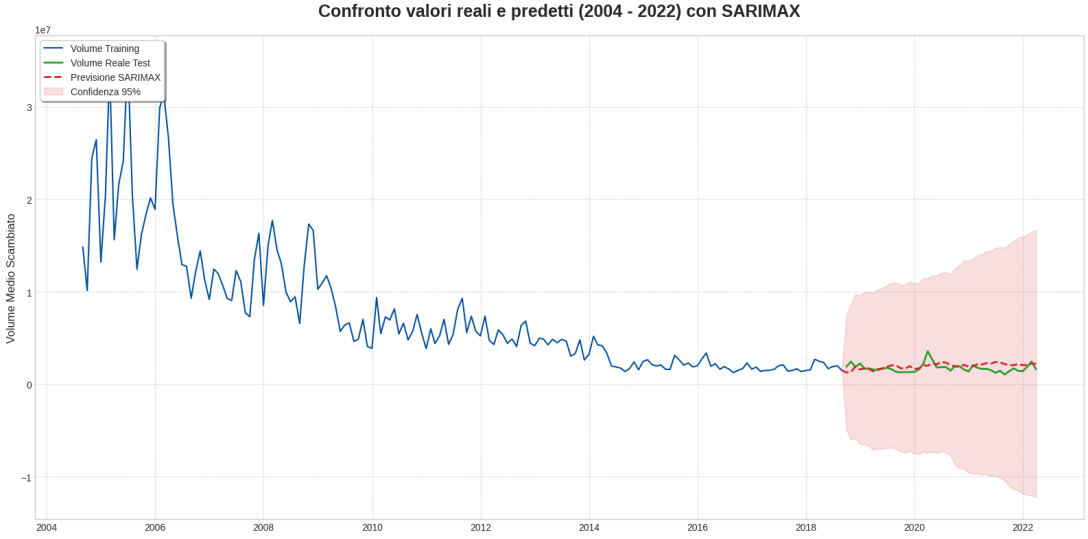


Figura 51: Confronto Volume Reale vs Forecast SARIMAX (Mensile).

Per osservare meglio i dettagli, la Figura 52 propone un ingrandimento dell'ultimo periodo.

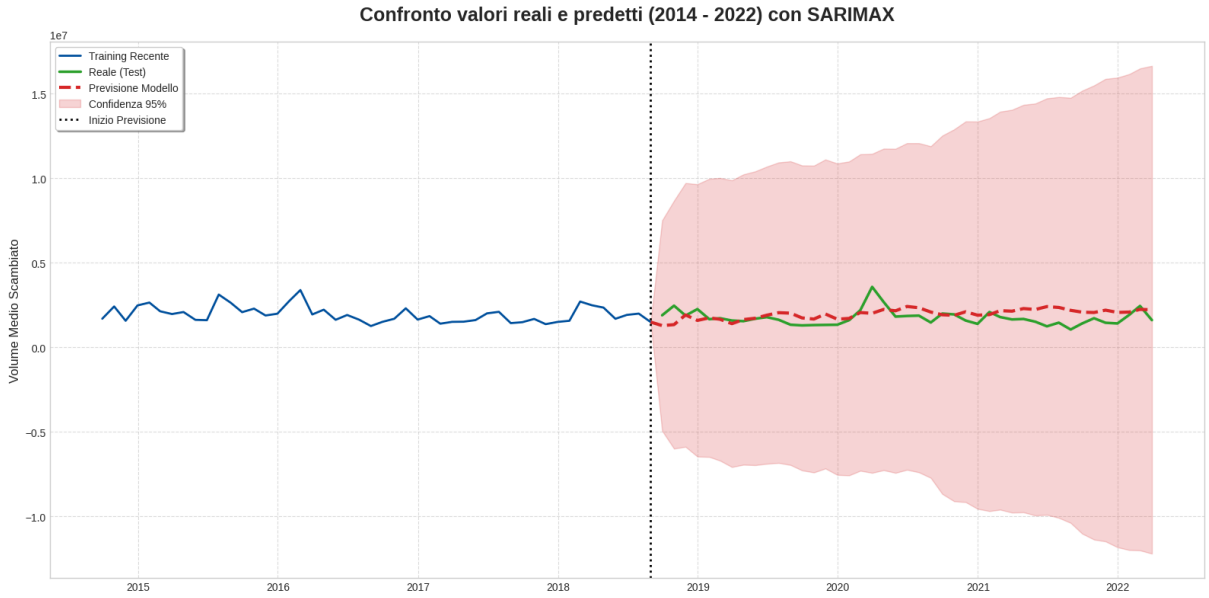


Figura 52: Dettaglio Zoom: Confronto Volume Reale vs Forecast.

Dall'analisi grafica emerge un comportamento interessante: il modello SARIMAX riesce a seguire piuttosto bene il livello medio degli scambi ("baseline") e le oscillazioni stagionali standard. Tuttavia, fatica a prevedere l'esatta altezza dei picchi estremi. Questo è del tutto normale: i picchi di volume sono quasi sempre causati da notizie improvvise o eventi shock che, per definizione, non possono essere previsti guardando solo al passato.

Per quantificare l'errore, sono state calcolate le metriche riportate nella Tabella 16.

Metrica	**Valore**
MAE (Errore Medio Assoluto)	469,935
MSE (Errore Quadratico Medio)	3.40×10^{11}
RMSE (Radice Err. Quadr. Medio)	583,193
MAPE (Err. Percentuale Medio)	29.04%
R^2 (Coefficiente di Determinazione)	-0.7283

Tabella 16: Metriche di performance SARIMAX.

Il **MAE** ci dice che, in media, la previsione sbaglia di circa 470.000 azioni. Considerando che il volume medio mensile è nell'ordine dei milioni, si tratta di un errore significativo ma non eccessivo. Il **MAPE** del **29.04%** indica che l'errore medio relativo è di circa il 30%. In un contesto volatile come quello dei volumi azionari, questo risultato indica che il modello è capace di stimare l'ordine di grandezza dell'attività di scambio, ma non

può essere usato per previsioni puntuali precise. Infine, il valore negativo dell'R^2 conferma che la variabilità dei volumi è talmente alta e influenzata da fattori esterni (notizie, macroeconomia) che un modello puramente statistico fatica a spiegare le fluttuazioni.

7.5 Forecasting della Volatilità IntraDay con Prophet

7.5.1 Introduzione al Modello Prophet

Nel panorama delle tecniche di previsione delle serie storiche, *Prophet* rappresenta un approccio distinto rispetto alla famiglia ARIMA. Sviluppato dal team Core Data Science di Facebook (ora Meta), è un modello basato su un approccio additivo generalizzato (GAM - *Generalized Additive Model*).

A differenza dei modelli autoregressivi che dipendono strettamente dai lag passati, Prophet scompone la serie storica in tre componenti principali secondo l'equazione:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

dove:

- $g(t)$ rappresenta il **trend** (non periodico), modellato come una crescita logistica o lineare a tratti.
- $s(t)$ rappresenta la **stagionalità** (periodica), modellata tramite serie di Fourier per catturare cicli settimanali e annuali.
- $h(t)$ rappresenta l'effetto delle **festività** (holidays), che nel contesto finanziario corrispondono spesso a giorni di chiusura o di attività ridotta.
- ϵ_t è il termine di errore.

Questo approccio rende Prophet particolarmente robusto nei confronti di dati mancanti e outlier, oltre a essere flessibile nell'adattarsi a cambiamenti strutturali del trend.

7.5.2 Selezione dei Dati e Definizione del Target

Per questa specifica analisi, l'obiettivo si è spostato nella previsione della *volatilità intraday*. La variabile target, definita come *Range*, è stata calcolata come differenza tra il prezzo massimo e il prezzo minimo di giornata:

$$Range_t = High_t - Low_t$$

Prevedere la volatilità intraday è cruciale per la gestione del rischio, in quanto fornisce una stima dell'escursione attesa del prezzo.

È stato utilizzato l'intero dataset disponibile, che copre il periodo dal 2004 al 2022. Data l'ampiezza dell'orizzonte temporale e la natura casuale della volatilità, il dataset è stato suddiviso in:

- **Training Set:** 3544 giorni (80% del dataset), utilizzati per l'addestramento.
- **Test Set:** 887 giorni (20% del dataset), utilizzati per la validazione.

7.5.3 Analisi Preliminare e Decomposizione (STL)

Prima di passare l'addestramento del modello, la serie storica della volatilità giornaliera (Range) è stata scomposta nelle sue parti fondamentali. Questo passaggio serve a capire quali elementi compongono la serie che osserviamo.

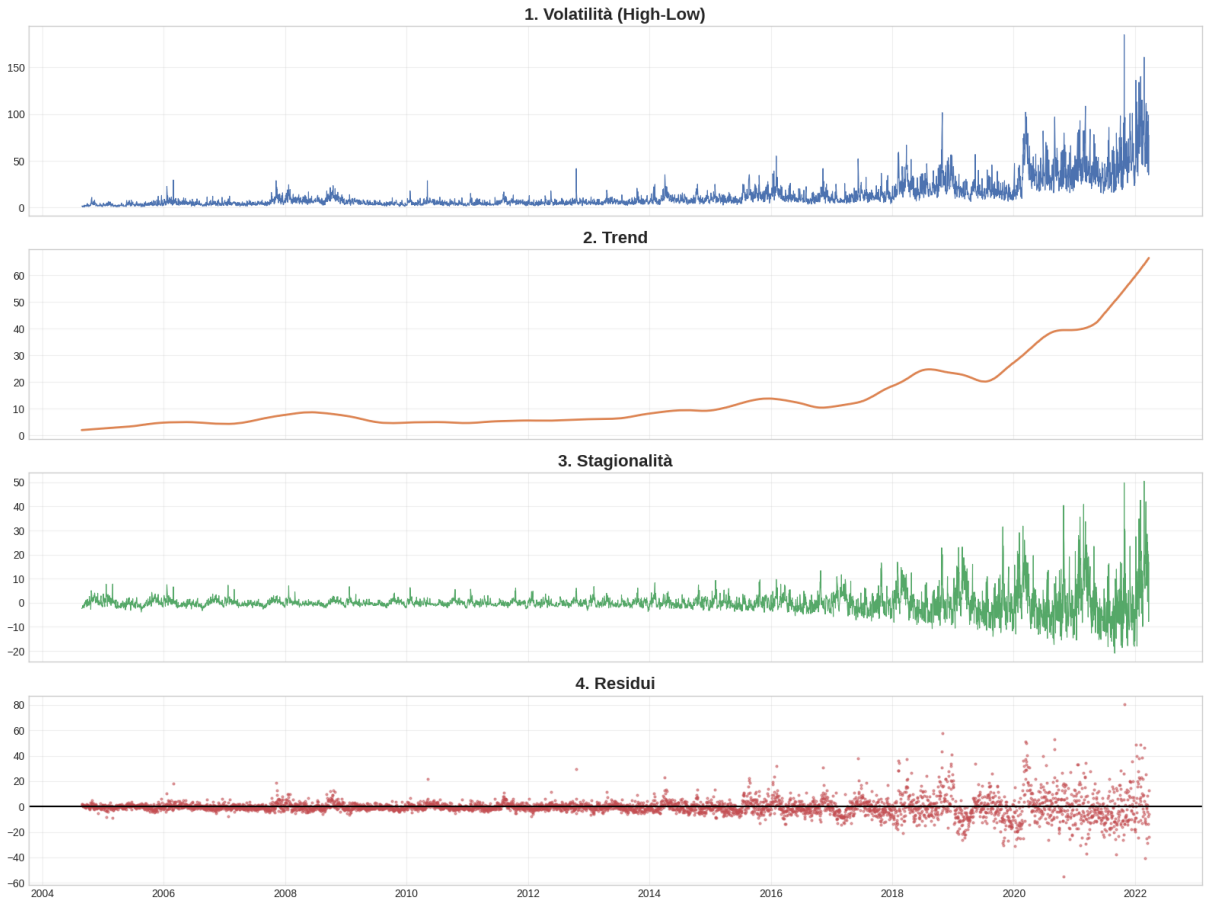


Figura 53: Decomposizione STL del Range: Volatilità osservata, Trend, Stagionalità e Residui.

Osservando la Figura 53, si possono notare i seguenti aspetti:

- **Volatilità Osservata:** Il grafico in alto mostra i dati reali. Si vede chiaramente che l'instabilità non è costante: ci sono periodi di relativa calma alternati a momenti più dinamici.
- **Trend:** La linea del trend mostra una crescita nel tempo. Questo è un fenomeno naturale legato al valore dell'azione: quando il prezzo di Google era basso (es. 100

dollari), le oscillazioni giornaliere erano di pochi dollari. Ora che il prezzo è alto (es. 2000 dollari), anche una piccola variazione percentuale corrisponde a molti dollari di differenza. Quindi, più sale il prezzo dell'azione, più ampia diventa l'oscillazione nominale.

- **Stagionalità:** Anche se meno evidente rispetto ad altri dati, si intravedono dei comportamenti che si ripetono ciclicamente. Questo suggerisce che, in certi momenti dell'anno, il titolo tende a essere sistematicamente più instabile rispetto ad altri.

- **Residui:** L'ultimo grafico mostra ciò che rimane togliendo il trend e la stagionalità. Rappresenta la parte totalmente imprevedibile. È importante notare i picchi molto alti: indicano che parte della volatilità è causata da notizie improvvise o eventi esterni che nessun modello matematico basato solo sul passato può prevedere con certezza.

Per capire meglio in quali momenti dell'anno il rischio è maggiore, è stato analizzato il grafico medio mensile (Figura 54).

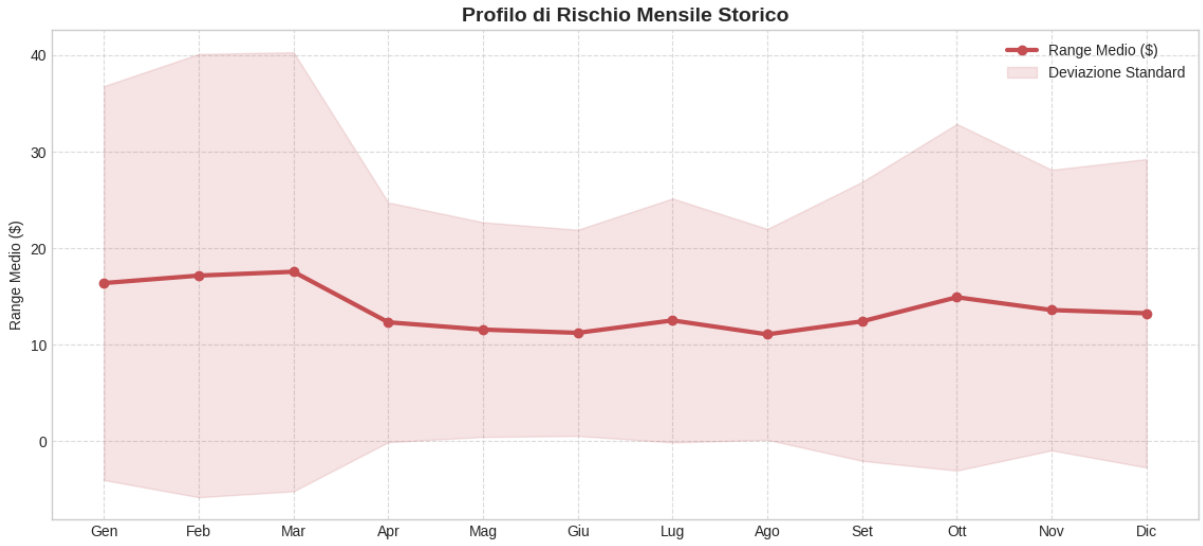


Figura 54: Profilo di rischio mensile: Media e Deviazione Standard del Range.

Il grafico mostra come l'ampiezza delle oscillazioni cambi durante i vari mesi. Si nota che il rischio non è uguale tutto l'anno: ci sono mesi in cui il titolo tende a muoversi molto di più (probabilmente legati all'uscita dei risultati finanziari o a periodi storicamente instabili) e mesi più tranquilli.

7.5.4 Configurazione del Modello e Componenti

Il modello Prophet è stato configurato attivando le stagionalità settimanale e annuale, e integrando il calendario delle festività statunitensi (*US Holidays*), poiché i giorni vicini alle festività hanno spesso volumi di scambio ridotti.

La Figura 55 mostra nel dettaglio come il modello ha appreso a scomporre il segnale.

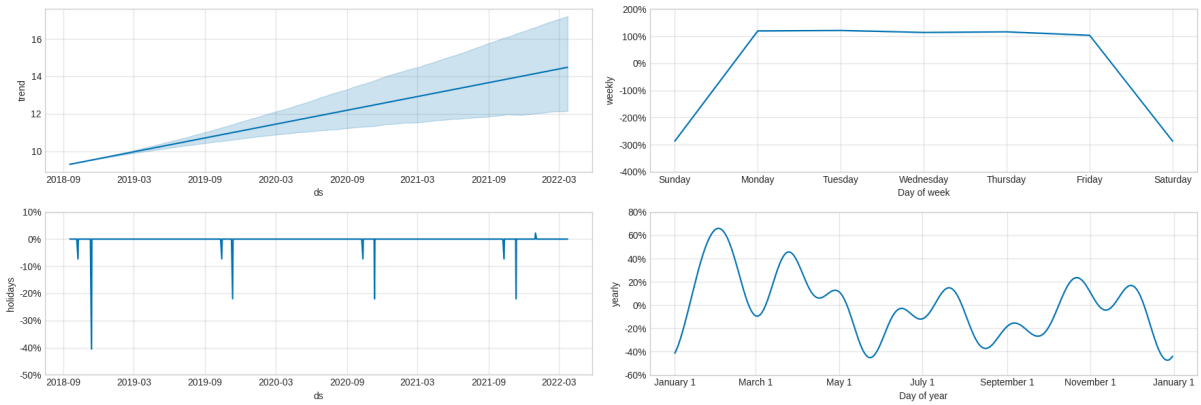


Figura 55: Componenti del modello Prophet: Trend, Festività e Stagionalità.

Analizzando i riquadri dell'immagine:

- **Trend:** Il modello ha identificato una crescita costante della volatilità di base nel corso degli anni, coerente con l'aumento del valore del titolo.
- **Holidays:** Si nota l'impatto delle festività. I picchi verso il basso indicano che, in quei giorni, l'oscillazione dei prezzi tende a ridursi drasticamente (il mercato è più "fermo").
- **Weekly:** Viene mostrato il pattern settimanale. Si osserva come la volatilità tenda ad essere leggermente superiore in alcuni giorni della settimana rispetto ad altri, fornendo indicazioni su quando il mercato è più attivo.
- **Yearly:** Rappresenta la stagionalità annuale. Il grafico mostra in quali mesi dell'anno, statisticamente, il titolo Google tende a essere più nervoso (picchi alti) o più tranquillo, permettendo di identificare ricorrenze stagionali nel rischio.

7.5.5 Valutazione dei Risultati

Il modello è stato utilizzato per generare previsioni sugli 887 giorni del Test Set. La Figura 56 mette a confronto il range reale con quello stimato.

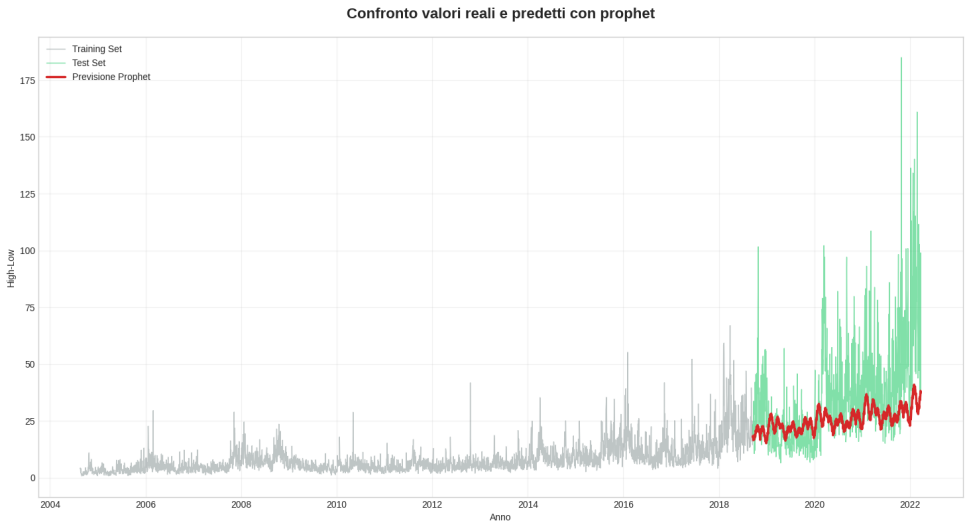


Figura 56: Confronto Range Reale vs Previsione Prophet

Osservando il grafico completo, il modello riesce a stimare correttamente il livello medio di rischio atteso per il periodo. Tuttavia, è evidente che non riesce a replicare i picchi estremi (le linee verdi che schizzano verso l'alto), che rappresentano i giorni di crisi o panico sui mercati.

Per un'analisi più dettagliata, la Figura 57 propone uno zoom sulla porzione del periodo di test.

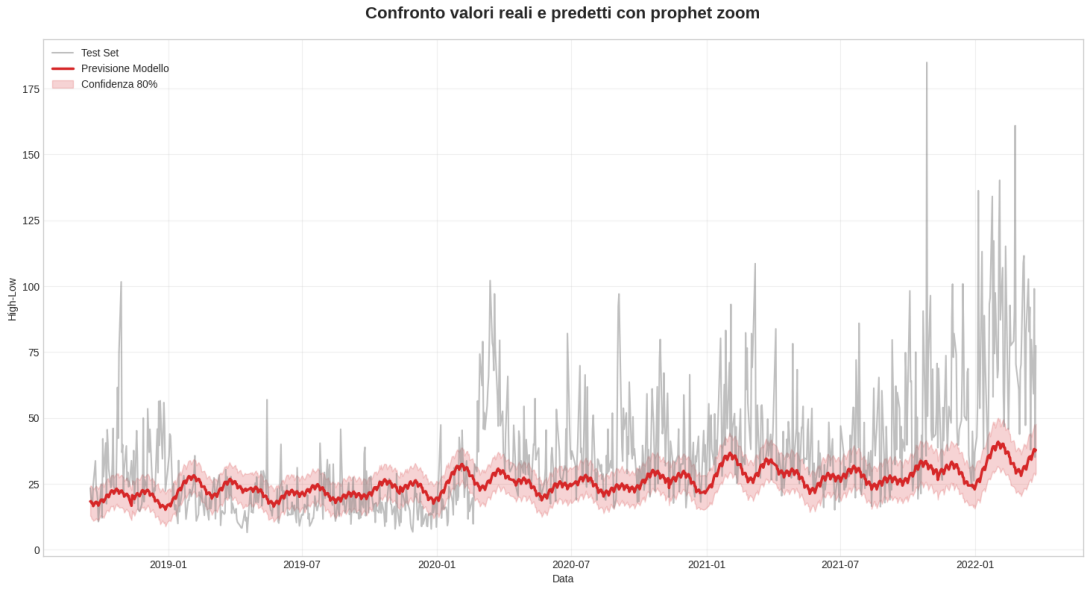


Figura 57: Dettaglio Zoom: La previsione (linea rossa) vs Realtà (linea grigia).

La Figura 57 evidenzia chiaramente il limite principale di questo approccio. La linea rossa della previsione appare molto regolare, seguendo un andamento dolce dettato dalla stagionalità. Al contrario, la linea grigia dei dati reali è estremamente frastagliata e nervosa. Prophet, per sua natura, tende a prevedere il comportamento medio, ma fallisce nel prevedere gli eventi improvvisi. Mentre il modello suggerisce un'oscillazione costante, la realtà mostra giorni di calma alternati a giorni di esplosione della volatilità. Questo conferma che Prophet è ottimo per identificare il trend generale, ma non è lo strumento ideale per prevedere gli shock di mercato giornalieri.

7.5.6 Diagnostica e Metriche di Performance

Per validare la robustezza statistica del modello, è stata condotta un'analisi approfondita sui residui (ovvero la differenza tra il valore reale e quello previsto). La Figura 58 presenta un pannello diagnostico composto da quattro grafici fondamentali.

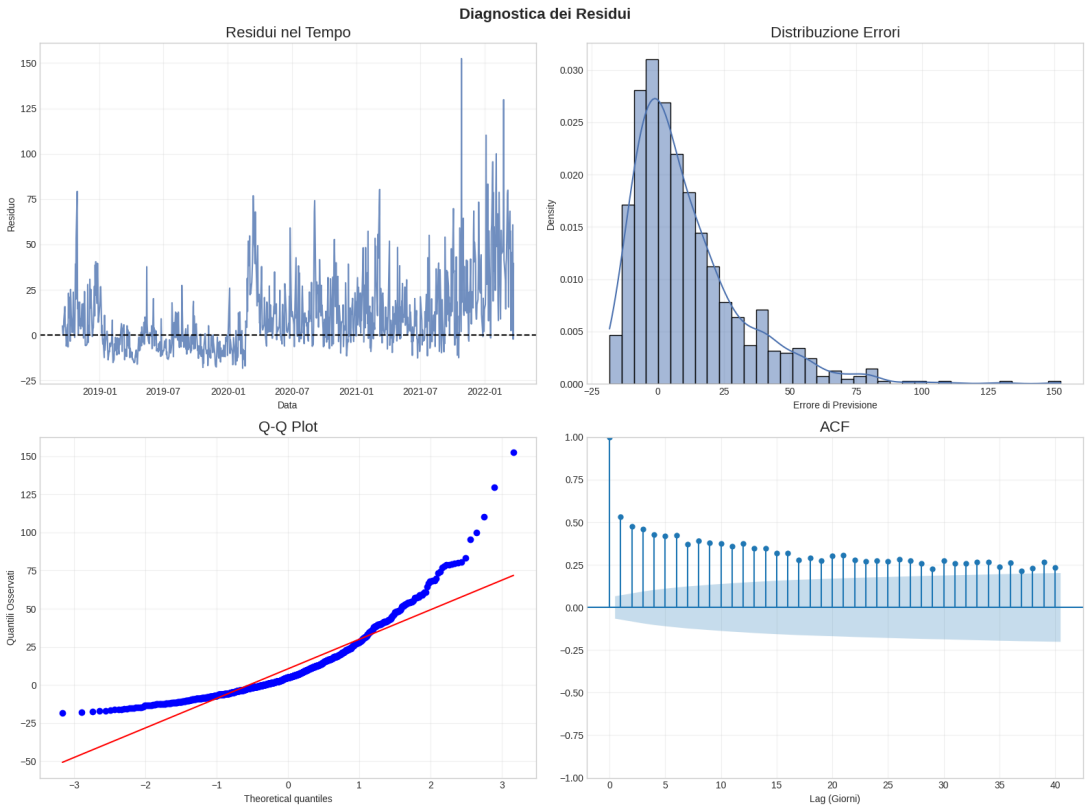


Figura 58: Diagnostica dei Residui: Analisi temporale, distribuzione, Q-Q Plot e Autocorrelazione

Analizzando i riquadri della figura in senso orario:

- **Residui nel Tempo (in alto a sinistra):** I residui dovrebbero idealmente oscillare in modo casuale attorno allo zero (la linea tratteggiata) con un'ampiezza costante.

Invece, si nota chiaramente che l'ampiezza degli errori aumenta drasticamente in certi periodi. Questo indica che il modello commette errori molto più grandi quando il mercato è agitato.

- **Distribuzione degli Errori (in alto a destra):** L'istogramma mostra la frequenza degli errori. La curva ideale dovrebbe essere una campana perfetta (distribuzione Normale). Si osserva invece una "coda lunga" verso destra: ciò significa che il modello tende a sottostimare i picchi di volatilità, generando errori positivi molto elevati più spesso di quanto previsto dalla teoria statistica.

- **Autocorrelazione - ACF (in basso a destra):** Questo grafico verifica se l'errore di oggi è collegato all'errore di ieri. La presenza di barre che escono dall'area ombreggiata indica che c'è ancora informazione nei dati che il modello non ha catturato.

- **Q-Q Plot (in basso a sinistra):** Confronta la distribuzione degli errori con una distribuzione normale teorica (linea rossa). I punti blu si discostano marcatamente dalla linea rossa agli estremi, confermando che gli eventi estremi non sono modellati correttamente.

Le metriche quantitative, calcolate sul set di test, sono riassunte nella Tabella 17.

Metrica	**Valore**
MAE (Errore Medio Assoluto)	15.34
MSE (Errore Quadratico Medio)	547.14
RMSE (Radice Err. Quadr. Medio)	23.39
MAPE (Err. Percentuale Medio)	40.26%
R^2 (Coefficiente di Determinazione)	-0.0414

Tabella 17: Metriche di performance Prophet

L'interpretazione dei risultati evidenzia i limiti dell'approccio per questo specifico problema:

- Il **MAE** di 15.34 indica che, in media, la previsione del range giornaliero sbaglia di circa 15 dollari.

- Il **MAPE** del **40.26%** è un valore elevato. Significa che l'errore relativo è consistente: prevedere l'esatta escursione di prezzo di una singola giornata è un compito estremamente difficile per un modello basato su trend e stagionalità.

Questo risultato era prevedibile piochè Prophet è progettato per serie con trend forti e stagionalità chiare (come le vendite natalizie o il traffico web). La volatilità finanziaria, invece, è un fenomeno tende a tornare alla media, ma soggetto a crescite improvvise di varianza che dipendono da fattori esterni , rendendola intrinsecamente ostica per i modelli additivi standard.