Università Politecnica delle Marche

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione



Applicazione di tecniche NLP sul dataset "Women's Clothing E-Commerce Reviews"

DATA SCIENCE

Diocis Calero Daniel
Ricci Ettore
Salvatore Pietro
Sebastianelli Nicola

Anno accademico: 2025–2026

Indice

1 Introduzione al progetto **3**

2 Il Dataset e il Pre-processing **4**

2.1 Caratteristiche del dataset 4

2.2 Descrizione Tecnica del Dataset 4

2.3 Pre-processing del testo 5

3 Analisi Descrittiva ed Esplorativa **6**

3.1 Distribuzione delle variabili e profilo utente 6

3.2 Lunghezza dei testi in base al rating 8

3.3 WordCloud: Visualizzazione dei termini frequenti 8

4 Information Extraction **11**

4.1 Strumenti Tecnici e Metodologia 11

4.2 Analisi dei Bi-grammi 11

4.3 Estrazione degli Aspetti e degli Aggettivi 12

4.4 Analisi della Soggettività e delle Emozioni 13

5 Text Classification: Previsione della Raccomandazione e del Rating **15**

5.1 Metodologia di Validazione e Rappresentazione del Testo 15

5.2 Classificazione Binaria con FastText: Previsione della Raccomandazione . . 15

5.2.1 Bilanciamento e Preprocessing 15

5.2.2 Configurazione del Modello 16

5.2.3 Risultati e Analisi della Matrice di Confusione 16

5.3 Classificazione Multi-classe con Logistic Regression: Previsione del Rating 18

5.3.1 Metodologia e Gestione dello Sbilanciamento dei Dati 18

5.3.2 Risultati e Analisi delle Metriche 18

5.3.3 Analisi della Matrice di Confusione 19

Elenco delle figure

1 Distribuzione dei rating (sinistra) e delle recensioni per dipartimento (destra). 6
2 Distribuzione dell'età delle clienti e incrocio con la raccomandazione del prodotto. 7
3 Le 15 classi di abbigliamento con il rating medio più alto 7
4 Le 5 classi di abbigliamento con il rating medio più basso. 8
5 Boxplot della lunghezza delle recensioni suddivise per rating. 8
6 WordCloud per le recensioni a 5 stelle. 9
7 WordCloud per le recensioni a 1 stella. 10
8 Distribuzione dei 20 bi-grammi più frequenti 12
9 I 20 aspetti (sostantivi) più estratti tramite l'analisi grammaticale spaCy. . 12
10 Distribuzione dei 20 aggettivi più ricorrenti per qualificare i prodotti. . . . 13
11 Le 20 parole legate alla soggettività più frequenti all'interno del dataset. . . 13
12 Matrice di confusione Previsione della Raccomandazione con FastText . . . 17
13 Matrice di confusione multi-classe con Logistic Regression 19

1 Introduzione al progetto

Il Natural Language Processing (NLP) sta diventando sempre più importante per analizzare grandi quantità di testi. In questo progetto si sono applicate diverse tecniche di NLP per analizzare le recensioni scritte dalle clienti di un e-commerce di abbigliamento femminile. L'idea alla base è capire cosa pensano le clienti dei capi acquistati e cercare di automatizzare l'analisi dei loro feedback.

I task principali affrontati nel progetto sono i seguenti:

- **Analisi Esplorativa (EDA) e WordCloud**: studio preliminare delle distribuzioni statistiche delle variabili e generazione di nuvole di parole per identificare visivamente i termini più ricorrenti nei testi positivi e negativi.

- **Information Extraction**: applicazione di tecniche di Part-of-Speech (POS) tagging per isolare gli aspetti specifici dei prodotti e gli aggettivi utilizzati dalle clienti per descriverli. In questa fase è stata condotta anche l'analisi dei bi-grammi per identificare le combinazioni di due parole più frequenti.

- **Text Classification**: addestramento di modelli per l'assegnazione automatica di etichette. Nello specifico, è stata implementata una classificazione binaria per prevedere se un prodotto verrà raccomandato (tramite FastText) e una classificazione multi-classe per stimare il rating numerico da 1 a 5 stelle (tramite Logistic Regression).

2 Il Dataset e il Pre-processing

2.1 Caratteristiche del dataset

Si è scelto di utilizzare il dataset "Women's E-Commerce Clothing Reviews". Questo dataset contiene recensioni reali lasciate da donne che hanno comprato vestiti online. Le colonne principali prese in esame sono *Review Text* (il testo della recensione), *Rating* (il voto da 1 a 5), *Recommended IND* (se la cliente consiglia il prodotto o no), oltre a informazioni aggiuntive come l'età e il reparto o la classe del vestito.

2.2 Descrizione Tecnica del Dataset

Il dataset utilizzato è composto da 23.486 osservazioni e 10 variabili. Per comprendere appieno le informazioni a disposizione, si sono suddivise le colonne in base alla loro tipologia:

- **Dati Identificativi e Demografici**:
  - *Clothing ID*: codice numerico intero e univoco che identifica il singolo capo di abbigliamento recensito.
  - *Age*: età della cliente che ha effettuato l'acquisto e scritto la recensione.
- **Dati Testuali (Focus dell'analisi NLP)**:
  - *Title*: breve titolo riassuntivo assegnato dalla cliente alla propria recensione.
  - *Review Text*: il corpo effettivo della recensione, contenente il testo in linguaggio naturale. Questa colonna rappresenta la base su cui si fondano le successive fasi di pulizia, sentiment analysis ed estrazione delle informazioni.
- **Dati di Target e Quantitativi**:
  - *Rating*: punteggio ordinale assegnato al prodotto, espresso su una scala da 1 (pessimo) a 5 (eccellente). Costituisce la variabile target per la classificazione multi-classe.
  - *Recommended IND*: variabile binaria che assume valore 1 se la cliente raccomanda l'acquisto ad altri utenti, e 0 in caso contrario. Costituisce la variabile target per la classificazione binaria.
  - *Positive Feedback Count*: numero intero che indica quanti altri utenti della piattaforma hanno trovato utile o positiva la recensione in questione.
- **Dati Categoriali Merceologici**:

- *Division Name*: macro-categoria del prodotto (ad esempio, divisione generale o taglie forti/petite).
- *Department Name*: reparto di appartenenza del capo (ad esempio, "Tops", "Dresses", "Bottoms").
- *Class Name*: classe merceologica specifica e più granulare per catalogare il vestito (ad esempio, maglieria, camicette, pantaloni).

Dall'analisi preliminare è emerso che il dataset presenta alcuni valori nulli, concentrati principalmente nelle colonne testuali (*Title* e *Review Text*). Questi valori mancanti sono stati gestiti durante la fase di preprocessing, eliminando le righe prive di testo per non compromettere l'addestramento dei successivi modelli.

2.3 Pre-processing del testo

I testi originali contengono rumore e non possono essere dati in pasto agli algoritmi così come sono. Quindi si è proceduto con una fase di pulizia usando le librerie pandas, re (per le espressioni regolari) e NLTK. Nello specifico si è provveduto a:

1. Rimuovere tutta la punteggiatura e i numeri, e convertire tutto il testo in minuscolo (lowercasing).
2. Togliere le *stop words*, cioè quelle parole comuni in inglese come articoli e preposizioni che non aggiungono un vero significato alla frase.
3. Applicare la lemmatizzazione (con *WordNetLemmatizer*) per riportare le parole alla loro forma base, ad esempio trasformando i plurali in singolari.

Tutto il testo processato è stato poi salvato in una nuova colonna chiamata `Cleaned_Review`.

3 Analisi Descrittiva ed Esplorativa

Prima di applicare algoritmi di information extraction e classificazione, si è condotta un'analisi esplorativa (EDA) per esaminare la distribuzione dei dati, comprendere il profilo delle clienti e analizzare visivamente il testo delle recensioni.

3.1 Distribuzione delle variabili e profilo utente

Si è partiti dall'osservazione delle variabili principali tramite l'uso di grafici a barre. Come visibile dalla Figura 1, la distribuzione del *Rating* mostra un evidente sbilanciamento, le valutazioni a 4 e 5 stelle costituiscono la stragrande maggioranza del dataset, indicando una base di acquirenti globalmente molto soddisfatta. Accanto alla distribuzione del rating, la distribuzione per *Department Name* evidenzia che i reparti relativi a "Tops" (maglie, camicie) e "Dresses" (vestiti) sono quelli che ricevono il maggior volume di recensioni in assoluto.

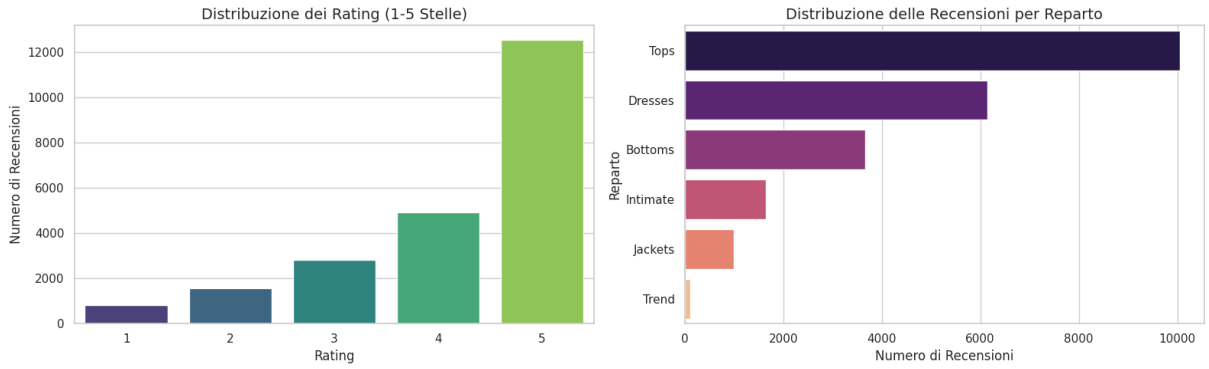


Figura 1: Distribuzione dei rating (sinistra) e delle recensioni per dipartimento (destra).

Successivamente, si è analizzato il profilo demografico delle acquirenti (Figura 2). La distribuzione dell'età si concentra prevalentemente nella fascia tra i 30 e i 50 anni. Incrociando l'età con la variabile *Recommended IND* (che indica se il capo è stato consigliato o meno), si nota che la tendenza a raccomandare positivamente un prodotto rimane proporzionalmente costante in quasi tutte le fasce d'età, senza subire scostamenti drastici.

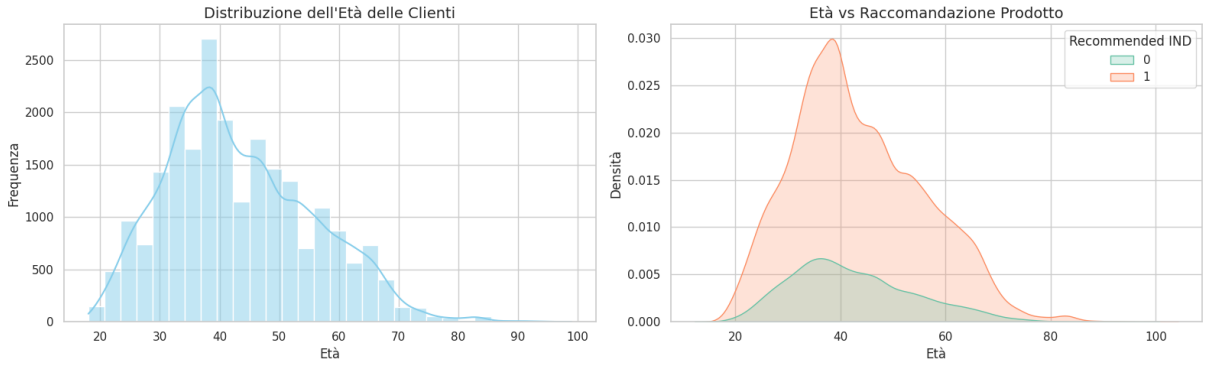


Figura 2: Distribuzione dell'età delle clienti e incrocio con la raccomandazione del prodotto.

Per scendere ancora più nel dettaglio, si è analizzato il livello di soddisfazione per singola categoria, estraendo la classifica delle 15 classi di abbigliamento con il rating medio più elevato (Figura 3). Osservando il grafico, si nota che le migliori classi siano Layering e Jeans e raggiungono punteggi medi molto buoni, con una recensione media che si attesta indicativamente di poco superiorire a 4.3 stelle su 5. Questa analisi permette di evidenziare quali tipologie di capi risultano qualitativamente più apprezzate dalle clienti, focalizzandosi sulla media dei voti ricevuti anziché sul semplice volume totale delle recensioni.

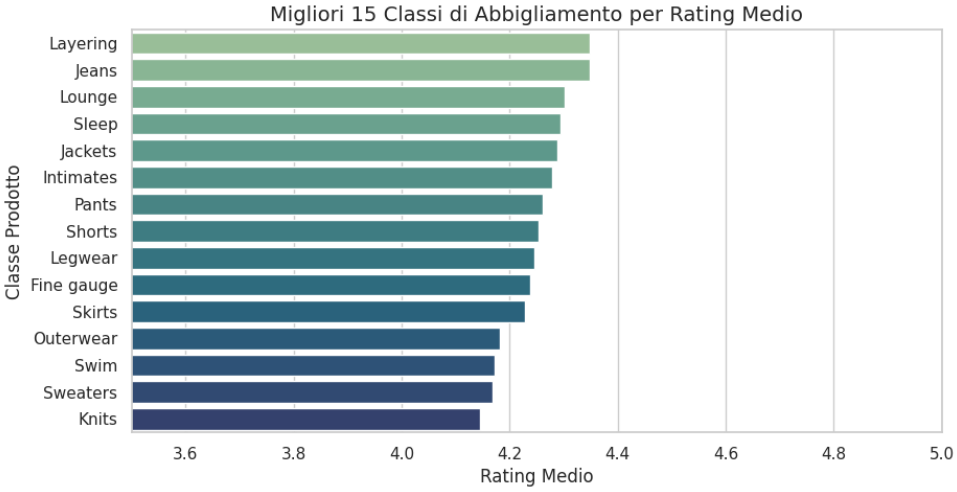


Figura 3: Le 15 classi di abbigliamento con il rating medio più alto

Di contro, per avere un quadro completo delle criticità, si è estratta anche la classifica delle 5 classi di abbigliamento con il rating medio più basso (Figura 4). Questo permette di individuare rapidamente le categorie di capi che generano maggiore insoddisfazione tra le acquirenti, evidenziando le aree del catalogo in cui potrebbe essere necessario un intervento per migliorare la qualità dei prodotti.

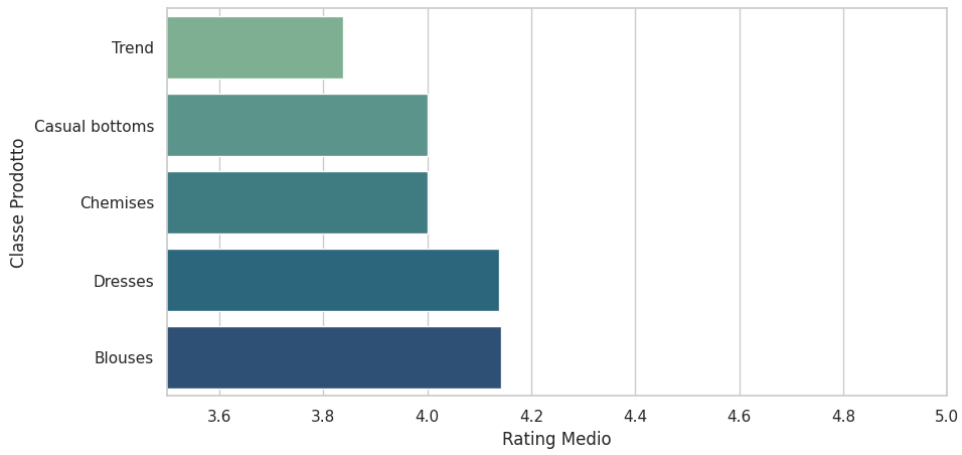


Figura 4: Le 5 classi di abbigliamento con il rating medio più basso.

3.2 Lunghezza dei testi in base al rating

Un altro aspetto interessante riguarda la potenziale relazione tra la lunghezza del testo scritto e il voto assegnato. Utilizzando un grafico boxplot riportato in Figura 5, si è analizzato il *Rating* con il conteggio delle parole (*Review Word Count*). Si osserva che le recensioni presentano una mediana e una distribuzione simili tra i vari rating. L'unica piccola differenza è che le recensioni a 1 stella e 5 stelle presentano una mediano leggermente inferiore.

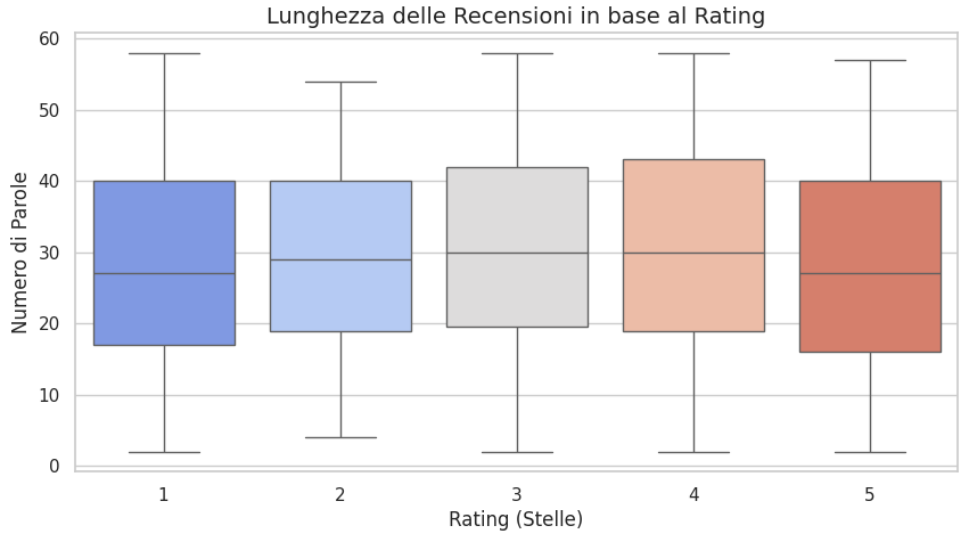


Figura 5: Boxplot della lunghezza delle recensioni suddivise per rating.

3.3 WordCloud: Visualizzazione dei termini frequenti

Per ottenere un riscontro immediato e intuitivo sul lessico utilizzato dalle clienti, si è applicata la tecnica visiva della **WordCloud** (nuvola di parole). I testi, precedentemente

ripuliti dalle stop-words, sono stati filtrati per isolare le recensioni eccellenti e confrontarle con quelle fortemente negative.

Osservando la WordCloud delle recensioni a 5 stelle (Figura 6), si nota la netta predominanza di termini legati all'estetica, all'apprezzamento per il capo e all'ottima vestibilità. Parole come *love, great, perfect, look, cute* ed *color* assumono dimensioni maggiori, confermando un ampio utilizzo da parte delle acquirenti.



Figura 6: WordCloud per le recensioni a 5 stelle.

Al contrario, nella WordCloud associata alle recensioni a 1 stella (Figura 7) emergere un lessico completamente diverso. Vocaboli come *fabric, size, fit, material, returned, small, huge, look* indicano chiaramente i motivi principali di insoddisfazione, solitamente legati alla scarsa qualità dei materiali, a taglie non conformi alle aspettative o alla necessità di effettuare un reso.



Figura 7: WordCloud per le recensioni a 1 stella.

4 Information Extraction

Prima di passare alla Text Classification che permette di prevedere il giudizio globale di una recensione, per un'analisi più profonda è necessario capire esattamente quali siano i temi discussi e in che modo vengano descritti. Per questo motivo si è proceduto con una fase di Information Extraction isolando elementi specifici dal testo.

4.1 Strumenti Tecnici e Metodologia

L'estrazione delle informazioni è stata realizzata principalmente attraverso la libreria **spaCy**, uno dei framework più utilizzati per il Natural Language Processing in Python. Nello specifico è stato impiegato il modello linguistico **en_core_web_sm**, addestrato per eseguire operazioni di analisi grammaticale complessa.

La tecnica centrale utilizzata è il **Part-Of-Speech (POS) Tagging**. Questa procedura permette di analizzare ogni frase e assegnare a ogni singola parola un'etichetta grammaticale precisa, distinguendo ad esempio i sostantivi dagli aggettivi. Grazie a questo approccio è stato possibile separare le caratteristiche fisiche dei prodotti (i nomi) dai giudizi qualitativi espressi dalle utenti (gli aggettivi), superando i limiti di una semplice conta delle parole più frequenti.

4.2 Analisi dei Bi-grammi

In primo luogo si sono estratte le sequenze di due parole consecutive, note come **bi-grammi**, utilizzando la tecnica del *CountVectorization*. Questa metodologia permette di catturare un contesto semantico più preciso rispetto alla singola parola. Nel grafico dei 20 bi-grammi più frequenti (Figura 8) si osserva come le espressioni più comuni riguardino spesso la vestibilità (come "true size"), l'estetica ("look like") o considerazioni generali sul prodotto.

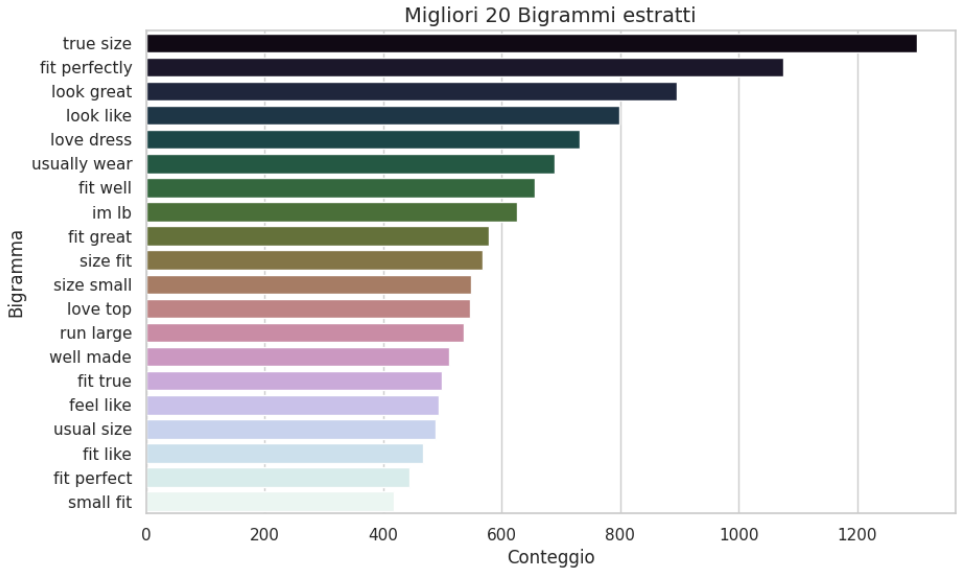


Figura 8: Distribuzione dei 20 bi-grammi più frequenti

4.3 Estrazione degli Aspetti e degli Aggettivi

Successivamente si è sfruttato il POS tagging per classificare grammaticalmente le parole con l'obiettivo di separare i sostantivi dagli aggettivi.

Gli **Aspetti** (Aspects) rappresentano i sostantivi, ovvero le caratteristiche fisiche e tangibili dei capi di abbigliamento. Dalla Figura 9 si nota che i termini più discussi dalle clienti sono "dress", "size", "color", "fabric" e "fit". Si tratta delle metriche fondamentali su cui si basa la valutazione oggettiva di un abito.

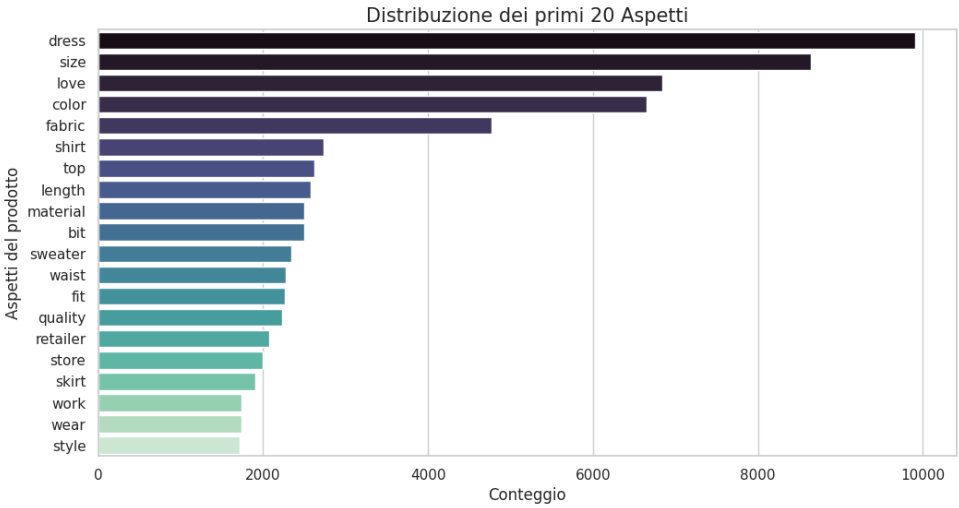


Figura 9: I 20 aspetti (sostantivi) più estratti tramite l'analisi grammaticale spaCy.

Per comprendere in che modo questi aspetti vengano qualificati, si è estratta la lista degli **Aggettivi** (Figura 10). I descrittori più utilizzati confermano un tono generale

positivo e focalizzato sulle dimensioni, con frequenti occorrenze di parole come "great", "small", "large", "perfect" e "beautiful".

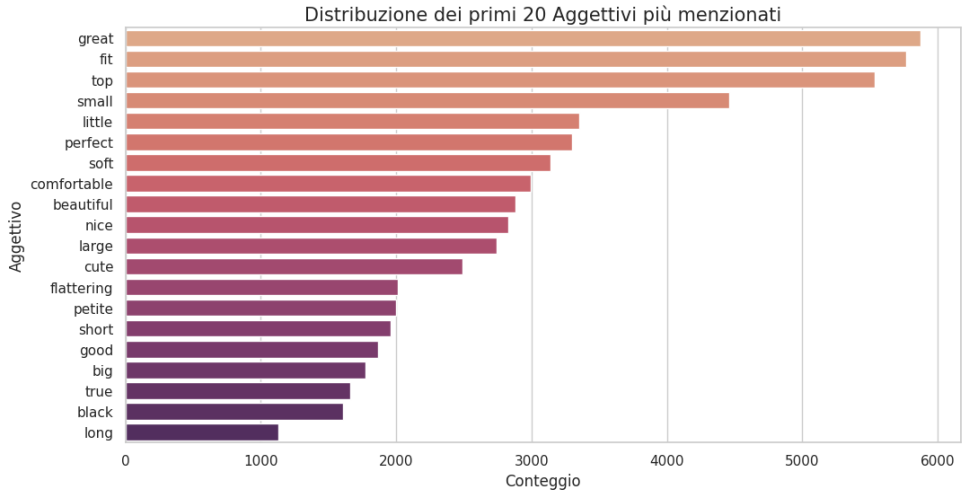


Figura 10: Distribuzione dei 20 aggettivi più ricorrenti per qualificare i prodotti.

4.4 Analisi della Soggettività e delle Emozioni

Infine l'analisi si è focalizzata sulla componente soggettiva dei commenti. Per questo task è stato adottato un approccio basato sul lessico, confrontando le parole delle recensioni con un dizionario predefinito di termini emozionali. Questa estrazione permette di isolare i termini chiave che caratterizzano il sentimento della recensione, come "love", "cute" o "happy" (Figura 11).

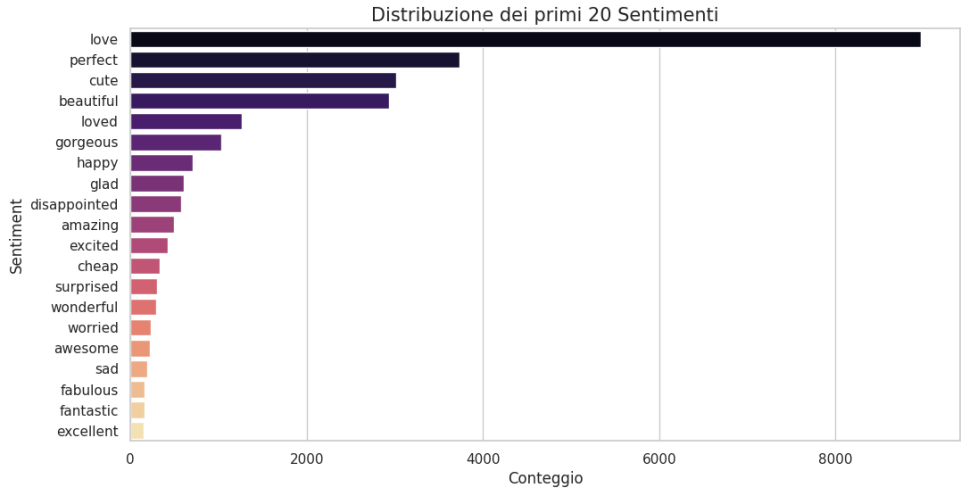


Figura 11: Le 20 parole legate alla soggettività più frequenti all'interno del dataset.

La combinazione di queste estrazioni fornisce un quadro complessivo che può risultare utile anche per le scelte aziendale. Tale approccio permette infatti di automatizzare la

scoperta dei difetti o dei punti di forza di specifiche parti del prodotto, andando ben oltre la semplice classificazione.

5 Text Classification: Previsione della Raccomandazione e del Rating

Il task di text classification ha l'obiettivo di assegnare automaticamente un'etichetta a un testo grezzo. In questo progetto si sono affrontati due approcci differenti: una classificazione binaria tramite FastText per prevedere la raccomandazione del prodotto, e una classificazione multi-classe con Logistic Regression per prevedere il rating esatto.

5.1 Metodologia di Validazione e Rappresentazione del Testo

Prima di procedere con l'addestramento dei modelli, il dataset è stato suddiviso in due set indipendenti: il **Training Set (80%)**, utilizzato per l'apprendimento dei modelli, e il **Test Set (20%)**, mantenuto isolato per la valutazione finale delle performance. Per garantire la riproducibilità dei risultati, è stato impostato un seed di casualità (*random_state = 42*).

Mentre il modello FastText utilizza embedding interni per la gestione del testo, per la Logistic Regression si è optato per la tecnica **TF-IDF** (Term Frequency-Inverse Document Frequency). Questo metodo assegna un peso matematico a ciascuna parola, valorizzando i termini specifici che caratterizzano fortemente una singola recensione e penalizzando quelli troppo comuni e generici nell'intero dataset. Per ottimizzare le prestazioni computazionali e prevenire l'overfitting, il vocabolario è stato limitato alle **5.000 feature (parole)** più rilevanti. Questa scelta ha permesso di catturare la quasi totalità del contenuto informativo escludendo termini comparsi in modo sporadico che non avrebbero aiutato la generalizzazione del modello.

5.2 Classificazione Binaria con FastText: Previsione della Raccomandazione

Il primo modello è stato implementato utilizzando la libreria **FastText**. L'obiettivo è stato distinguere tra recensioni "Positive" (prodotto raccomandato) e "Negative" (non raccomandato).

5.2.1 Bilanciamento e Preprocessing

Dall'analisi esplorativa è emerso un forte sbilanciamento del dataset verso le recensioni positive. Per evitare che il modello ignorasse la classe minoritaria, nel codice è stata applicata una tecnica di **Upsampling** tramite la funzione `resample` di Scikit-Learn. Le recensioni negative nel training set sono state duplicate fino a pareggiare numericamente quelle positive, garantendo un addestramento equo.

5.2.2 Configurazione del Modello

Il classificatore è stato addestrato con parametri specifici per catturare il contesto locale:

- **wordNgrams=3**: il modello non analizza solo parole singole, ma combinazioni di tre parole consecutive (tri-grammi), fondamentale per distinguere espressioni come "not very good".
- **Normalizzazione implicita**: FastText opera una normalizzazione vettoriale interna durante l'addestramento degli embedding, scalando i pesi affinché la lunghezza della recensione non distorca la classificazione.
- **Epochs=25** e **lr=0.5**: un numero elevato di iterazioni con un learning rate di 0.5 scelto per massimizzare la convergenza sui dati bilanciati.

5.2.3 Risultati e Analisi della Matrice di Confusione

I risultati (Tabella 1) mostrano l'efficacia del bilanciamento: il modello ottiene un **Recall del 92%** sulla classe negativa. Questo significa che l'algoritmo è estremamente sensibile nell'individuare i clienti insoddisfatti, sebbene tenda a classificare come negativi anche alcuni feedback incerti (bassa Precision).

Classe	**Precision**	**Recall**	**F1-Score**	**Support**
Negativo	0.47	0.92	0.62	812
Positivo	0.98	0.77	0.86	3717
Accuracy	**0.80**			

Tabella 1: Metriche di classificazione del modello FastText

Questa dinamica è graficamente evidente nella matrice di confusione (Figura 12). Il quadrante relativo ai Veri Negativi (TN, 16.41%) conferma l'ottima capacità del modello di intercettare le recensioni che sconsigliano il prodotto, minimizzando i Falsi Positivi (FP, 1.52%), ovvero le mancate identificazioni di clienti insoddisfatti. Di contro, la quota di Falsi Negativi (FN, 18.61%) mostra l'effetto collaterale dell'upsampling: l'algoritmo, diventato particolarmente sensibile alle critiche, finisce per etichettare come negative anche diverse recensioni formalmente positive ma che contengono espressioni linguistiche ambigue.

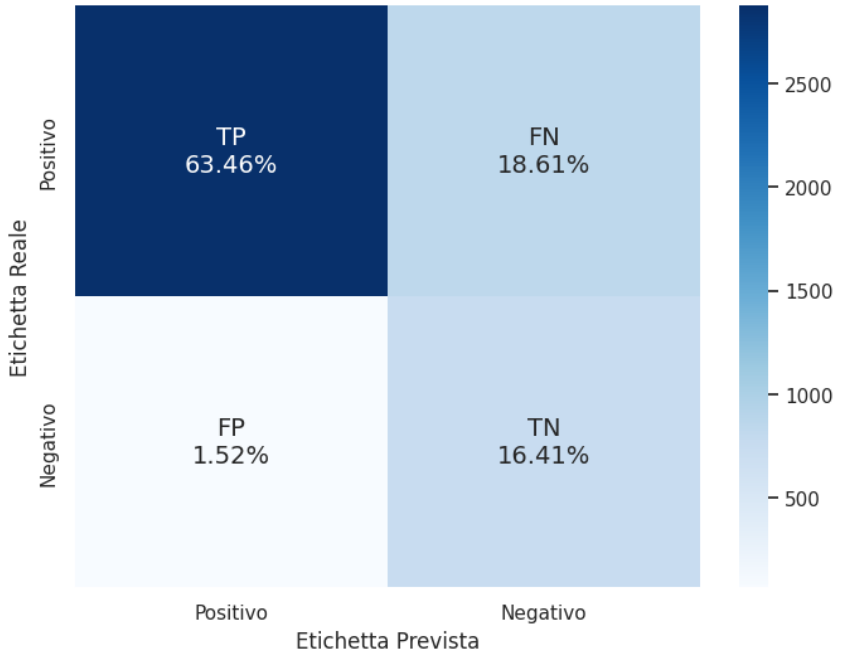


Figura 12: Matrice di confusione Previsione della Raccomandazione con FastText

5.3 Classificazione Multi-classe con Logistic Regression: Previsione del Rating

Il secondo task di classificazione riguarda la previsione del rating su una scala da 1 a 5 stelle. Per questa analisi è stato scelto il modello di **Logistic Regression**, un algoritmo ampiamente utilizzato nel Natural Language Processing per la sua efficacia statistica e la chiarezza nel pesare l'importanza delle parole durante la fase di predizione.

5.3.1 Metodologia e Gestione dello Sbilanciamento dei Dati

Come descritto nella sezione 5.1, i testi sono stati trasformati in vettori numerici tramite TF-IDF con un limite di 5.000 feature.

Il dataset presenta una distribuzione del rating fortemente sbilanciata, la maggioranza delle recensioni appartiene alla classe 5 (voto massimo), mentre le classi 1 e 2 (voti bassi) sono numericamente molto scarse. In una situazione simile, un modello standard tenderebbe a ignorare i feedback negativi, imparando a prevedere quasi esclusivamente il voto più frequente per massimizzare la correttezza statistica globale.

Per risolvere questo problema e rendere il modello capace di identificare anche le critiche, è stato attivato il parametro `class_weight='balanced'`. Grazie a questa configurazione, l'algoritmo assegna automaticamente un'importanza maggiore agli errori commessi sui rating meno frequenti durante l'addestramento. In questo modo, il modello è forzato ad apprendere i pattern tipici delle recensioni negative (come ad esempio i termini di insoddisfazione), garantendo una capacità predittiva più equa tra tutti e cinque i livelli di rating.

5.3.2 Risultati e Analisi delle Metriche

L'addestramento è stato eseguito su un training set pari all'80% del totale. Le performance ottenute sul test set sono riassunte nella Tabella 2.

Classe (Rating)	**Precision**	**Recall**	**F1-Score**	**Support**
1 Stella	0.19	0.38	0.26	148
2 Stelle	0.24	0.34	0.28	309
3 Stelle	0.36	0.37	0.36	588
4 Stelle	0.37	0.40	0.39	939
5 Stelle	0.85	0.73	0.78	2545
Accuracy	**0.58**			

Tabella 2: Metriche di classificazione del modello Logistic Regression

Il modello raggiunge un'accuratezza complessiva del **58%**. Il successo del bilanciamento è confermato dal valore di **Recall** per le classi 1 e 2 (rispettivamente 38% e 34%): questi dati indicano che il sistema è ora in grado di intercettare correttamente una quota significativa di clienti insoddisfatti, un compito che risulterebbe impossibile senza l'adeguamento dei pesi delle classi.

5.3.3 Analisi della Matrice di Confusione

La matrice di confusione (Figura 13) illustra graficamente la distribuzione delle predizioni.

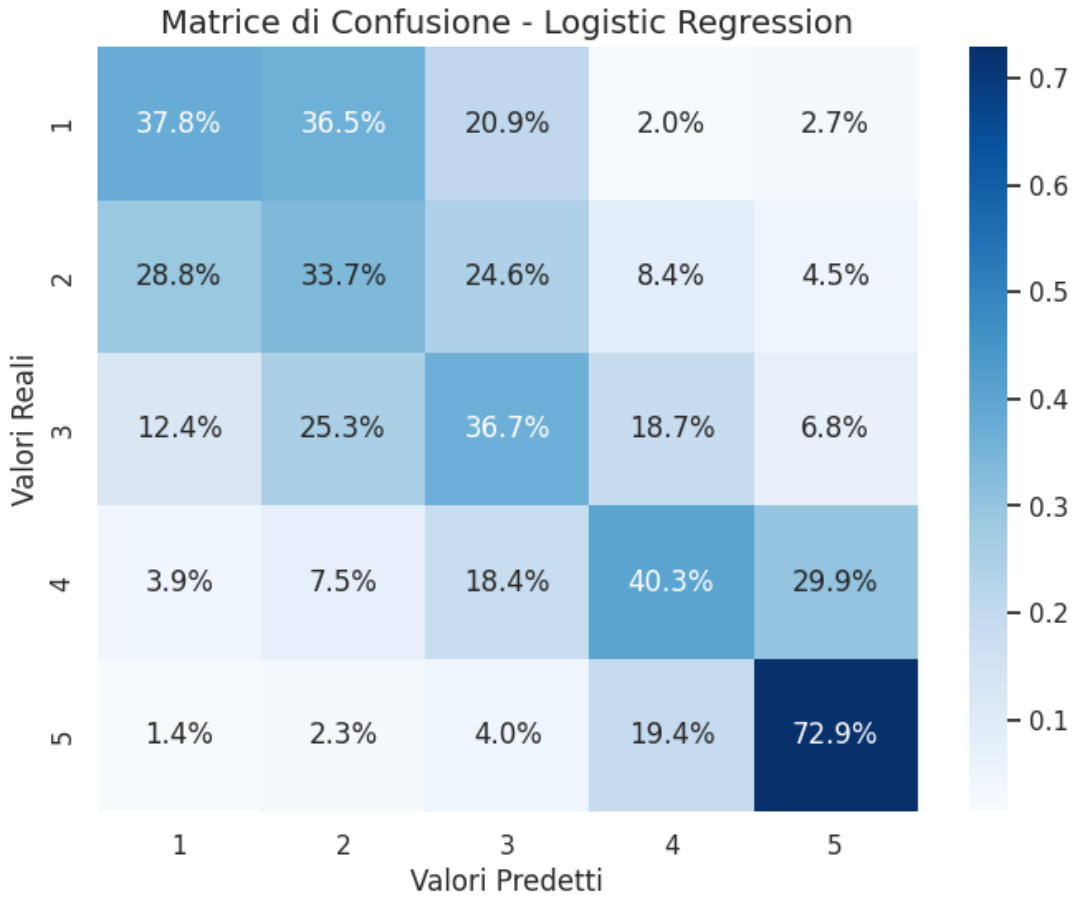


Figura 13: Matrice di confusione multi-classe con Logistic Regression

Dall'analisi della diagonale principale emerge che la classe 5 è quella predetta con maggiore affidabilità (72.9%). Un aspetto fondamentale riguarda la natura degli errori, infatti la matrice mostra che il modello scambia i voti prevalentemente con rating adiacenti (ad esempio, confonde una recensione da 2 stelle con una da 1 o da 3). Questo dimostra che l'algoritmo ha compreso la scala del rating. La sfida maggiore resta la distinzione tra i voti intermedi (3 stelle), dove il linguaggio delle clienti diventa spesso ambiguo, mescolando elementi positivi a critiche.